UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO – FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

INFORME PARCIAL

PROYECTO DE INVESTIGACIÓN II

PLAN DE TESIS Y PROTOCOLO DE INVESTIGACIÓN

SISTEMA HÍBRIDO DE APRENDIZAJE AUTOMÁTICO Y OPTIMIZACIÓN COMBINATORIA PARA LA PLANIFICACIÓN DE RUTAS DE RECOLECCIÓN DE RESIDUOS SÓLIDOS URBANOS

Programa: Maestría en Inteligencia Artificial

Estudiantes:

Grimaldo René Abarca Urbano

Jorge Raúl Valega Marquina

Docente del curso: Dr. Glen Dario Rodriguez Rafael

Lima, noviembre de 2026

Índice

Índice 2
PARTE I. PLAN DE TESIS 5
Datos generales 5
CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA 6
1.1 Diagnóstico 6
1.1.1 Identificación y descripción del problema de estudio 8
1.1.2 Antecedentes de la investigación 9
1.1.3 Formulación del problema 13
1.1.3.1 Formulación del problema general 13
1.1.3.2 Formulación de los problemas específicos 14
1.2 Justificación y alcances 14
1.2.1 Justificación 14
1.2.2 Alcances 15
CAPÍTULO II. OBJETIVOS 16
2.1 Objetivo general 16
2.2 Objetivos específicos 16
CAPÍTULO III. MARCO TEÓRICO 17
3.1 Bases teóricas 17
3.2 Definición de términos 21
3.3 Hipótesis y variables 23
3.3.1 Hipótesis 24
3.3.2 Variables 25
CAPÍTULO IV. DISEÑO METODOLÓGICO 27
4.1 Tipo de investigación 27
4.2 Nivel de investigación 27

4.3 Métodos de trabajo 27
4.4 Población y muestra (cuando corresponda / si aplica) 28
4.5 Tipo de diseño 29
4.6 Técnicas e instrumentos de recolección de datos 30
4.7 Técnicas e instrumentos de análisis y procesamiento de datos 32
4.8 Etapas de intervención del estudio 39
CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS 41
5.1 Cronograma 41
5.2 Presupuesto 41
5.3 Financiamiento 42
PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL 43
6. Datos y material de estudio 43
6.1 Origen, condiciones de uso y trazabilidad 43
6.2 Estructura, diccionario de datos y análisis exploratorio 45
6.3 Ética, privacidad y seguridad 47
6.4 Preprocesamiento y control de fuga de información 48
7. Protocolo experimental 51
7.1 Preguntas de evaluación y criterios de éxito 52
7.2 Diseño de particiones y validación 53
7.3 Métricas y análisis estadístico 54
7.4 Baseline y variantes 55
7.5 Ingeniería de atributos o componentes 57
7.6 Optimización y presupuesto de búsqueda 58
7.7 Reproducibilidad y registro de experimentos 60
8. Resultados parciales y evidencia 63
8.1 Estado de implementación del pipeline 64

8.2 Comparación cuantitativa del baseline y variantes 65
8.3 Ablaciones y análisis de sensibilidad 67
8.4 Sobreajuste, errores y robustez 69
8.5 Interpretación y amenazas a la validez 71
9. Conclusiones del avance y próximos pasos 73
9.1 Conclusiones sustentadas por evidencia 73
9.2 Riesgos y plan de mitigación 74
9.3 Trabajo futuro para el siguiente sprint 76
REFERENCIAS 79
ANEXOS 84
Anexo A. Matriz de consistencia 84
Anexo B. Cronograma detallado 85
Anexo C. Diccionario de datos 86
Anexo D. Configuraciones y tabla completa de corridas 88
Anexo E. Evidencia de ejecución, repositorio, logs, pruebas y figuras 91

PARTE I. PLAN DE TESIS

Datos generales

Campo	Información
Título del plan de tesis	Sistema híbrido de aprendizaje automático y optimización combinatoria para la planificación de rutas de recolección de residuos sólidos urbanos.
Autores	Grimaldo René Abarca Urbano y Jorge Raúl Valega Marquina.
Asesor	Pendiente de designación.
Unidad de posgrado y programa	Unidad de Posgrado de la Facultad de Ingeniería Industrial y de Sistemas – Maestría en Ciencias con mención en Inteligencia Artificial.
Lugar o institución donde se desarrollará el proyecto	Municipalidad Distrital de Yarinacocha, provincia de Coronel Portillo, departamento de Ucayali, Perú.
Duración estimada	Inicio: julio de 2026. Finalización: marzo de 2027.

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

La gestión de residuos sólidos urbanos constituye uno de los principales desafíos ambientales y operativos para los gobiernos locales, debido al crecimiento poblacional, la expansión urbana y el incremento de los residuos generados por las actividades humanas. El Programa de las Naciones Unidas para el Medio Ambiente (PNUMA, 2024) advirtió que la generación mundial de residuos sólidos municipales podría aumentar de aproximadamente 2 000 millones a 3 800 millones de toneladas para el año 2050, situación que incrementaría las exigencias sobre los sistemas de recolección, transporte y disposición final. Asimismo, Kaza et al. (2018) señalaron que numerosas ciudades, especialmente en países en desarrollo, presentan dificultades relacionadas con la cobertura del servicio, la infraestructura disponible y el financiamiento de las operaciones municipales.

En América Latina, esta problemática se manifiesta mediante limitaciones en la planificación de los servicios de limpieza pública y en el aprovechamiento de los recursos operativos. Najar (2024) identificó deficiencias relacionadas con la planificación del servicio, la preparación del personal responsable y la disponibilidad de alternativas eficientes. Asimismo, el Banco Interamericano de Desarrollo (BID, 2024) destacó la importancia de incorporar tecnologías digitales que permitan fortalecer la gestión de residuos sólidos en la región. Estas condiciones evidencian la necesidad de modernizar los procedimientos de planificación y organizar los recorridos de recolección considerando las características territoriales y las necesidades de atención de la población.

En el Perú, Quispe et al. (2024) señalaron que la generación diaria promedio de residuos sólidos municipales aumentó de aproximadamente 19 mil a 21 mil toneladas entre 2014 y 2021. Asimismo, identificaron que, hasta 2019, el 36 % de las municipalidades carecía de estudios de caracterización de residuos sólidos y solamente el 21 % contaba con un Plan Integral de Gestión Ambiental de Residuos Sólidos. Estas cifras reflejan limitaciones en la disponibilidad de información y en los instrumentos de planificación necesarios para organizar adecuadamente las actividades de recolección, particularmente cuando deben considerarse las distancias, los tiempos de desplazamiento y la capacidad de los vehículos disponibles.

En el ámbito local, la Municipalidad Distrital de Yarinacocha (2024) aprobó, mediante la Resolución de Gerencia Municipal N.° 191-2024-MDY-GM, disposiciones orientadas a actualizar el mapa de rutas de recolección de residuos sólidos municipales, ampliar la cobertura del servicio y verificar el cumplimiento de los recorridos establecidos. Posteriormente, la Municipalidad Distrital de Yarinacocha (2025), mediante la Resolución de Gerencia Municipal N.° 148-2025-MDY-GM, aprobó el plan de rutas correspondiente al año 2025, manteniendo como propósito la optimización de la cobertura y el seguimiento de las actividades operativas. Estos antecedentes evidencian la importancia de actualizar permanentemente los recorridos y evaluar su funcionamiento para fortalecer la prestación del servicio municipal.

A partir de este contexto, el problema de estudio se relaciona con la necesidad de evaluar el aprovechamiento de los datos históricos, operativos y geográficos en la planificación de las rutas de recolección. Entre los posibles síntomas operativos que requieren evaluación se encuentran los recorridos prolongados, los desplazamientos innecesarios, las diferencias en los tiempos de atención y las dificultades para distribuir la carga de trabajo entre los vehículos. Como posibles causas se consideran la limitada integración de información sobre la generación de residuos, la utilización de recorridos previamente establecidos y la ausencia de mecanismos predictivos que permitan anticipar la demanda de recolección en los diferentes puntos o sectores del distrito. Estas condiciones deberán comprobarse mediante el diagnóstico de los registros y recorridos municipales.

De mantenerse dichas limitaciones, podrían presentarse consecuencias relacionadas con un mayor consumo de combustible, incremento de los costos operativos, utilización inadecuada de la capacidad vehicular y dificultades para atender oportunamente los sectores programados. Asimismo, la población beneficiaria del servicio podría verse afectada por la acumulación prolongada de residuos en determinados espacios urbanos, con posibles repercusiones ambientales y sanitarias. En este sentido, Chacaltana et al. (2024) destacaron la importancia de incorporar tecnologías eficientes e infraestructura adecuada para fortalecer los sistemas integrados de gestión de residuos sólidos urbanos.

Frente a esta problemática, Fang et al. (2023) reportaron que la aplicación de inteligencia artificial en la logística de residuos permitió reducir hasta un 36,8% la distancia de transporte, un 13,35% los costos operativos y un 28,22% el tiempo de operación. Asimismo, Alsabt et al. (2024) identificaron resultados favorables mediante modelos predictivos aplicados a la generación de residuos y la eficiencia operativa. Estos antecedentes evidencian el potencial

de integrar aprendizaje automático y técnicas de optimización para mejorar la planificación, aunque los beneficios específicos deberán determinarse mediante la evaluación del sistema propuesto en Yarinacocha.

En consecuencia, el diagnóstico permite reconocer la necesidad de desarrollar y evaluar un sistema híbrido de aprendizaje automático y optimización combinatoria que utilice información histórica, operativa y geográfica para predecir la cantidad de residuos sólidos urbanos y generar rutas de recolección factibles. Su evaluación permitirá establecer si las rutas propuestas presentan mejoras respecto de las utilizadas por la Municipalidad Distrital de Yarinacocha, principalmente en términos de distancia y tiempo de recorrido, considerando las restricciones operativas del servicio.

1.1.1 Identificación y descripción del problema de estudio

El problema de estudio se identifica en la necesidad de fortalecer la planificación de las rutas de recolección de residuos sólidos urbanos mediante el aprovechamiento de información histórica, operativa y geográfica que permita anticipar la demanda de residuos y organizar eficientemente los recorridos. Al respecto, Xia et al. (2022) señalaron que las técnicas de aprendizaje automático permiten identificar patrones en los datos y desarrollar modelos predictivos aplicables a diferentes procesos de gestión de residuos sólidos. Por su parte, Liang et al. (2022) destacaron que la planificación de rutas requiere establecer recorridos eficientes para atender los puntos de recolección, considerando las condiciones y restricciones operativas del servicio.

La investigación se desarrollará en el distrito de Yarinacocha, provincia de Coronel Portillo, departamento de Ucayali, durante el año 2026, tomando como ámbito de estudio el servicio de recolección de residuos sólidos urbanos de la Municipalidad Distrital de Yarinacocha. El sistema objeto de análisis estará conformado por las rutas municipales de recolección, los puntos o sectores atendidos, los vehículos asignados y las condiciones operativas relacionadas con la prestación del servicio. La unidad de análisis comprenderá los recorridos y registros operativos disponibles, a partir de los cuales se examinarán las características de la planificación actual y las posibilidades de mejoramiento mediante herramientas computacionales.

En este contexto, la Municipalidad Distrital de Yarinacocha (2024, 2025) aprobó instrumentos relacionados con la actualización de las rutas, la ampliación de la cobertura y el seguimiento del servicio de limpieza pública. Sin embargo, estos documentos no permiten establecer, por

sí solos, el grado de eficiencia alcanzado en los recorridos ni el nivel de aprovechamiento de los datos disponibles para anticipar la generación de residuos. Por ello, será necesario caracterizar las rutas existentes y examinar indicadores operativos que permitan determinar las condiciones actuales de planificación, considerando aspectos como distancia, tiempo, capacidad vehicular y demanda de recolección.

El problema técnico se concentra en la integración de dos procesos complementarios. El primero corresponde a la estimación de la cantidad de residuos sólidos urbanos que se generará en los puntos o sectores de recolección, mediante modelos de aprendizaje automático entrenados con datos históricos y operativos. En este sentido, Cerna et al. (2022) evidenciaron que los modelos predictivos permiten estimar la generación de residuos a partir de variables relacionadas con sus características de producción. El segundo proceso comprende la utilización de dichas estimaciones en un modelo de optimización combinatoria que permita establecer la asignación y secuencia de atención de los vehículos, considerando restricciones de capacidad, horarios, cobertura y condiciones de desplazamiento. Al respecto, Ochoa-Barragán et al. (2023) desarrollaron un enfoque que integró aprendizaje automático y programación matemática para apoyar la optimización de la gestión de residuos sólidos municipales.

Por consiguiente, el estudio se delimitará al desarrollo y evaluación de un sistema híbrido de aprendizaje automático y optimización combinatoria aplicado a la planificación de las rutas de recolección de residuos sólidos urbanos de Yarinacocha. Su desempeño se determinará mediante la comparación de las rutas generadas por el sistema con los recorridos convencionales de la municipalidad, considerando principalmente la distancia y el tiempo de recorrido y, según la disponibilidad de información confiable, el consumo de combustible, el costo operativo, la cobertura, el cumplimiento de las rutas y el aprovechamiento de la capacidad vehicular. De esta manera, se buscará establecer en qué medida la integración de herramientas predictivas y métodos de optimización contribuye a mejorar la planificación del servicio municipal durante el período de estudio.

1.1.2 Antecedentes de la investigación

Antecedentes internacionales

Goswami et al. (2026) desarrollaron un modelo híbrido denominado LO-DCS para optimizar las rutas de recolección de residuos sólidos urbanos mediante algoritmos metaheurísticos, técnicas de búsqueda local 2-opt y agrupamiento K-means. La investigación utilizó

información georreferenciada de Bengaluru, India, y evaluó indicadores relacionados con distancia recorrida, consumo de combustible, emisiones de dióxido de carbono y tiempo operativo. Los resultados mostraron mejoras promedio cercanas al 85 % en los principales indicadores de rendimiento, superando el desempeño de otros algoritmos de optimización. Sin embargo, su propuesta se concentró principalmente en la optimización de recorridos mediante técnicas metaheurísticas, sin desarrollar como componente central un modelo supervisado para predecir la demanda futura de residuos. Este antecedente resulta pertinente porque demuestra la utilidad de integrar métodos computacionales para mejorar la planificación de rutas.

Por su parte, Jerbi et al. (2026) propusieron un sistema inteligente de gestión de residuos que integró sensores del Internet de las cosas, aprendizaje automático y técnicas de optimización. El modelo empleó el algoritmo Dynamic Bald Eagle Search Optimization y técnicas predictivas para monitorear contenedores, estimar la generación de residuos y organizar los recorridos de recolección. Los resultados reportaron niveles de precisión superiores al 96 %, evidenciando la capacidad de estas tecnologías para mejorar la gestión operativa. No obstante, la propuesta dependió de una infraestructura tecnológica basada en sensores y monitoreo, condición que podría limitar su implementación en municipalidades con recursos tecnológicos restringidos. Su aporte al presente estudio radica en demostrar la viabilidad de utilizar predicciones como información para la optimización de rutas, aunque se plantea una alternativa basada principalmente en registros históricos y operativos disponibles.

Asimismo, Ali et al. (2023) desarrollaron un sistema de optimización de rutas de recolección de residuos municipales mediante sensores del Internet de las cosas y el método multicriterio TOPSIS. La investigación consideró variables como volumen de residuos, toxicidad, distancias y tiempos de recorrido para seleccionar trayectos adecuados. Los resultados evidenciaron una reducción aproximada del 14 % en la distancia total recorrida respecto de métodos tradicionales. Sin embargo, el modelo se orientó principalmente a la selección eficiente de rutas mediante información obtenida por sensores, sin incorporar de manera central la predicción de la demanda mediante algoritmos supervisados de aprendizaje automático. Este trabajo aporta criterios relacionados con la selección de recorridos y la incorporación de restricciones operativas en los procesos de optimización.

De igual manera, Niu et al. (2024) formularon un modelo de optimización multiobjetivo para mejorar la gestión de residuos municipales, considerando simultáneamente costos

operativos, emisiones de carbono y satisfacción de los residentes. La investigación incorporó técnicas de aprendizaje automático para orientar la búsqueda de soluciones y evaluó el modelo mediante un caso de aplicación en Pekín, China. Los resultados evidenciaron un rendimiento competitivo frente a otros métodos de optimización y permitieron identificar alternativas eficientes de localización y enrutamiento. Sin embargo, el aprendizaje automático se empleó principalmente como apoyo al proceso de búsqueda, y no como un componente específico destinado a predecir la cantidad de residuos generados en cada punto de recolección. Su contribución se relaciona con la formulación de modelos capaces de considerar múltiples objetivos y restricciones en la planificación de recorridos.

En esa misma línea, Benítez-Bravo et al. (2021) diseñaron una estrategia para optimizar las rutas de recolección de residuos sólidos urbanos en el Área Metropolitana de Monterrey, México. El estudio incorporó herramientas de análisis geográfico, evaluación de costos y técnicas de optimización de recorridos, considerando factores como las condiciones del tránsito, las características de los vehículos y la dirección de las vías. Los resultados evidenciaron reducciones en la distancia recorrida y en las emisiones de gases de efecto invernadero, con mejoras reportadas de hasta el 20 % y el 9 %, respectivamente. No obstante, la propuesta se concentró en la optimización de recorridos y sus efectos ambientales, sin integrar un modelo predictivo de aprendizaje automático para estimar anticipadamente la demanda de residuos. Este antecedente aporta fundamentos para utilizar información territorial y restricciones de desplazamiento en el diseño de rutas municipales.

Finalmente, Xia et al. (2022) realizaron una revisión de investigaciones sobre la aplicación de algoritmos de aprendizaje automático en la gestión de residuos sólidos municipales, considerando procesos de generación, recolección, transporte y disposición final. Los autores identificaron que los modelos predictivos permiten reconocer patrones y estimar cantidades de residuos a partir de información histórica, contribuyendo a mejorar las decisiones operativas. Sin embargo, al tratarse de una revisión de literatura, el trabajo no desarrolló ni evaluó un sistema específico que integrara la predicción de residuos con la optimización combinatoria de rutas en un contexto municipal determinado. Su aporte constituye una base conceptual para seleccionar y evaluar algoritmos predictivos aplicables al sistema híbrido propuesto.

Antecedentes nacionales

En el ámbito nacional, Arista-López (2025) desarrolló una revisión sistemática sobre la aplicación de inteligencia artificial en la gestión de residuos sólidos, mediante el análisis de 47 investigaciones indexadas en Scopus. El estudio identificó aplicaciones relacionadas con visión artificial, aprendizaje profundo, sensores inteligentes y plataformas tecnológicas para mejorar los procesos de gestión. Asimismo, reconoció limitaciones vinculadas con infraestructura tecnológica, disponibilidad de datos y capacitación especializada. Sin embargo, por su carácter de revisión bibliográfica, no implementó ni validó experimentalmente un sistema híbrido de predicción y optimización de rutas en una municipalidad peruana. Su aporte permite reconocer las condiciones tecnológicas que deben considerarse al desarrollar soluciones de inteligencia artificial para gobiernos locales.

Julca (2025) realizó un análisis comparativo de algoritmos de aprendizaje automático para predecir la generación de residuos sólidos en la playa Venecia, ubicada en Lima. La investigación utilizó una base de datos de 200 registros y evaluó modelos como redes neuronales artificiales, árboles de decisión, máquinas de vectores de soporte y K vecinos más cercanos. Los resultados evidenciaron un desempeño favorable de las redes neuronales artificiales, mientras que las máquinas de vectores de soporte presentaron un equilibrio adecuado entre precisión y eficiencia computacional. Sin embargo, el estudio se delimitó a la predicción de residuos en un entorno costero, sin incorporar un módulo de optimización combinatoria para planificar rutas municipales de recolección. Este antecedente resulta relevante para la selección y comparación de algoritmos predictivos.

Asimismo, Sopla (2023) desarrolló una aplicación web basada en sistemas de información geográfica para apoyar la gestión de rutas de recolección de residuos sólidos urbanos en Chachapoyas, Amazonas. La plataforma integró información catastral, archivos geográficos y herramientas de ArcGIS Online, facilitando la representación y actualización de los recorridos municipales. Su principal contribución consistió en proporcionar una herramienta informática para organizar y visualizar información territorial relacionada con el servicio. No obstante, su alcance se concentró en la gestión geográfica de las rutas, sin integrar modelos de aprendizaje automático para predecir la cantidad de residuos ni un procedimiento de optimización combinatoria basado en la demanda estimada. Este trabajo aporta fundamentos para la representación de los puntos de recolección y la construcción de información geográfica necesaria para planificar los recorridos.

Por otra parte, Cerna et al. (2022) desarrollaron un modelo predictivo de aprendizaje automático para estimar la generación de residuos sólidos domiciliarios en una zona rural de Puno. La investigación utilizó información de 50 familias y evaluó algoritmos como redes neuronales artificiales, regresión lineal múltiple, máquinas de vectores de soporte, procesos gaussianos y Random Forest. Los resultados mostraron un desempeño destacado de las redes neuronales, que alcanzaron un coeficiente de determinación de 0,986, evidenciando la utilidad de las variables socioeconómicas para estimar la generación de residuos. Sin embargo, el estudio se limitó a la predicción de cantidades generadas en un contexto rural, sin incorporar restricciones vehiculares, horarios o modelos de optimización de rutas. Su aporte al presente trabajo consiste en demostrar la aplicabilidad de técnicas predictivas para estimar la demanda de residuos a partir de información disponible.

De igual manera, Anton et al. (2021) desarrollaron un sistema informático para optimizar las rutas de recolección de residuos sólidos en Chiclayo, utilizando el algoritmo de Dijkstra y una representación de la red vial mediante grafos dirigidos ponderados. La propuesta empleó información geográfica obtenida mediante Google Maps API para determinar recorridos de menor distancia entre distintos puntos de atención. Los resultados evidenciaron la utilidad de los algoritmos de rutas mínimas para mejorar el procesamiento de recorridos y apoyar la planificación del servicio. Sin embargo, el sistema se concentró en la identificación de caminos más cortos, sin incorporar un modelo predictivo de generación de residuos ni abordar conjuntamente la asignación de múltiples vehículos bajo restricciones de capacidad y horarios. Este antecedente proporciona fundamentos para la representación de redes viales y el cálculo de distancias entre puntos de recolección.

1.1.3 Formulación del problema

1.1.3.1 Formulación del problema general

- ¿En qué medida el desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará la planificación de las rutas de recolección de residuos sólidos urbanos?

1.1.3.2 Formulación de los problemas específicos

- ¿Qué patrones de generación de residuos sólidos urbanos se identifican mediante el análisis de los datos históricos, operativos y geográficos de los puntos o sectores de recolección?
- ¿En qué medida un modelo de aprendizaje automático permite predecir la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección?
- ¿Cómo diseñar un modelo de optimización combinatoria que permita generar rutas de recolección factibles, considerando la demanda estimada, la capacidad vehicular, las restricciones horarias, la cobertura y las condiciones operativas del servicio?
- ¿Qué diferencias existen entre las rutas generadas por el sistema híbrido y las rutas convencionales respecto a la distancia y el tiempo de recorrido, el consumo de combustible, el costo operativo, la cobertura del servicio, el cumplimiento de las rutas y el aprovechamiento de la capacidad vehicular?

1.2 Justificación y alcances

1.2.1 Justificación

Desde el enfoque teórico y tecnológico, el estudio contribuyó al conocimiento sobre la integración de modelos predictivos y técnicas de optimización para la gestión de residuos sólidos. El aprendizaje automático permitió estimar la demanda de recolección a partir de datos históricos y operativos, mientras que la optimización combinatoria facilitó la generación de rutas considerando la capacidad vehicular, los horarios y las condiciones del servicio.

En el ámbito práctico, la investigación buscó proporcionar una herramienta que contribuyera a mejorar la planificación municipal mediante la reducción de distancias y tiempos de recorrido. Su utilidad se evaluó mediante la comparación de las rutas propuestas con las convencionales, considerando también otros indicadores operativos cuando se dispuso de información confiable.

Desde la perspectiva metodológica, se estableció un procedimiento para recopilar y procesar datos, entrenar modelos predictivos, optimizar recorridos y evaluar resultados. Asimismo, el estudio tuvo relevancia social y ambiental, debido a que una planificación más eficiente podía favorecer la cobertura del servicio, el aprovechamiento de los recursos municipales y la reducción de la acumulación de residuos en los espacios públicos.

1.2.2 Alcances

La investigación se desarrolló en el distrito de Yarinacocha, provincia de Coronel Portillo, Ucayali, durante 2026. Comprendió el análisis de datos históricos, operativos y geográficos del servicio municipal de recolección de residuos sólidos urbanos, así como el desarrollo y evaluación de un sistema híbrido de aprendizaje automático y optimización combinatoria para predecir la demanda de residuos y generar rutas eficientes.

El estudio incluyó la comparación de las rutas propuestas con las convencionales, principalmente mediante indicadores de distancia y tiempo de recorrido, considerando la capacidad vehicular, los horarios y las condiciones operativas. No comprendió los procesos de reciclaje, tratamiento o disposición final de residuos, ni la instalación de sensores inteligentes o la implementación permanente del sistema en la municipalidad.

Se asumió la disponibilidad de registros suficientes para entrenar y evaluar los modelos, así como de información geográfica para representar los recorridos. Las principales restricciones estuvieron relacionadas con la calidad y actualización de los datos municipales, las condiciones de las vías, el clima y la disponibilidad de información operativa. Los resultados se circunscribieron al contexto estudiado y su utilización en otras municipalidades requirió adaptaciones según sus características y condiciones operativas.

CAPÍTULO II. OBJETIVOS

2.1 Objetivo general

- Determinar en qué medida el desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará la planificación de las rutas de recolección de residuos sólidos urbanos.

2.2 Objetivos específicos

- Identificar los patrones de generación de residuos sólidos urbanos mediante el análisis de los datos históricos, operativos y geográficos de los puntos o sectores de recolección.
- Evaluar la capacidad predictiva de un modelo de aprendizaje automático para estimar la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección.
- Diseñar un modelo de optimización combinatoria para generar rutas de recolección factibles, considerando la demanda estimada, la capacidad vehicular, las restricciones horarias, la cobertura y las condiciones operativas del servicio.
- Comparar las rutas generadas por el sistema híbrido con las rutas convencionales, considerando la distancia y el tiempo de recorrido, el consumo de combustible, el costo operativo, la cobertura del servicio, el cumplimiento de las rutas y el aprovechamiento de la capacidad vehicular.

CAPÍTULO III. MARCO TEÓRICO

3.1 Bases teóricas

Recolección y transporte de residuos sólidos urbanos

La recolección de residuos sólidos urbanos comprende las actividades destinadas a retirar los desechos generados en viviendas, establecimientos comerciales, instituciones y espacios públicos, para trasladarlos hacia lugares autorizados de tratamiento o disposición final. Este proceso requiere una planificación adecuada de los recursos humanos, vehículos, horarios y recorridos, debido a su influencia sobre la eficiencia del servicio. López et al. (2023) señalaron que la optimización de las rutas constituye una alternativa para mejorar las operaciones de recolección, mediante la reducción de desplazamientos y el aprovechamiento de los recursos disponibles.

Asimismo, Liang et al. (2022) explicaron que la planificación de rutas de recolección representa un problema logístico que involucra múltiples puntos de atención, vehículos y restricciones operativas. En consecuencia, la eficiencia del servicio no depende únicamente de seleccionar recorridos cortos, sino también de considerar la cantidad de residuos, la capacidad de transporte y las condiciones de acceso. Estos fundamentos permiten comprender la necesidad de desarrollar herramientas computacionales que contribuyan a organizar las operaciones municipales.

Fundamentos del aprendizaje automático

El aprendizaje automático constituye una rama de la inteligencia artificial que permite desarrollar modelos capaces de identificar patrones y realizar predicciones mediante el análisis de información histórica. Su funcionamiento se basa en algoritmos que reconocen relaciones entre variables y ajustan sus parámetros durante el entrenamiento. Xia et al. (2022) señalaron que estas técnicas presentan aplicaciones relevantes en la gestión de residuos sólidos municipales, especialmente en la estimación de cantidades generadas y el apoyo a las decisiones operativas.

El desarrollo de modelos de aprendizaje automático comprende procesos de recopilación, preparación y transformación de datos, selección de características, entrenamiento y evaluación del desempeño. Entre los algoritmos utilizados destacan las redes neuronales artificiales, árboles de decisión, máquinas de vectores de soporte, Random Forest y métodos de potenciación por gradiente. Según Xia et al. (2022), estos métodos permiten analizar relaciones complejas entre variables y desarrollar modelos predictivos adaptados a

diferentes características de los datos. En la presente investigación, el aprendizaje automático permitirá estimar la cantidad de residuos sólidos urbanos que deberá recolectarse en los distintos puntos o sectores del distrito de Yarinacocha.

Modelos predictivos aplicados a la gestión de residuos

Los modelos predictivos permiten estimar anticipadamente la cantidad de residuos que podrían generarse en un lugar y período determinado, utilizando información histórica y variables relacionadas con su producción. Alsabt et al. (2024) señalaron que la aplicación de algoritmos de aprendizaje automático puede contribuir a mejorar las estrategias de gestión de residuos, siempre que se disponga de información adecuada y procedimientos de preparación de datos que favorezcan la confiabilidad de las estimaciones.

Entre las técnicas utilizadas destacan Random Forest y XGBoost, que permiten identificar relaciones entre múltiples variables y generar predicciones sobre cantidades de residuos. Alsabt et al. (2024) evaluaron diferentes algoritmos predictivos y destacaron la importancia del procesamiento de datos para mejorar su desempeño. En este contexto, la selección del modelo deberá considerar indicadores como el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), con la finalidad de identificar el algoritmo que presente un comportamiento adecuado para la demanda de recolección.

Predicción de la generación de residuos sólidos

La predicción de la generación de residuos constituye un proceso que permite anticipar las necesidades de recolección mediante el análisis de patrones históricos, variaciones temporales y características de los sectores atendidos. Ramos et al. (2019) señalaron que el aprendizaje automático puede utilizarse para estimar el comportamiento de acumulación de residuos y proporcionar información que facilite posteriormente la planificación de los recorridos. De esta manera, las predicciones permiten relacionar la demanda esperada con la asignación de recursos operativos.

Asimismo, Zhao et al. (2024) destacaron que los modelos predictivos permiten analizar las variables que influyen en la generación de residuos sólidos municipales y estimar su comportamiento futuro. Entre los factores que pueden considerarse se encuentran la cantidad recolectada anteriormente, la frecuencia de atención, la ubicación geográfica y las características temporales del servicio. En la presente investigación, las estimaciones

obtenidas mediante aprendizaje automático constituirán información de entrada para el modelo de optimización combinatoria encargado de generar las rutas de recolección.

Internet de las cosas y contenedores inteligentes

El Internet de las cosas (IoT) comprende tecnologías que permiten conectar dispositivos físicos con sistemas informáticos para recopilar y transmitir información. En la gestión de residuos sólidos, esta tecnología puede facilitar el monitoreo de contenedores mediante sensores que registran niveles de llenado, peso, temperatura y otras condiciones operativas. Ogbolumani y Adekoya (2025) señalaron que la integración de sensores inteligentes y aprendizaje automático puede contribuir a mejorar la planificación de las actividades de recolección.

Sin embargo, la utilización de estas tecnologías requiere infraestructura, conectividad y mantenimiento especializado. Por ello, en la presente investigación, los sensores y contenedores inteligentes se considerarán alternativas tecnológicas complementarias, debido a que el sistema híbrido será desarrollado principalmente mediante información histórica, operativa y geográfica disponible en la Municipalidad Distrital de Yarinacocha.

Optimización combinatoria y planificación de rutas

La optimización combinatoria comprende un conjunto de métodos matemáticos y computacionales orientados a identificar soluciones eficientes entre diversas alternativas posibles, considerando objetivos y restricciones previamente definidos. Bai et al. (2023) señalaron que los problemas de enrutamiento de vehículos constituyen un campo relevante para la aplicación de técnicas de optimización y aprendizaje automático, debido a la complejidad que representa organizar múltiples recorridos con recursos limitados.

En la recolección de residuos sólidos urbanos, la optimización combinatoria permite determinar la asignación de puntos de atención a los vehículos y establecer la secuencia de recorrido, considerando distancias, tiempos y capacidades disponibles. Liang et al. (2022) destacaron la importancia de los métodos heurísticos para resolver problemas de recolección de residuos, especialmente cuando intervienen numerosas ubicaciones y restricciones operativas. En este estudio, dichas técnicas permitirán generar rutas factibles utilizando las estimaciones de demanda obtenidas mediante aprendizaje automático.

Problema de enrutamiento de vehículos

El problema de enrutamiento de vehículos, conocido como VRP, consiste en determinar las rutas que deberá seguir un conjunto de vehículos para atender diferentes puntos, procurando minimizar los costos, distancias o tiempos de desplazamiento. Liang et al. (2022) explicaron que su aplicación en la gestión de residuos permite organizar los recorridos considerando los puntos de recolección y las características de los vehículos disponibles.

Una variante importante es el problema de enrutamiento de vehículos capacitado con ventanas de tiempo (CVRPTW), que incorpora restricciones relacionadas con la capacidad máxima de carga y los horarios establecidos para atender los diferentes puntos. Silva et al. (2025) señalaron que las herramientas de optimización permiten abordar restricciones urbanas y operativas en la planificación de flotas de recolección. Por consiguiente, la presente investigación utilizará este enfoque para generar recorridos que consideren la demanda estimada, la capacidad vehicular y las condiciones temporales del servicio.

Redes viales y sistemas de información geográfica

Los sistemas de información geográfica permiten recopilar, organizar y representar datos vinculados con ubicaciones territoriales, facilitando el análisis espacial de los puntos de recolección y las vías de desplazamiento. Alzate Montoya et al. (2024) señalaron que la representación de redes viales mediante nodos y conexiones permite analizar alternativas de recorrido y determinar trayectos eficientes, considerando las características geográficas y operativas del territorio.

Asimismo, Hu et al. (2024) explicaron que la integración de información geográfica con algoritmos de optimización permite mejorar la planificación de los recorridos de recolección y transporte de residuos sólidos municipales. En la presente investigación, estas herramientas permitirán representar los puntos o sectores de recolección del distrito de Yarinacocha y construir matrices de distancias y tiempos de desplazamiento, que posteriormente serán utilizadas por el modelo de optimización combinatoria.

Detección y clasificación de residuos mediante inteligencia artificial

La inteligencia artificial también puede aplicarse a la identificación y clasificación automática de residuos sólidos mediante técnicas de visión por computadora y aprendizaje profundo. Granda Cruz y Agurto Marchena (2024) señalaron que los sistemas inteligentes pueden reconocer características visuales de los residuos mediante el procesamiento de imágenes, contribuyendo a automatizar determinadas actividades relacionadas con su gestión.

Sin embargo, estas aplicaciones requieren conjuntos de imágenes representativos y recursos computacionales adecuados. Por ello, la presente investigación no comprenderá la clasificación automática de residuos mediante imágenes, debido a que su finalidad principal será predecir la demanda de recolección y optimizar los recorridos de los vehículos municipales. No obstante, estas tecnologías podrán considerarse alternativas complementarias para futuras aplicaciones.

Articulación teórica del sistema híbrido propuesto

Los fundamentos analizados permiten establecer que la integración del aprendizaje automático y la optimización combinatoria constituye una alternativa tecnológica para fortalecer la planificación de rutas de recolección de residuos sólidos urbanos. Ochoa-Barragán et al. (2023) desarrollaron un enfoque que combinó modelos de aprendizaje automático con programación matemática para apoyar la gestión de residuos municipales, evidenciando las posibilidades de utilizar información predictiva en procesos de optimización.

En la presente investigación, el sistema híbrido estará conformado por tres componentes principales: preparación e integración de datos, predicción de la demanda mediante aprendizaje automático y optimización combinatoria de las rutas de recolección. El primer componente organizará los registros históricos, operativos y geográficos; el segundo estimará la cantidad de residuos esperada en los puntos o sectores; y el tercero utilizará dichas estimaciones para generar rutas factibles mediante un modelo de enrutamiento con restricciones de capacidad y tiempo.

Finalmente, las rutas generadas serán comparadas con las utilizadas convencionalmente por la Municipalidad Distrital de Yarinacocha, considerando principalmente la distancia y el tiempo de recorrido, así como otros indicadores operativos cuya información se encuentre disponible. Esta integración permitirá evaluar el desempeño del sistema híbrido y determinar su contribución a la planificación de las rutas de recolección de residuos sólidos urbanos.

3.2 Definición de términos

- **Residuos sólidos urbanos:** Comprenden los desechos generados por las actividades domésticas, comerciales e institucionales desarrolladas en las ciudades, cuya gestión incluye la generación, almacenamiento, recolección, transporte, tratamiento y disposición final. Xia et al. (2022) señalaron que el crecimiento poblacional y la urbanización incrementan la producción de residuos sólidos municipales, lo que hace necesario incorporar tecnologías que contribuyan a mejorar su gestión.

- **Aprendizaje automático (Machine Learning):** Es una rama de la inteligencia artificial que utiliza algoritmos capaces de identificar patrones, analizar información histórica y realizar predicciones a partir de los datos disponibles. Xia et al. (2022) explicaron que estas técnicas permiten desarrollar modelos predictivos aplicables a diferentes etapas de la gestión de residuos sólidos, particularmente en la estimación de cantidades generadas y la planificación de operaciones de recolección.
- **Sistema híbrido de aprendizaje automático y optimización:** Es un sistema tecnológico que integra modelos predictivos de aprendizaje automático con métodos de optimización matemática para mejorar la toma de decisiones. Ochoa-Barragán et al. (2023) desarrollaron un enfoque que combinó técnicas de aprendizaje automático y programación matemática, utilizando las estimaciones generadas por los modelos como información para optimizar procesos relacionados con la gestión de residuos sólidos municipales.
- **Predicción de la generación de residuos:** Es el proceso mediante el cual se estima anticipadamente la cantidad de residuos sólidos que podría generarse en un lugar y período determinado, utilizando información histórica y variables relacionadas con su producción. Zhao et al. (2024) señalaron que la predicción de residuos sólidos municipales constituye una herramienta importante para anticipar las necesidades operativas y contribuir a una gestión más eficiente del servicio.
- **Optimización combinatoria:** Es un procedimiento matemático y computacional orientado a identificar la solución más conveniente entre diferentes alternativas posibles, considerando una función objetivo y determinadas restricciones. Bai et al. (2023) señalaron que los problemas de enrutamiento de vehículos constituyen aplicaciones relevantes de la optimización combinatoria, debido a que requieren determinar recorridos eficientes mediante la asignación de vehículos y puntos de atención.
- **Problema de enrutamiento de vehículos (VRP):** Es un problema de optimización que busca determinar las rutas que deben seguir uno o varios vehículos para atender diferentes puntos, procurando minimizar distancias, tiempos o costos de desplazamiento. Liang et al. (2022) explicaron que, en la recolección de residuos sólidos, los puntos de atención pueden representarse mediante nodos conectados por una red vial, permitiendo establecer recorridos eficientes según las condiciones operativas del servicio.

- **Problema de enrutamiento de vehículos capacitado con ventanas de tiempo (CVRPTW):** Es una variante del problema de enrutamiento de vehículos que incorpora restricciones relacionadas con la capacidad máxima de carga y los horarios establecidos para atender los puntos de recolección. Silva et al. (2025) abordaron la optimización de flotas de recolección mediante herramientas computacionales que consideran restricciones urbanas y operativas, proporcionando fundamentos para organizar recorridos factibles de acuerdo con la disponibilidad y capacidad vehicular.
- **Planificación de rutas de recolección:** Es el proceso mediante el cual se organizan los puntos de atención, la asignación de vehículos y la secuencia de los recorridos, con la finalidad de aprovechar eficientemente los recursos disponibles. Liang et al. (2022) señalaron que la planificación de rutas de recolección busca atender los puntos establecidos mediante recorridos que reduzcan distancias o tiempos, considerando las características y restricciones operativas del servicio.
- **Sistema de Información Geográfica (SIG):** Es una herramienta tecnológica que permite recopilar, almacenar, representar y analizar información asociada con ubicaciones geográficas y redes viales. Hu et al. (2024) señalaron que la integración de información espacial con modelos de enrutamiento contribuye a mejorar la planificación de las operaciones de recolección y transporte de residuos sólidos, facilitando la identificación de recorridos adecuados.
- **Demanda de recolección:** Corresponde a la cantidad de residuos sólidos que requiere ser recogida en un punto o sector durante un período determinado y que debe considerarse para organizar los recorridos y asignar la capacidad de los vehículos. Silva et al. (2025) destacaron la importancia de incorporar restricciones de capacidad y condiciones operativas en los modelos de optimización de flotas, debido a que estos elementos permiten determinar la factibilidad de las rutas de recolección.

3.3 Hipótesis y variables

- El desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará significativamente la planificación de las rutas de recolección de residuos sólidos urbanos.

3.3.1 Hipótesis

- Los patrones de generación de residuos sólidos urbanos presentan variaciones identificables mediante el análisis de los datos históricos, operativos y geográficos de los puntos o sectores de recolección.
- El modelo de aprendizaje automático presenta una capacidad predictiva adecuada para estimar con precisión la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección.
- El modelo de optimización combinatoria permitirá generar rutas de recolección factibles, cumpliendo las restricciones de demanda estimada, capacidad vehicular, horarios, cobertura y condiciones operativas del servicio.
- Las rutas generadas por el sistema híbrido serán significativamente más eficientes que las rutas convencionales, al reducir la distancia y el tiempo de recorrido, el consumo de combustible y el costo operativo, y mejorar la cobertura, el cumplimiento del servicio y el aprovechamiento de la capacidad vehicular.

3.3.2 Variables

Tabla 1

Operacionalización de las variables sistema híbrido de aprendizaje automático y optimización combinatoria

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Ítems	Escala de medición
Sistema híbrido de aprendizaje automático y optimización combinatoria	Sistema tecnológico que integrará modelos de aprendizaje automático para predecir la cantidad o demanda de residuos y técnicas de optimización combinatoria para asignar los puntos de recolección a los vehículos y establecer su secuencia de atención, considerando restricciones geográficas, temporales y operativas.	Se desarrollará mediante la recopilación y depuración de datos históricos, operativos y geográficos; el entrenamiento y evaluación de modelos predictivos; y la aplicación de un modelo CVRPTW para generar rutas factibles. Su funcionamiento será medido mediante reportes de los algoritmos desarrollados en Python, Scikit-learn, OR-Tools, GeoPandas, OSMnx, NetworkX y QGIS.	Preparación e integración de datos	Porcentaje de registros válidos.	**I1.** Número total de registros recopilados.**I2.** Número de registros válidos después de la depuración.	Razón
				Porcentaje de completitud de los datos.	**I3.** Número de campos obligatorios completos.**I4.** Número total de campos obligatorios evaluados.	Razón
				Porcentaje de puntos correctamente georreferenciados.	**I5.** Número de puntos con coordenadas geográficas válidas.**I6.** Número total de puntos de recolección registrados.	Razón
				Disponibilidad de la matriz de distancias y tiempos.	**I7.** Generación de la matriz de distancias.**I8.** Generación de la matriz de tiempos de desplazamiento.	Nominal dicotómica: Sí/No
			Desempeño predictivo del aprendizaje automático	Error absoluto medio — MAE.	**I9.** Diferencia absoluta promedio entre los valores reales y los valores estimados.	Razón
				Error cuadrático medio — MSE.	**I10.** Promedio de los errores elevados al cuadrado.	Razón
				Raíz del error cuadrático medio — RMSE.	**I11.** Raíz cuadrada del promedio de los errores cuadráticos.	Razón
				Coeficiente de determinación — R^2.	**I12.** Proporción de la variabilidad de la demanda de residuos explicada por el modelo.	Intervalo
				Tiempo de entrenamiento del modelo.	**I13.** Tiempo empleado para entrenar cada algoritmo predictivo.	Razón
				Tiempo de generación de las predicciones.	**I14.** Tiempo empleado para predecir la demanda de recolección.	Razón
			Optimización combinatoria de rutas	Porcentaje de rutas factibles generadas.	**I15.** Número de rutas que cumplen todas las restricciones.**I16.** Número total de rutas generadas.	Razón
				Cumplimiento de la capacidad vehicular.	**I17.** Carga asignada a cada vehículo.**I18.** Capacidad máxima de cada vehículo.	Razón
				Cumplimiento de las ventanas de tiempo.	**I19.** Número de puntos atendidos dentro del horario establecido.**I20.** Número total de puntos con restricciones horarias.	Razón
				Cobertura de puntos incorporados en las rutas.	**I21.** Número de puntos incluidos en las rutas optimizadas.**I22.** Número total de puntos programados.	Razón
				Número de restricciones operativas incumplidas.	**I23.** Incumplimientos de capacidad.**I24.** Incumplimientos de horario.**I25.** Incumplimientos de cobertura o acceso.	Razón
				Tiempo computacional de optimización.	**I26.** Tiempo empleado por OR-Tools para encontrar la solución final.	Razón

Tabla 2

Operacionalización de las variables planificación de rutas de recolección de residuos sólidos urbanos

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Ítems	Escala de medición
Planificación de rutas de recolección de residuos sólidos urbanos	Grado en que la planificación permitirá atender los puntos de recolección mediante una adecuada asignación y secuencia de vehículos, reduciendo la distancia, el tiempo, el consumo de combustible y los costos operativos, sin incumplir la capacidad vehicular, los horarios y la cobertura requerida.	Se medirá comparando los resultados de las rutas convencionales —O_1— con los resultados de las rutas generadas por el sistema híbrido —O_2—. Se utilizarán fichas de observación, registros municipales, matriz comparativa de rutas, reportes del algoritmo de optimización, Python, OR-Tools, GeoPandas y QGIS.	Eficiencia del recorrido	Distancia total recorrida.	**I1.** Kilómetros recorridos por cada ruta antes y después de la intervención.	Razón
				Tiempo total de recorrido.	**I2.** Minutos u horas transcurridos desde la salida hasta la finalización de la ruta.	Razón
				Velocidad promedio.	**I3.** Relación entre la distancia recorrida y el tiempo empleado.	Razón
				Porcentaje de reducción de la distancia.	**I4.** Diferencia porcentual entre la distancia convencional y la distancia optimizada.	Razón
				Porcentaje de reducción del tiempo.	**I5.** Diferencia porcentual entre el tiempo convencional y el tiempo optimizado.	Razón
			Eficiencia económica y energética	Consumo total de combustible.	**I6.** Litros de combustible utilizados durante cada recorrido.	Razón
				Consumo de combustible por kilómetro.	**I7.** Relación entre los litros consumidos y los kilómetros recorridos.	Razón
				Costo operativo total.	**I8.** Costo de combustible, personal, mantenimiento y otros recursos utilizados en cada ruta.	Razón
				Costo operativo por kilómetro.	**I9.** Relación entre el costo total de la ruta y la distancia recorrida.	Razón
				Porcentaje de reducción del consumo de combustible.	**I10.** Diferencia porcentual entre el consumo convencional y el consumo posterior.	Razón
				Porcentaje de reducción del costo operativo.	**I11.** Diferencia porcentual entre el costo convencional y el costo posterior.	Razón
			Cobertura y cumplimiento del servicio	Número de puntos programados.	**I12.** Total de puntos previstos para ser atendidos en cada ruta.	Razón
				Número de puntos atendidos.	**I13.** Total de puntos efectivamente atendidos durante el recorrido.	Razón
				Porcentaje de puntos atendidos.	**I14.** Relación porcentual entre los puntos atendidos y los puntos programados.	Razón
				Porcentaje de cumplimiento de la ruta.	**I15.** Proporción del recorrido programado que fue ejecutado.	Razón
				Número de puntos o sectores no atendidos.	**I16.** Total de puntos programados que no fueron atendidos.	Razón
			Productividad y aprovechamiento vehicular	Cantidad total de residuos recolectados.	**I17.** Peso o volumen total de residuos recolectados por ruta.	Razón
				Cantidad de residuos recolectados por punto.	**I18.** Relación entre la cantidad recolectada y el número de puntos atendidos.	Razón
				Cantidad de residuos recolectados por kilómetro.	**I19.** Relación entre la cantidad recolectada y la distancia total recorrida.	Razón
				Porcentaje de utilización de la capacidad vehicular.	**I20.** Relación porcentual entre la carga transportada y la capacidad máxima del vehículo.	Razón
				Número de puntos atendidos por vehículo.	**I21.** Relación entre los puntos atendidos y los vehículos utilizados.	Razón

CAPÍTULO IV. DISEÑO METODOLÓGICO

4.1 Tipo de investigación

La investigación fue de tipo aplicada, porque estuvo orientada a resolver una problemática concreta relacionada con la planificación de rutas de recolección de residuos sólidos urbanos mediante herramientas de inteligencia artificial. Para ello, se desarrolló un sistema híbrido que procesó datos históricos, operativos y geográficos sobre puntos de recolección, distancias, tiempos de desplazamiento, capacidad vehicular, cantidad estimada de residuos y restricciones del servicio. El aprendizaje automático permitió predecir la demanda de residuos, mientras que la optimización combinatoria utilizó dichas estimaciones para determinar la asignación de vehículos y la secuencia de las rutas. Este enfoque fue coherente con Hernández et al. (2014), quienes señalaron que la investigación aplicada se orienta a la utilización del conocimiento para atender problemas concretos.

4.2 Nivel de investigación

La investigación tuvo un nivel explicativo, porque buscó determinar el efecto del sistema híbrido de aprendizaje automático y optimización combinatoria sobre la eficiencia de la planificación de rutas de recolección de residuos sólidos urbanos. El sistema propuesto constituyó la variable independiente, mientras que la planificación de rutas representó la variable dependiente, evaluada mediante indicadores como distancia recorrida, tiempo de operación, consumo estimado de combustible, cobertura del servicio y aprovechamiento de la capacidad vehicular. Según Ruiz y Valenzuela (2022), la investigación explicativa busca comprender las relaciones causales entre las variables estudiadas. En ese sentido, la comparación de los resultados antes y después de la intervención permitió evaluar los cambios asociados con la aplicación del sistema híbrido.

4.3 Métodos de trabajo

La investigación empleó el método experimental mediante un diseño preexperimental, porque se introdujo deliberadamente un sistema híbrido de aprendizaje automático y optimización combinatoria para evaluar sus efectos sobre la planificación de rutas de recolección de residuos sólidos urbanos. Inicialmente, se recopilaron datos históricos, operativos y geográficos sobre las rutas convencionales, puntos de recolección, distancias, tiempos, capacidad vehicular y cantidad de residuos. Posteriormente, se desarrolló un modelo de aprendizaje automático que generó predicciones utilizadas por el componente de

optimización combinatoria para diseñar rutas alternativas. Finalmente, se compararon los resultados obtenidos antes y después de la intervención mediante los mismos indicadores operativos. Este procedimiento se sustentó en Hernández et al. (2014), quienes explicaron que los estudios experimentales implican la manipulación de una variable independiente para observar sus efectos sobre otra variable.

4.4 Población y muestra (cuando corresponda / si aplica)

La población estuvo conformada por la totalidad de los registros operativos de las jornadas y recorridos de recolección de residuos sólidos urbanos ejecutados por la Municipalidad Distrital de Yarinacocha entre enero y diciembre de 2026. Cada recorrido o jornada registrada constituyó una unidad de análisis y comprendió información necesaria para identificar patrones operativos, entrenar los modelos de aprendizaje automático y proporcionar datos al algoritmo de optimización combinatoria.

Tabla 3
Características de la población del estudio

Aspecto	Descripción
Población	▪ Totalidad de los registros operativos de las jornadas y recorridos de recolección de residuos sólidos urbanos.
Institución	▪ Municipalidad Distrital de Yarinacocha.
Ámbito geográfico	▪ Distrito de Yarinacocha, provincia de Coronel Portillo, región Ucayali.
Periodo	▪ Enero a diciembre de 2026.
Unidad de análisis	▪ Cada recorrido o jornada de recolección debidamente registrada.
Información geográfica	▪ Rutas realizadas, puntos de recolección y coordenadas geográficas.
Información temporal	▪ Tiempos de desplazamiento y servicio, horarios de operación y frecuencia de recolección.
Información operativa	▪ Distancias recorridas, número de paradas, capacidad de carga vehicular, consumo de combustible y restricciones del recorrido.
Información sobre residuos	▪ Volumen o peso estimado de los residuos recolectados.
Atributos asociados	▪ Vehículos recolectores, sectores atendidos, puntos de recolección y condiciones operativas.
Finalidad de los datos	▪ Identificar patrones del servicio, entrenar los modelos de aprendizaje automático y proporcionar información al algoritmo de optimización combinatoria.

Nota. La población está basada en registros reales y verificables del servicio municipal de recolección de residuos sólidos urbanos.

La muestra fue censal, debido a que comprendió la totalidad de los registros operativos disponibles entre enero y diciembre de 2026 que cumplieron con los criterios de calidad establecidos. Por ello, no se aplicó una fórmula estadística de muestreo. Se incluyeron los

registros completos y consistentes sobre rutas, vehículos, puntos atendidos, coordenadas geográficas, distancias, tiempos, volumen o peso de residuos y demás variables requeridas por el sistema. Se excluyeron los registros duplicados, incompletos, ilegibles o con inconsistencias geográficas y operativas. Después de la depuración, el número de registros válidos constituyó la muestra efectiva del estudio, representada por n, cuyo valor quedó sujeto a la consolidación de la base de datos municipal.

Tabla 4

Características de la muestra del estudio

Aspecto	Descripción
Tipo de muestra	▪ Censal.
Muestra inicial	▪ Totalidad de los registros operativos disponibles correspondientes al periodo de estudio.
Muestra efectiva	▪ Registros que cumplan con los criterios de inclusión y calidad de datos.
Tamaño de la muestra	▪ Se representará mediante **n** y será determinado después de la depuración y consolidación de la base de datos.
Criterios de inclusión	▪ Registros con información completa sobre fecha, vehículo, puntos atendidos, coordenadas geográficas, distancia, tiempo, volumen o peso de residuos y demás variables requeridas.
Criterios de exclusión	▪ Registros duplicados, incompletos, ilegibles, con coordenadas inconsistentes o ausencia de variables esenciales.
Entrenamiento	▪ Aproximadamente el 70% de los registros válidos.
Validación	▪ Aproximadamente el 15% de los registros válidos.
Prueba	▪ Aproximadamente el 15% de los registros válidos.
Criterio de división	▪ Cuando exista una secuencia temporal, los subconjuntos serán organizados cronológicamente para evitar la incorporación de información futura en el entrenamiento.
Uso de los resultados	▪ Las predicciones serán incorporadas al modelo de optimización combinatoria y las rutas obtenidas serán comparadas con las rutas convencionales.
Indicadores de comparación	▪ Distancia total, tiempo de recorrido, consumo estimado de combustible, cobertura del servicio y aprovechamiento de la capacidad vehicular.

Nota. La distribución de 70%, 15% y 15% podrá ajustarse según la cantidad y calidad de los registros disponibles, sin alterar la separación entre los datos de entrenamiento, validación y prueba.

4.5 Tipo de diseño

La investigación empleó un diseño preexperimental con un solo grupo y mediciones antes y después de la intervención. Según Hernández et al. (2014), este diseño permitió evaluar los cambios observados en una variable dependiente después de aplicar un estímulo o tratamiento, aunque presentó limitaciones para establecer relaciones causales debido a la ausencia de un grupo de control y asignación aleatoria.

El diseño se representó mediante el esquema G: O_1 — X — O_2, donde G correspondió a las rutas o unidades operativas evaluadas; O_1, a la medición inicial de la planificación convencional; X, a la aplicación del sistema híbrido de aprendizaje automático y optimización combinatoria; y O_2, a la medición posterior a la intervención. Ambas evaluaciones consideraron indicadores como distancia recorrida, tiempo de operación, consumo estimado de combustible, cobertura de puntos programados y aprovechamiento de la capacidad vehicular.

El sistema procesó los datos disponibles, generó predicciones sobre la demanda de residuos y propuso rutas optimizadas considerando las restricciones del servicio. Posteriormente, se compararon los resultados obtenidos antes y después de la intervención bajo condiciones similares respecto a los puntos de recolección, vehículos y restricciones operativas. Asimismo, se consideraron factores externos, como cierres de vías, fallas mecánicas, lluvias intensas y variaciones extraordinarias en la generación de residuos. De esta manera, se buscó obtener evidencia inicial sobre la efectividad y viabilidad del sistema híbrido en la planificación de rutas de recolección de residuos sólidos urbanos.

4.6 Técnicas e instrumentos de recolección de datos

La recolección de datos permitió obtener información objetiva sobre la planificación y ejecución de las rutas de recolección de residuos sólidos urbanos antes y después de la aplicación del sistema híbrido de aprendizaje automático y optimización combinatoria. Los registros obtenidos fueron revisados para verificar su legibilidad, consistencia, integridad y completitud. Posteriormente, se organizaron y codificaron mediante categorías y valores numéricos, lo que facilitó su procesamiento estadístico y computacional.

Técnicas de recolección de datos

Observación

La observación fue la principal técnica de recolección de datos, debido a que permitió registrar directamente la ejecución de las rutas de recolección de residuos sólidos urbanos. Se aplicó durante periodos previamente definidos, antes y después de la intervención del sistema híbrido de aprendizaje automático y optimización combinatoria. Mediante una ficha de observación, se recopilaron datos sobre los horarios de salida y llegada, tiempo y distancia del recorrido, puntos atendidos, consumo de combustible, capacidad vehicular utilizada e incidencias presentadas. La

información se registró de manera ordenada y objetiva, evitando apreciaciones personales que pudieran afectar la confiabilidad de los resultados.

Análisis documental o revisión documental

El análisis documental permitió recopilar información secundaria relacionada con el servicio de recolección de residuos sólidos urbanos. Para ello, se revisaron hojas de ruta, reportes de vehículos, registros de combustible, mapas de recorrido, horarios, informes operativos, estadísticas institucionales y bases de datos disponibles. Asimismo, se consultaron libros, tesis, artículos científicos, manuales técnicos y documentos oficiales relacionados con el aprendizaje automático, la optimización combinatoria y la planificación de rutas. Esta información permitió describir el funcionamiento del servicio, identificar las limitaciones de las rutas convencionales y determinar los datos necesarios para desarrollar y evaluar el sistema híbrido.

Instrumentos de recolección de datos

Ficha de observación

La ficha de observación permitió registrar de manera directa, ordenada y uniforme los datos correspondientes a las rutas de recolección de residuos sólidos urbanos. Incluyó información sobre la fecha, código de ruta, vehículo utilizado, zona atendida, horarios de inicio y término, duración, distancia recorrida, consumo de combustible, puntos programados y atendidos, cantidad de residuos recolectados e incidencias presentadas.

Ficha de análisis documental

La ficha de análisis documental permitió registrar y organizar la información relevante de los documentos administrativos, técnicos y operativos revisados. Contuvo datos sobre el documento, periodo, unidad responsable, tipo y frecuencia de ruta, vehículo utilizado, distancia, tiempo, consumo de combustible, costo operativo y nivel de cumplimiento. Esta información facilitó la selección, codificación y procesamiento de los registros necesarios para la investigación.

Matriz de registro de datos

La matriz de registro de datos permitió consolidar la información obtenida mediante la observación y el análisis documental. En ella se organizaron y codificaron los resultados correspondientes a cada ruta, antes y después de la intervención del

sistema híbrido, considerando indicadores como distancia y tiempo total de recorrido, consumo de combustible, costo operativo, puntos atendidos, porcentaje de cumplimiento y cantidad de residuos recolectados.

4.7 Técnicas e instrumentos de análisis y procesamiento de datos

El análisis y procesamiento de datos se realizó a partir de la información recopilada mediante la observación directa y el análisis documental. Los datos registrados en las fichas de observación, las fichas de análisis documental y la matriz de registro fueron revisados, codificados y organizados en una base de datos estructurada para su tratamiento estadístico, computacional y geoespacial.

La información procesada comprendió la fecha de ejecución, código de ruta, vehículo utilizado, zona atendida, horarios de salida y llegada, duración del recorrido, distancia recorrida, consumo de combustible, costo operativo, capacidad vehicular utilizada, puntos programados y atendidos, porcentaje de cumplimiento, cantidad de residuos recolectados e incidencias presentadas.

El procesamiento se desarrolló mediante etapas sucesivas que comprendieron la depuración de datos, el análisis estadístico descriptivo y exploratorio, la preparación de variables, la aplicación de algoritmos de aprendizaje automático, el agrupamiento geográfico, el procesamiento de la red vial, la optimización combinatoria y la comparación de las rutas convencionales con las generadas por el sistema híbrido.

Técnicas de análisis y procesamiento de datos

Revisión, edición y depuración de datos

Inicialmente, se revisaron los registros obtenidos mediante los instrumentos de recolección para verificar su legibilidad, consistencia, integridad y completitud. Se identificaron datos duplicados, valores faltantes, coordenadas incorrectas, diferencias en los horarios, distancias inconsistentes y valores operativos fuera de los rangos esperados.

Los registros con información incompleta fueron contrastados con los documentos institucionales para determinar su validez. Cuando fue posible, se corrigieron las inconsistencias; de lo contrario, los registros fueron excluidos. Asimismo, los valores atípicos se evaluaron considerando posibles incidencias operativas, como

desperfectos mecánicos, congestión vehicular, restricciones de acceso o variaciones extraordinarias en la generación de residuos.

Codificación y organización de los datos

Después de la depuración, los datos fueron codificados y organizados en una matriz digital estructurada. Cada registro representó una ruta, recorrido o punto de recolección, mientras que las columnas correspondieron a las variables e indicadores establecidos en la investigación.

Las variables cualitativas, como zona atendida, tipo de vehículo, turno e incidencias, fueron codificadas para facilitar su procesamiento. Las variables cuantitativas se registraron mediante unidades homogéneas. Asimismo, se calcularon indicadores derivados, como tiempo y distancia total de recorrido, velocidad promedio, consumo de combustible por kilómetro, costo operativo, cantidad de residuos recolectados, porcentaje de utilización de la capacidad vehicular y porcentaje de puntos atendidos.

Análisis estadístico descriptivo

Se empleó la estadística descriptiva para resumir y caracterizar los registros operativos correspondientes a las rutas convencionales y optimizadas. Se calcularon frecuencias, porcentajes, medias, medianas, desviaciones estándar, valores mínimos, máximos y rangos.

Este análisis permitió describir el comportamiento de los principales indicadores operativos, como distancia recorrida, tiempo de operación, consumo de combustible, costo operativo, cobertura del servicio y aprovechamiento de la capacidad vehicular. Los resultados se organizaron mediante tablas descriptivas y comparativas para identificar las diferencias entre ambos procedimientos de planificación.

Análisis exploratorio de datos

El análisis exploratorio permitió identificar tendencias, distribuciones, relaciones y posibles anomalías en los registros operativos. Se examinaron las relaciones entre distancia y tiempo de recorrido, distancia y consumo de combustible, tiempo y costo operativo, cantidad de residuos recolectados y puntos atendidos, así como capacidad vehicular y eficiencia de las rutas.

Asimismo, se analizaron patrones temporales relacionados con fechas, días y turnos de recolección, junto con patrones espaciales correspondientes a las zonas y sectores atendidos. Este procedimiento facilitó la identificación de variables relevantes para el entrenamiento de los modelos predictivos.

Análisis predictivo mediante aprendizaje automático

Se utilizaron los datos históricos y operativos para desarrollar el componente predictivo del sistema híbrido. Las variables de entrada comprendieron información sobre ubicación, fecha, horario, puntos programados, capacidad vehicular y registros históricos de generación de residuos. La variable principal de salida correspondió a la cantidad estimada de residuos sólidos urbanos por punto o sector de recolección.

Se consideró la regresión lineal múltiple como modelo de referencia y se evaluaron algoritmos de aprendizaje automático, como Random Forest Regressor, XGBoost Regressor y LightGBM Regressor, para identificar el modelo con mejor desempeño predictivo.

La base de datos se dividió cronológicamente en conjuntos de entrenamiento, validación y prueba, utilizando proporciones del 70 %, 15 % y 15 %, respectivamente. El rendimiento de los modelos se evaluó mediante el error absoluto medio (MAE), el error cuadrático medio (MSE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2). El modelo seleccionado proporcionó las estimaciones utilizadas posteriormente por el componente de optimización combinatoria.

Agrupamiento de los puntos de recolección

Los puntos de recolección fueron organizados considerando su ubicación geográfica y características operativas. Para ello, se contempló el algoritmo K-means como técnica de agrupamiento, con la finalidad de identificar sectores geográficos según la proximidad entre los puntos.

La cantidad adecuada de agrupaciones se evaluó mediante el método del codo y el coeficiente de silueta. Asimismo, se consideró DBSCAN como técnica alternativa para identificar concentraciones de puntos con distribuciones irregulares y posibles ubicaciones aisladas. Este procedimiento permitió estructurar territorialmente los puntos de recolección y facilitar la planificación de rutas.

Procesamiento geoespacial

La información geográfica obtenida de los registros institucionales, mapas y hojas de ruta fue organizada para representar los puntos de recolección y la red vial. Se construyó una representación mediante grafos, donde los nodos correspondieron a intersecciones y puntos de atención, mientras que las aristas representaron los segmentos de las vías.

El procesamiento geoespacial se realizó mediante herramientas como QGIS, GeoPandas, OSMnx y NetworkX. Asimismo, se contemplaron algoritmos de caminos mínimos, como Dijkstra y A*, para determinar distancias y tiempos de desplazamiento entre los puntos. Esta información permitió construir las matrices utilizadas por el componente de optimización combinatoria.

Optimización combinatoria de las rutas

La optimización de rutas se formuló mediante el problema de enrutamiento de vehículos con restricciones de capacidad y ventanas de tiempo (CVRPTW). El modelo consideró como información de entrada la ubicación de los puntos de recolección, demanda estimada de residuos, capacidad de los vehículos, horarios de operación, distancias y tiempos de desplazamiento.

El procedimiento permitió asignar los puntos de recolección a los vehículos y determinar la secuencia de atención, procurando minimizar la distancia total y el tiempo de operación, sin incumplir las restricciones establecidas.

Para resolver el problema se empleó OR-Tools, considerando estrategias de búsqueda como Guided Local Search. Asimismo, se contempló la técnica 2-opt para mejorar las secuencias de recorrido y reducir desplazamientos innecesarios.

Comparación de las rutas antes y después

Los resultados generados por el sistema híbrido fueron comparados con los registros correspondientes a la planificación convencional. La evaluación comprendió indicadores de distancia total recorrida, tiempo de operación, consumo de combustible, costo operativo, puntos programados y atendidos, porcentaje de cumplimiento, cantidad de residuos recolectados y aprovechamiento de la capacidad vehicular.

Para cada indicador se calculó la variación porcentual entre las mediciones iniciales y finales. Las reducciones en distancia, tiempo, consumo de combustible y costos operativos se interpretaron como mejoras de eficiencia, mientras que los incrementos en cobertura, cumplimiento y aprovechamiento vehicular se consideraron resultados favorables.

Asimismo, se evaluó la normalidad de las diferencias entre mediciones relacionadas. Cuando se cumplió este supuesto, se utilizó la prueba t de Student para muestras relacionadas; en caso contrario, se empleó la prueba de rangos con signo de Wilcoxon. Se estableció un nivel de significancia estadística de $\alpha = .05$.

Representación de los resultados

Los resultados se organizaron mediante tablas descriptivas y comparativas, que permitieron presentar las diferencias entre las rutas convencionales y las optimizadas. Se incluyeron indicadores relacionados con distancia, tiempo de recorrido, consumo de combustible, costo operativo, cobertura del servicio y capacidad vehicular utilizada.

Asimismo, se emplearon representaciones cartográficas para identificar la ubicación de los puntos de recolección, los sectores atendidos y los recorridos propuestos. Estas representaciones facilitaron la evaluación espacial de las rutas generadas mediante el sistema híbrido.

Instrumentos de análisis y procesamiento de datos

Matriz digital de datos procesados

La matriz digital de datos procesados constituyó el principal instrumento para organizar la información recopilada. Contuvo los registros depurados, codificados y transformados correspondientes a cada ruta antes y después de la intervención del sistema híbrido. Asimismo, incorporó las variables originales y los indicadores derivados, como velocidad promedio, costo por kilómetro, consumo de combustible por kilómetro, porcentaje de utilización vehicular y eficiencia de las rutas.

Base de datos geoespacial

La base de datos geoespacial permitió almacenar las coordenadas de los puntos de recolección, las zonas atendidas, los recorridos existentes y la estructura de la red vial. Este instrumento facilitó la integración de los datos operativos con su ubicación

geográfica y proporcionó información para la aplicación de algoritmos de agrupamiento, caminos mínimos y optimización de rutas.

Cuadernos computacionales y scripts de programación

Se utilizaron cuadernos computacionales de Jupyter Notebook y scripts desarrollados en Python para ejecutar los procedimientos de depuración, transformación, análisis estadístico, visualización, entrenamiento de modelos predictivos y optimización de rutas. Estos instrumentos permitieron conservar el código, los parámetros utilizados, los resultados intermedios y las métricas obtenidas, favoreciendo la trazabilidad y reproducibilidad del procesamiento de datos.

Matriz de evaluación de modelos predictivos

La matriz de evaluación de modelos permitió registrar y comparar el desempeño de los algoritmos de regresión lineal múltiple, Random Forest, XGBoost y LightGBM. Incluyó indicadores como el error absoluto medio (MAE), error cuadrático medio (MSE), raíz del error cuadrático medio (RMSE), coeficiente de determinación (R^2) y tiempo de entrenamiento. Este instrumento facilitó la identificación del modelo predictivo con mejor desempeño para su integración con el componente de optimización combinatoria.

Matriz de distancias y tiempos

La matriz de distancias y tiempos permitió organizar los valores mínimos de desplazamiento entre los puntos de recolección, calculados mediante algoritmos como Dijkstra o A*. Esta información se utilizó como entrada para el modelo de enrutamiento de vehículos con restricciones de capacidad y ventanas de tiempo (CVRPTW), facilitando la asignación de los puntos de recolección y la determinación de las secuencias de recorrido.

Matriz comparativa de rutas

La matriz comparativa de rutas permitió contrastar los resultados de la planificación convencional con los obtenidos mediante el sistema híbrido. Se registraron indicadores relacionados con distancia recorrida, tiempo de operación, consumo de combustible, costo operativo, puntos atendidos, cobertura del servicio, cantidad de residuos recolectados y utilización de la capacidad vehicular. Asimismo, se calcularon las diferencias absolutas y variaciones porcentuales de cada indicador, lo que permitió evaluar las mejoras asociadas con la aplicación del sistema híbrido.

Tabla 5

Técnicas, algoritmos e instrumentos de análisis y procesamiento

Componente	Técnica o algoritmo	Finalidad dentro del estudio	Instrumento o herramienta
Control de calidad	Revisión, edición y depuración	Verificar la consistencia, integridad y completitud de los registros recopilados	Matriz digital, Python, Pandas y NumPy
Codificación	Transformación de variables	Convertir los datos observados y documentales en valores procesables	Diccionario de datos y matriz digital
Análisis descriptivo	Estadística descriptiva	Resumir tiempos, distancias, costos, residuos, cobertura y eficiencia	Python, Pandas y NumPy
Análisis exploratorio	Distribuciones, correlaciones y valores atípicos	Identificar patrones temporales, espaciales y operativos	Pandas y Matplotlib
Modelo base	Regresión lineal múltiple	Establecer una referencia para comparar los modelos predictivos	Scikit-learn
Predicción	Random Forest Regressor	Estimar variables operativas considerando relaciones no lineales	Scikit-learn
Predicción	XGBoost Regressor	Predecir tiempos, residuos, consumo o demanda por sector	XGBoost
Predicción	LightGBM Regressor	Evaluar un modelo eficiente de potenciación de árboles	LightGBM
Evaluación predictiva	MAE, MSE, RMSE y R^2	Comparar el desempeño de los modelos predictivos	Matriz de evaluación y Scikit-learn
Agrupamiento	K-means	Agrupar los puntos de recolección en sectores geográficos	Scikit-learn
Agrupamiento alternativo	DBSCAN	Identificar concentraciones irregulares y puntos aislados	Scikit-learn
Procesamiento geoespacial	Construcción de grafos viales	Representar calles, intersecciones y puntos de recolección	Base geoespacial, QGIS, GeoPandas, OSMnx y NetworkX
Caminos mínimos	Dijkstra o A*	Calcular la distancia o tiempo mínimo entre los puntos	Matriz de distancias, NetworkX y OSMnx
Optimización de rutas	CVRPTW	Generar rutas considerando capacidad, horario y cobertura	OR-Tools
Búsqueda de soluciones	Guided Local Search	Explorar alternativas eficientes de ruteo	OR-Tools
Mejoramiento local	2-opt	Reducir cruces y desplazamientos innecesarios	Python u OR-Tools
Comparación antes-después	Variación porcentual y pruebas relacionadas	Determinar la mejora producida por el sistema híbrido	Matriz comparativa, Python y SciPy
Representación	Gráficos y mapas	Visualizar las diferencias entre las rutas tradicionales y optimizadas	Matplotlib y QGIS

4.8 Etapas de intervención del estudio

La intervención del estudio se desarrolló mediante una secuencia ordenada de etapas metodológicas que permitió recopilar, procesar y analizar la información necesaria para desarrollar el sistema híbrido de aprendizaje automático y optimización combinatoria. Estas etapas facilitaron la integración de datos históricos, operativos y geográficos, la predicción de la demanda de residuos, la optimización de las rutas y la comparación de los resultados con la planificación convencional. El procedimiento comprendió el preprocesamiento de datos, la predicción, la representación de la red vial, la optimización combinatoria y la evaluación de las rutas generadas.

Primera etapa: planificación y coordinación. Se definieron el ámbito de intervención, las unidades de análisis, los periodos de observación, los criterios de inclusión y exclusión de los registros y los procedimientos para acceder a la información operativa necesaria para el desarrollo de la investigación.

Segunda etapa: recolección de datos y medición inicial. Se recopilaron datos sobre las rutas convencionales mediante la observación directa y el análisis documental. Se registraron los puntos programados y atendidos, distancias recorridas, tiempos de operación, capacidad vehicular, consumo de combustible, costos operativos, cantidad de residuos recolectados e incidencias presentadas.

Tercera etapa: depuración e integración de los datos. Los registros recopilados fueron revisados para identificar duplicados, valores ausentes, inconsistencias y errores geográficos. Posteriormente, se codificaron e integraron en una base de datos estructurada que permitió relacionar la información operativa con la ubicación geográfica de los puntos de recolección.

Cuarta etapa: análisis exploratorio y preparación de variables. Se analizaron los patrones temporales, espaciales y operativos relacionados con la recolección de residuos sólidos urbanos. Asimismo, se seleccionaron las variables relevantes y se organizaron los registros en conjuntos de entrenamiento, validación y prueba, respetando su secuencia cronológica para evitar la incorporación de información futura durante el entrenamiento.

Quinta etapa: desarrollo del modelo de aprendizaje automático. Se entrenaron y evaluaron diferentes algoritmos predictivos para estimar la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección. El desempeño de los

modelos se comparó mediante las métricas de error absoluto medio (MAE), error cuadrático medio (MSE), raíz del error cuadrático medio (RMSE) y coeficiente de determinación (R^2), lo que permitió seleccionar el modelo con mejor capacidad predictiva.

Sexta etapa: diseño del modelo de optimización combinatoria. Las predicciones obtenidas se incorporaron a un modelo de enrutamiento de vehículos con restricciones de capacidad y ventanas de tiempo (CVRPTW). Se consideraron la capacidad vehicular, los horarios, la cobertura, la demanda estimada y las restricciones operativas. Asimismo, se construyó una matriz de distancias y tiempos de desplazamiento para generar rutas factibles.

Séptima etapa: desarrollo e integración del sistema híbrido. Se integraron los componentes predictivo, geoespacial y de optimización combinatoria, permitiendo utilizar las estimaciones generadas mediante aprendizaje automático para determinar la asignación de vehículos y la secuencia de atención de los puntos de recolección.

Octava etapa: evaluación y comparación de resultados. Se compararon las rutas generadas por el sistema híbrido con las rutas convencionales mediante indicadores de distancia, tiempo de recorrido, consumo de combustible, costo operativo, cobertura, cumplimiento del servicio y aprovechamiento de la capacidad vehicular. Finalmente, se aplicaron las pruebas estadísticas correspondientes, se contrastaron las hipótesis y se organizaron los resultados mediante tablas comparativas y representaciones cartográficas.

CAPÍTULO V. ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

Tabla 6

Cronograma de actividades e hitos de la investigación

Actividad / hito	Semanas	Responsable	Producto verificable
1. Delimitación del problema y revisión bibliográfica.	1–4	Investigadores	Planteamiento del problema y antecedentes.
2. Formulación de objetivos, hipótesis y marco teórico.	5–8	Investigadores	Marco teórico y matriz de consistencia.
3. Elaboración del diseño metodológico e instrumentos.	9–12	Investigadores y asesor	Metodología e instrumentos de recolección.
4. Recopilación de datos y evaluación de rutas convencionales.	13–16	Investigadores	Base de datos inicial y fichas de observación.
5. Depuración, integración y análisis exploratorio de datos.	17–20	Investigadores	Base de datos procesada y validada.
6. Desarrollo y evaluación del modelo de aprendizaje automático.	21–24	Investigadores	Modelo predictivo y métricas MAE, MSE, RMSE y R^2.
7. Desarrollo del modelo de optimización combinatoria e integración del sistema híbrido.	25–26	Investigadores	Sistema híbrido funcional y rutas optimizadas.
8. Comparación de resultados, elaboración y presentación del informe final.	27–28	Investigadores y asesor	Tablas comparativas, resultados e informe final.

Nota. Elaboración propia. El cronograma comprende 28 semanas, equivalentes aproximadamente a siete meses (enero-julio de 2026). Los productos verificables constituyen las evidencias previstas para comprobar el cumplimiento de cada actividad.

5.2 Presupuesto

El presupuesto de la investigación comprendió los recursos materiales, tecnológicos, computacionales y operativos necesarios para desarrollar y evaluar el sistema híbrido de aprendizaje automático y optimización combinatoria para la planificación de rutas de recolección de residuos sólidos urbanos. Se consideraron los costos de adquisición de materiales, servicios de procesamiento, acceso a información geográfica, trabajo de campo y herramientas informáticas, incluyendo los recursos gratuitos y de código abierto.

Tabla 7

Presupuesto estimado de la investigación

Rubro	Cantidad	Costo estimado
Materiales de escritorio	1 paquete	S/ 300.00
Impresión y encuadernación	5 servicios	S/ 600.00
Almacenamiento de información (disco duro externo)	1 unidad	S/ 450.00
Dispositivo de geolocalización	1 unidad	S/ 800.00
Servicio de internet	10 meses	S/ 1,000.00
Servicios de computación en la nube	1 servicio	S/ 1,200.00
Servicios cartográficos y API	1 servicio	S/ 650.00
Movilidad local	20 salidas	S/ 1,200.00
Trabajo de campo	10 jornadas	S/ 700.00
Soporte técnico especializado	1 servicio	S/ 700.00
Difusión y sustentación	1 servicio	S/ 200.00
Gastos imprevistos	1 fondo	S/ 200.00
Licencias de Python, Scikit-learn, XGBoost y OR-Tools (código abierto)	4 herramientas	S/ 0.00
Software QGIS, GeoPandas, OSMnx y NetworkX (código abierto)	4 herramientas	S/ 0.00
Jupyter Notebook y herramientas de desarrollo gratuitas	1 conjunto	S/ 0.00
Datos históricos y operativos municipales (sujetos a autorización)	1 base de datos	S/ 0.00
Instrumentos digitales de observación y registro	3 instrumentos	S/ 0.00
Equipos de cómputo propios de los investigadores	2 equipos	S/ 0.00
Total estimado		**S/ 8,000.00**

Nota. Los costos fueron estimados en soles. Los recursos registrados con costo cero correspondieron a herramientas gratuitas, software de código abierto y equipos propios. El costo cero de los datos municipales se consideró bajo el supuesto de acceso gratuito previa autorización institucional. Los servicios tecnológicos de pago se presupuestaron como recursos complementarios para el procesamiento y análisis.

5.3 Financiamiento

El financiamiento de la investigación se sustentó en recursos propios de los investigadores, con un presupuesto estimado de S/ 8,000.00. Este monto se destinó a cubrir los gastos relacionados con la recolección y georreferenciación de datos, adquisición de materiales, movilidad para el trabajo de campo, procesamiento computacional, servicios tecnológicos, almacenamiento de información y elaboración del informe final. Asimismo, se contempló el aprovechamiento de herramientas informáticas gratuitas y de código abierto, lo que permitió reducir los costos asociados con el desarrollo y evaluación del sistema híbrido.

PARTE II. PROTOCOLO DE INVESTIGACIÓN Y AVANCE EXPERIMENTAL

6. Datos y material de estudio

El estudio abordó información relacionada con las operaciones de recolección de residuos sólidos urbanos de la Municipalidad Distrital de Yarinacocha, provincia de Coronel Portillo, departamento de Ucayali. Para el desarrollo experimental se utilizó una base de datos estructurada que comprendió características temporales, operativas y geográficas de los recorridos de recolección, lo que permitió ejecutar procedimientos de preparación, análisis exploratorio, identificación de patrones y evaluación de modelos predictivos de aprendizaje automático.

El procesamiento se desarrolló mediante el lenguaje de programación Python, utilizando las bibliotecas Pandas y NumPy para la organización y transformación de los registros, Scikit-learn y XGBoost para el entrenamiento de modelos predictivos, y Optuna para la búsqueda y optimización de hiperparámetros. Asimismo, se emplearon procedimientos de validación temporal y mecanismos de registro de experimentos para favorecer la comparabilidad y reproducibilidad de los resultados. Esta etapa se concentró en la predicción de la cantidad de residuos por recorrido, mientras que la integración con el componente de optimización combinatoria quedó prevista para una fase posterior.

6.1 Origen, condiciones de uso y trazabilidad

La investigación consideró como institución de referencia a la Municipalidad Distrital de Yarinacocha, provincia de Coronel Portillo, departamento de Ucayali. De acuerdo con la procedencia institucional declarada por los investigadores, la información correspondió a registros relacionados con las operaciones de recolección de residuos sólidos urbanos del distrito. No obstante, la documentación disponible del experimento no permitió acreditar de manera independiente su obtención directa de la municipalidad, por lo que dicha procedencia quedó pendiente de sustento documental.

La base de datos utilizada se encontró organizada en el archivo denominado residuos_yarinacocha_2026.csv, cuyo contenido comprendió registros fechados entre el 1 de enero y el 31 de diciembre de 2026. La información incluyó características de las rutas de recolección, vehículos asignados, sectores atendidos, horarios, distancias, capacidad vehicular, puntos programados y cantidad de residuos recolectados. Su utilización permitió

desarrollar los procedimientos computacionales orientados a identificar patrones y evaluar la capacidad predictiva de los algoritmos seleccionados.

El conjunto presentó inicialmente 733 registros y 18 variables, identificándose tres observaciones duplicadas que fueron eliminadas durante el procesamiento. Como resultado, se conservaron 730 registros para el desarrollo experimental. Cada observación representó un recorrido de recolección, mientras que la variable objetivo correspondió a la cantidad de residuos recolectados, expresada en kilogramos.

Respecto de las condiciones de uso, los datos se emplearon con fines académicos y de investigación, limitándose su tratamiento al desarrollo de procedimientos de análisis, entrenamiento y evaluación computacional. La documentación revisada no incluyó una licencia específica del conjunto de datos, una autorización institucional de entrega ni la fecha exacta de adquisición del archivo. Por esta razón, tales elementos quedaron pendientes de acreditación. Asimismo, debido a que el conjunto incluía fechas posteriores al momento de elaboración del informe, no fue posible confirmar que la totalidad de sus observaciones correspondiera a operaciones municipales efectivamente realizadas.

La trazabilidad computacional se sustentó en la documentación del código fuente, la definición de una semilla aleatoria fija de 42 y la utilización de particiones cronológicas para entrenamiento, validación y prueba. También se establecieron tres pliegues de validación temporal y se registraron las configuraciones de los experimentos, los hiperparámetros evaluados, los tiempos de ejecución y las métricas obtenidas. Los principales archivos de seguimiento comprendieron search_config.yaml, hpo_runs.csv, comparacion_validacion.csv, config_ganadora.json y metricas_test.csv, generados por las instrucciones del notebook.

La versión del procedimiento experimental se identificó mediante el archivo Sprint_IA07_Individualizado_Ejecutado.ipynb, cuya huella digital SHA-256 correspondió a: fd157c8d0791e0dc2bb36e056aed5b1f28720b2f1241fd1815d5cb95155200a0

La huella digital correspondiente al archivo CSV original quedó pendiente de incorporación, debido a que no se contó con una copia independiente del conjunto de datos para verificarla. Este elemento resulta necesario para identificar inequívocamente la versión utilizada y facilitar la reproducción posterior del experimento.

Entre las principales limitaciones se identificaron la falta de documentación verificable sobre el origen institucional y el procedimiento de generación de los registros, la ausencia de validación con operaciones municipales observadas y la organización de la información por

recorridos, en lugar de puntos individuales de recolección. En consecuencia, la evidencia experimental permitió evaluar el funcionamiento del procedimiento predictivo, pero no fue suficiente para establecer su desempeño operativo real ni demostrar mejoras en la planificación de rutas municipales.

6.2 Estructura, diccionario de datos y análisis exploratorio

El conjunto de datos presentó una estructura tabular conformada inicialmente por 733 observaciones y 18 variables relacionadas con las características temporales, operativas y geográficas del servicio de recolección de residuos sólidos urbanos. Cada fila representó un registro de recorrido, mientras que las columnas describieron aspectos de su programación, ejecución y cantidad de residuos recolectados. Las variables comprendieron datos numéricos continuos y discretos, identificadores categóricos y campos temporales. Debido a que el problema abordado correspondió a una tarea de regresión supervisada, la variable objetivo fue continua y no se establecieron clases de clasificación.

Tabla 8

Diccionario de datos del conjunto utilizado

Variable	Tipo	Descripción y unidad
fecha	Temporal	Fecha del recorrido, expresada en año, mes y día.
codigo_ruta	Categórico	Identificador de la ruta de recolección.
vehiculo	Categórico	Identificador del vehículo asignado.
sector	Categórico	Sector correspondiente al recorrido.
hora_salida	Temporal	Hora de salida del vehículo, en formato HH.
hora_llegada	Temporal	Hora de finalización del recorrido, en formato HH.
duracion_min	Numérico	Duración del recorrido, expresada en minutos.
distancia_km	Numérico	Distancia recorrida, expresada en kilómetros.
combustible_l	Numérico	Combustible consumido, expresado en litros.
costo_operativo_soles	Numérico	Costo operativo del recorrido, expresado en soles.
capacidad_vehicular_kg	Numérico	Capacidad de carga del vehículo, expresada en kilogramos.
residuos_recolectados_kg	Numérico	Cantidad de residuos recolectados, expresada en kilogramos.
puntos_programados	Numérico discreto	Cantidad de puntos previstos para la recolección.
puntos_atendidos	Numérico discreto	Cantidad de puntos efectivamente atendidos.
cumplimiento_pct	Numérico	Porcentaje de cumplimiento del recorrido.
latitud	Numérico	Coordenada geográfica de latitud, en grados decimales.
longitud	Numérico	Coordenada geográfica de longitud, en grados decimales.
incidencia	Categórico	Registro descriptivo de incidencias operativas.

Nota. Elaboración a partir de la estructura de datos documentada en el notebook Sprint IA07

Respecto de la distribución de la variable objetivo, se obtuvo una media de 3 833,59 kg, una mediana de 3 826,04 kg y una desviación estándar de 476,91 kg. Los valores oscilaron entre 2 453,53 kg y 5 352,75 kg, mientras que el primer cuartil alcanzó 3 519,47 kg y el tercer

cuartil registró 4 140,92 kg. La proximidad entre la media y la mediana evidenció una concentración relativamente equilibrada de las observaciones alrededor de sus valores centrales, aunque no permitió establecer por sí sola que los datos siguieran una distribución normal.

Tabla 9

Estadísticos descriptivos de la cantidad de residuos recolectados

Estadístico	Valor (kg)
Número de observaciones	730
Media	3 833,59
Desviación estándar	476,91
Mínimo	2 453,53
Primer cuartil (Q1)	3 519,47
Mediana	3 826,04
Tercer cuartil (Q3)	4 140,92
Máximo	5 352,75

Nota. Estadísticos obtenidos de la salida de describe() de Pandas sobre la variable residuos_recolectados_kg.

El examen gráfico comprendió un histograma de la cantidad recolectada y una representación del promedio mensual de residuos. Estas visualizaciones permitieron identificar la concentración de observaciones alrededor de los valores centrales y diferencias entre los meses considerados. Sin embargo, las variaciones encontradas constituyeron características descriptivas del conjunto disponible y no fueron suficientes para establecer relaciones causales o confirmar patrones estacionales del servicio municipal.

Posteriormente, se desarrolló un procedimiento de ingeniería de atributos que incorporó variables derivadas de la fecha y del horario de salida, incluyendo mes, día de la semana, día del año, identificación de fines de semana y representaciones cíclicas mediante funciones seno y coseno. Asimismo, se calculó la relación entre los puntos programados y la capacidad vehicular expresada en toneladas, permitiendo representar características de la programación operativa.

Como resultado, se seleccionaron 13 atributos predictivos, conformados por tres variables categóricas y diez numéricas. Entre los atributos categóricos se consideraron el código de ruta, el vehículo y el sector, mientras que los atributos numéricos comprendieron la capacidad vehicular, los puntos programados y las variables temporales derivadas. Esta selección respondió al criterio de incorporar exclusivamente información disponible antes del inicio de cada recorrido.

En relación con las anomalías y los riesgos de sesgo, la auditoría identificó duplicados y valores faltantes, mientras que los valores extremos de la variable objetivo fueron descritos mediante sus estadísticos básicos. No obstante, el experimento no documentó una evaluación exhaustiva de valores atípicos mediante reglas estadísticas específicas. Asimismo, se reconoció que la información podía presentar redundancia entre los identificadores de ruta y sector, diferencias de distribución entre períodos y limitaciones de representatividad respecto de las operaciones municipales. Otra limitación fue que la cantidad efectivamente recolectada podía estar condicionada por la capacidad de los vehículos, por lo que no necesariamente representaba la totalidad de la demanda de residuos generada en cada sector.

6.3 Ética, privacidad y seguridad

El tratamiento de los datos se orientó al respeto de los principios de integridad académica, confidencialidad, trazabilidad y utilización responsable de la información. La base empleada en el avance experimental comprendió registros relacionados con las operaciones de recolección de residuos sólidos urbanos y no presentó campos destinados directamente a identificar ciudadanos, tales como nombres, documentos de identidad, domicilios particulares o información de contacto.

Sin embargo, se reconoció que determinados atributos operativos, como los identificadores de vehículos, sectores y coordenadas geográficas, podrían requerir medidas de protección cuando correspondieran a información institucional restringida. En ese sentido, la utilización posterior de registros municipales reales deberá estar respaldada por las autorizaciones correspondientes y respetar las condiciones establecidas por la entidad responsable de su administración, así como la normativa peruana aplicable en materia de protección de datos personales.

El procesamiento experimental se desarrolló mediante herramientas informáticas utilizadas con fines académicos, incluyendo Python, Jupyter Notebook y bibliotecas de aprendizaje automático. Como criterio de seguridad para las etapas posteriores, se estableció la necesidad de restringir el acceso a los archivos originales, conservar versiones de respaldo, separar los datos de trabajo de los materiales de difusión y evitar la publicación de identificadores o información institucional que no cuente con autorización.

Asimismo, se contempló la aplicación de mecanismos de seudonimización cuando los registros permitieran identificar indirectamente a personas vinculadas con las operaciones

municipales. De igual manera, la publicación de los notebooks, configuraciones y resultados experimentales deberá diferenciar el código reproducible de los archivos de información cuyo uso o distribución pudiera encontrarse restringido.

Debido a que el avance experimental no comprendió entrevistas, encuestas ni intervenciones directas sobre personas, no se identificó la necesidad de obtener consentimiento informado individual para los procedimientos computacionales desarrollados. No obstante, cualquier actividad posterior que implique recopilación de datos personales o participación directa de trabajadores municipales deberá considerar los procedimientos éticos y las autorizaciones pertinentes.

Finalmente, se estableció como criterio de integridad científica documentar de manera transparente el origen de los registros, las transformaciones aplicadas, las limitaciones de la información y el alcance efectivo de los resultados. Esta consideración resultó especialmente importante para evitar atribuir al servicio municipal mejoras operativas que todavía no hubieran sido comprobadas mediante una evaluación con datos reales y verificables.

6.4 Preprocesamiento y control de fuga de información

El preprocesamiento se desarrolló mediante procedimientos orientados a garantizar la consistencia de los registros y preservar la independencia entre los conjuntos utilizados para entrenamiento, validación y prueba. Inicialmente, la base de datos fue cargada en Python mediante Pandas, verificándose la disponibilidad de los campos obligatorios fecha y residuos_recolectados_kg. Posteriormente, se efectuó la conversión de la fecha a formato temporal y de la variable objetivo a formato numérico, utilizando mecanismos para identificar valores no interpretables.

Durante la depuración se eliminaron los registros duplicados y se estableció la exclusión de observaciones que carecieran de fecha o de la variable objetivo. Después de este procedimiento, las observaciones fueron ordenadas cronológicamente, conservándose 730 registros para el desarrollo experimental. Esta organización permitió establecer una secuencia temporal coherente con la finalidad predictiva del estudio.

La ingeniería de atributos comprendió la extracción del mes, día de la semana y día del año, así como la identificación de fines de semana. También se transformó la hora de salida a minutos y se generaron variables cíclicas mediante funciones seno y coseno. Adicionalmente, se calculó la relación entre los puntos programados y la capacidad vehicular expresada en toneladas. Estas transformaciones se realizaron a partir de información

disponible antes de cada recorrido, sin utilizar estadísticas calculadas sobre la variable objetivo.

Para prevenir la fuga de información (data leakage), se excluyeron del conjunto de predictores los atributos hora_llegada, duracion_min, distancia_km, combustible_l, costo_operativo_soles, puntos_atendidos, cumplimiento_pct e incidencia, debido a que describían resultados conocidos después de ejecutar el servicio. Su incorporación habría permitido al modelo acceder a información que no estaría disponible al momento de efectuar una predicción anticipada. Asimismo, las coordenadas geográficas no fueron incorporadas como predictores en esta etapa y quedaron reservadas para una posterior integración con el componente territorial.

La separación de los datos se efectuó cronológicamente mediante una distribución aproximada del 70% para entrenamiento, 15% para validación y 15% para prueba. Para ello, se utilizaron fechas únicas, evitando que registros correspondientes a una misma fecha aparecieran simultáneamente en distintos subconjuntos. Esta estrategia permitió mantener la precedencia temporal entre las observaciones empleadas para ajustar los modelos y aquellas destinadas a evaluar su capacidad de generalización.

Tabla 10

Distribución temporal de los registros

Conjunto	Registros	Proporción	Período
Entrenamiento	510	69,86%	01/01/2026 al 12/09/2026
Validación	110	15,07%	13/09/2026 al 06/11/2026
Prueba	110	15,07%	07/11/2026 al 31/12/2026
Total	**730**	**100%**	**01/01/2026 al 31/12/2026**

Nota. Distribución obtenida de la ejecución del notebook IA07 mediante separación cronológica de fechas únicas.

El tratamiento de variables categóricas y numéricas se implementó utilizando las herramientas Pipeline y ColumnTransformer de Scikit-learn. En los atributos categóricos se aplicó SimpleImputer con la estrategia de categoría más frecuente, seguido de OneHotEncoder para convertir las categorías en representaciones numéricas. En los atributos cuantitativos se utilizó imputación mediante la mediana. Estos procedimientos fueron integrados dentro del mismo pipeline utilizado para entrenar los modelos predictivos.

Los parámetros estadísticos necesarios para la imputación y las categorías utilizadas en la codificación se ajustaron exclusivamente con los datos de entrenamiento de cada experimento. Posteriormente, las transformaciones aprendidas se aplicaron a los conjuntos

de validación sin recalcular sus parámetros. De esta manera, se evitó que la información correspondiente a períodos posteriores influyera en la preparación de los registros utilizados para entrenar los modelos.

Adicionalmente, la búsqueda de hiperparámetros se desarrolló mediante tres pliegues temporales utilizando TimeSeriesSplit, exclusivamente dentro del conjunto inicial de entrenamiento. En cada pliegue se ajustó nuevamente el pipeline sobre su respectivo subconjunto de entrenamiento y se evaluó el modelo sobre las observaciones temporalmente posteriores. Este procedimiento permitió comparar las configuraciones de Random Forest y XGBoost mediante las estrategias Random Search y optimización bayesiana TPE, manteniendo constantes las particiones, la semilla aleatoria y la métrica principal de evaluación.

El conjunto independiente de validación se utilizó para comparar las configuraciones obtenidas y seleccionar el modelo con menor error absoluto medio (MAE). Posteriormente, el modelo ganador fue reentrenado utilizando conjuntamente los registros de entrenamiento y validación, mientras que el conjunto de prueba permaneció reservado hasta la evaluación final. De esta manera, los resultados de prueba no intervinieron en la selección de hiper parámetros ni en la elección del algoritmo.

Este procedimiento permitió controlar las principales fuentes de fuga de información temporal, mantener la separación entre las etapas del experimento y favorecer la reproducibilidad de los resultados. No obstante, la estrategia implementada no descartó completamente posibles dependencias entre observaciones, redundancias entre atributos o diferencias de distribución entre períodos. Por consiguiente, la validación posterior deberá incorporar información municipal verificable y controles adicionales de calidad, de manera que las predicciones puedan integrarse con el componente de optimización combinatoria y utilizarse para evaluar la planificación de rutas de recolección.

7. Protocolo experimental

El protocolo experimental se estructuró para evaluar la capacidad predictiva de algoritmos de aprendizaje automático aplicados a la estimación de residuos sólidos urbanos por recorrido en el distrito de Yarinacocha. Se establecieron procedimientos de preparación de datos, entrenamiento, validación temporal, optimización de hiperparámetros y evaluación del desempeño, manteniendo criterios uniformes que permitieron comparar las configuraciones bajo condiciones equivalentes.

La experimentación se desarrolló mediante Random Forest Regressor y XGBoost Regressor, utilizando la búsqueda aleatoria (Random Search) y la optimización bayesiana basada en el estimador de Parzen estructurado por árboles (TPE), implementadas con Optuna. Cada combinación de algoritmo y estrategia de búsqueda se ejecutó individualmente, considerando una semilla aleatoria fija de 42, tres pliegues de validación temporal y el error absoluto medio (MAE) como métrica principal. Asimismo, se registraron la raíz del error cuadrático medio (RMSE), el coeficiente de determinación (R^2) y los tiempos de ejecución, con la finalidad de examinar la precisión, estabilidad y costo computacional de los experimentos.

El procedimiento contempló una separación cronológica de los datos en entrenamiento, validación y prueba, utilizando proporciones aproximadas del 70 %, 15 % y 15 %, respectivamente. La búsqueda de hiperparámetros se restringió al conjunto de entrenamiento, mientras que la selección del modelo se realizó mediante el conjunto independiente de validación. Finalmente, el algoritmo seleccionado fue reentrenado con los registros de entrenamiento y validación para efectuar una evaluación única sobre los datos de prueba. Esta secuencia permitió mantener la independencia temporal de las observaciones y reducir el riesgo de utilizar información futura durante el ajuste de los modelos.

El alcance experimental se limitó a la predicción de la cantidad de residuos recolectados, expresada en kilogramos por recorrido. La utilización de estas estimaciones como entrada del componente de optimización combinatoria y la comparación de rutas convencionales frente a rutas optimizadas correspondieron a una etapa posterior del proyecto.

7.1 Preguntas de evaluación y criterios de éxito

La evaluación experimental se orientó a determinar si la optimización de hiper parámetros mejoraba el desempeño predictivo de Random Forest y XGBoost respecto de sus configuraciones iniciales, así como a identificar qué combinación de algoritmo y estrategia de búsqueda presentaba el menor error de predicción. Para ello, se formularon tres preguntas de evaluación relacionadas con la precisión, la estabilidad y la capacidad de generalización de los modelos.

La primera pregunta examinó en qué medida la búsqueda de hiper parámetros mediante Random Search y optimización bayesiana TPE permitía reducir el error absoluto medio de cada algoritmo respecto de su configuración de referencia. La segunda buscó establecer cuál de las combinaciones evaluadas presentaba el menor MAE sobre el conjunto independiente de validación, considerando también el RMSE, R^2 y el tiempo de ejecución. La tercera examinó si el modelo seleccionado conservaba un desempeño predictivo razonable cuando se evaluaba sobre observaciones temporalmente posteriores que no habían intervenido en el entrenamiento ni en la selección de hiper parámetros.

La métrica principal se definió como el MAE, expresado en kilogramos, debido a que permitió cuantificar la diferencia absoluta promedio entre la cantidad observada de residuos y la cantidad estimada por el modelo. Se estableció como objetivo minimizar este indicador durante la búsqueda y seleccionar, entre las configuraciones evaluadas, aquella que alcanzara el menor MAE en validación independiente.

Como criterio comparativo mínimo, se consideró favorable una variante optimizada cuando su MAE de validación resultara inferior al obtenido por la configuración inicial del mismo algoritmo, manteniendo idénticos datos, atributos y procedimiento de evaluación. En términos relativos, esta condición equivalió a una reducción positiva del error respecto de su referencia. Asimismo, se utilizó el RMSE para examinar la influencia de errores de mayor magnitud y el R^2 para determinar la proporción de variabilidad explicada por las estimaciones.

La estabilidad se examinó mediante el promedio y la desviación estándar del MAE obtenidos en los tres pliegues temporales. Se consideró conveniente que las mejoras no dependieran exclusivamente de un pliegue y que el costo computacional permaneciera dentro del presupuesto de búsqueda establecido. Sin embargo, no se fijó previamente una tolerancia operativa absoluta, expresada en kilogramos, que permitiera calificar el modelo como suficientemente preciso para su implementación municipal. Por consiguiente, los criterios

aplicados permitieron seleccionar la mejor alternativa experimental, pero no demostrar todavía su aptitud operativa para la planificación real de rutas.

7.2 Diseño de particiones y validación

El diseño de validación se estableció considerando la naturaleza temporal de los registros de recolección de residuos sólidos urbanos. Debido a que la predicción buscó estimar cantidades futuras a partir de información disponible previamente, se utilizó una separación cronológica de las observaciones, evitando la distribución aleatoria de los registros entre los conjuntos de entrenamiento, validación y prueba.

Después de la depuración, se conservaron 730 registros, organizados según sus fechas de operación. La partición se realizó sobre fechas únicas, con el propósito de impedir que observaciones correspondientes a una misma fecha fueran incorporadas simultáneamente en subconjuntos diferentes. De esta manera, se destinaron 510 registros al entrenamiento, 110 a la validación y 110 a la prueba, correspondientes aproximadamente al 70%, 15% y 15% del conjunto disponible.

Tabla 11

Diseño de particiones y validación temporal

Conjunto / fold	Criterio de separación	Tamaño / período	Uso permitido
Entrenamiento	Primer bloque cronológico	510 registros, del 01/01/2026 al 12/09/2026	Ajuste inicial de modelos y búsqueda de hiperparámetros.
Validación	Bloque temporal posterior al entrenamiento	110 registros, del 13/09/2026 al 06/11/2026	Comparación de configuraciones y selección del modelo.
Prueba	Último bloque cronológico reservado	110 registros, del 07/11/2026 al 31/12/2026	Evaluación final del modelo seleccionado.
Fold 1	Primera ventana expansiva dentro del entrenamiento	132 registros de ajuste y 126 de validación interna	Primera evaluación temporal del MAE.
Fold 2	Segunda ventana expansiva dentro del entrenamiento	258 registros de ajuste y 126 de validación interna	Segunda evaluación temporal del MAE.
Fold 3	Tercera ventana expansiva dentro del entrenamiento	384 registros de ajuste y 126 de validación interna	Tercera evaluación temporal del MAE.

Nota. La validación cruzada se realizó exclusivamente dentro de los 510 registros iniciales mediante TimeSeriesSplit(n_splits=3). Los tamaños de los subconjuntos se obtuvieron de la ejecución del notebook IA07.

La validación interna se efectuó mediante tres pliegues temporales expansivos, de modo que cada iteración utilizó un período de entrenamiento progresivamente mayor y evaluó el modelo sobre un bloque posterior. Este procedimiento permitió examinar el comportamiento predictivo bajo diferentes ventanas históricas, respetando la secuencia temporal de los registros y evitando incorporar observaciones futuras en el ajuste.

La semilla aleatoria se fijó en 42 para los algoritmos y los métodos de búsqueda. Asimismo, se mantuvieron las mismas particiones, atributos y métrica principal durante los experimentos. Se ejecutó una búsqueda por combinación de algoritmo y método, con 15 pruebas de hiperparámetros en cada caso. No se realizaron repeticiones independientes con semillas adicionales, por lo que la variabilidad examinada correspondió principalmente a los tres pliegues temporales y no a una distribución de resultados obtenida mediante múltiples ejecuciones independientes.

Para prevenir la contaminación entre conjuntos, las transformaciones estadísticas de imputación y codificación se ajustaron únicamente con los datos de entrenamiento correspondientes a cada pliegue. El conjunto independiente de validación no intervino en la función objetivo utilizada por Optuna y el conjunto de prueba permaneció reservado hasta finalizar la selección del modelo. Adicionalmente, se excluyeron los atributos que describían resultados conocidos después de la ejecución del recorrido, evitando que el modelo utilizara información no disponible al momento de efectuar la predicción.

7.3 Métricas y análisis estadístico

La evaluación del desempeño predictivo se realizó mediante indicadores cuantitativos apropiados para problemas de regresión supervisada. Se estableció el error absoluto medio (MAE) como métrica principal, mientras que la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2) se utilizaron como indicadores complementarios. Asimismo, se registraron los tiempos de ejecución, el número de pruebas completadas y las configuraciones de hiper parámetros, permitiendo comparar tanto la calidad predictiva como el costo computacional de las alternativas.

El MAE se calculó como el promedio de las diferencias absolutas entre las cantidades observadas y predichas de residuos, expresadas en kilogramos. Este indicador permitió interpretar directamente la magnitud promedio del error asociado con cada recorrido, por lo que se utilizó como función objetivo de minimización durante la optimización de hiper parámetros.

El RMSE se obtuvo mediante la raíz cuadrada del promedio de los errores elevados al cuadrado. Su incorporación permitió otorgar mayor influencia a las predicciones con desviaciones elevadas y examinar si determinadas configuraciones generaban errores particularmente grandes. Por su parte, el R^2 permitió evaluar la capacidad explicativa del modelo respecto de la variabilidad observada en la cantidad de residuos recolectados, considerando que valores cercanos a uno indicaban un mejor ajuste y que valores iguales o inferiores a cero reflejaban un desempeño equivalente o inferior al de una predicción constante basada en la media del conjunto evaluado.

Durante la búsqueda de hiper parámetros se calculó el MAE de cada uno de los tres pliegues temporales. Posteriormente, los resultados se agregaron mediante la media aritmética, utilizada como función objetivo de Optuna, y la desviación estándar, empleada como indicador descriptivo de variabilidad entre los pliegues. Esta agregación permitió identificar configuraciones con menor error promedio y examinar la consistencia de su comportamiento entre diferentes períodos.

La comparación definitiva se efectuó sobre el conjunto independiente de validación, aplicando las mismas métricas a las configuraciones iniciales y a los modelos optimizados. Se priorizó el menor MAE de validación como criterio de selección, mientras que el RMSE, R^2 y el tiempo computacional permitieron complementar la interpretación de los resultados. Después de seleccionar la configuración ganadora, se realizó una única evaluación sobre el conjunto de prueba, sin utilizar sus métricas para modificar la elección.

La incertidumbre experimental se describió mediante la desviación estándar de los errores registrados en la validación temporal. No se calcularon intervalos de confianza ni se realizaron pruebas de significancia estadística, debido a que el protocolo ejecutado contempló tres pliegues y una única búsqueda por combinación, sin repeticiones independientes suficientes para sustentar inferencias de mayor alcance. En consecuencia, las diferencias entre algoritmos se interpretaron como resultados comparativos del experimento y no como evidencia concluyente de superioridad estadística generalizable.

7.4 Baseline y variantes

La experimentación consideró como referencias iniciales dos configuraciones predictivas, correspondientes a Random Forest Regressor y XGBoost Regressor. Estas configuraciones permitieron establecer un desempeño de partida, frente al cual se evaluaron las mejoras obtenidas mediante búsqueda de hiperparámetros. Para garantizar la comparabilidad, ambos

algoritmos utilizaron los mismos registros de entrenamiento, conjunto de validación, variable objetivo, atributos predictivos y procedimientos de preprocesamiento.

El baseline de Random Forest se configuró con 150 árboles, profundidad máxima de 12 y un mínimo de tres observaciones por hoja. Por su parte, el baseline de XGBoost utilizó 150 estimadores, profundidad máxima de cinco, tasa de aprendizaje de 0,07 y proporciones de muestreo de 0,9 para registros y atributos. Estas configuraciones fueron utilizadas como referencias iniciales antes de ejecutar las estrategias de búsqueda.

Posteriormente, se desarrollaron cuatro variantes experimentales, combinando cada algoritmo predictivo con Random Search y optimización bayesiana TPE. Cada experimento se ejecutó individualmente, modificando la estrategia de búsqueda o el algoritmo, según la comparación correspondiente. Las evaluaciones dentro de un mismo algoritmo permitieron examinar el efecto del método de búsqueda, mientras que las comparaciones entre Random Forest y XGBoost permitieron identificar diferencias asociadas con sus respectivos procedimientos de aprendizaje.

Tabla 12

Modelos de referencia y variantes experimentales

ID	Modelo / configuración	Diferencia frente a baseline	Hipótesis de cambio
B1	Random Forest Baseline	Configuración inicial sin búsqueda de hiperparámetros.	Proporcionar un desempeño de referencia para Random Forest.
B2	XGBoost Baseline	Configuración inicial sin búsqueda de hiperparámetros.	Proporcionar un desempeño de referencia para XGBoost.
V1	Random Forest + Random Search	Optimización aleatoria de cinco hiperparámetros.	Reducir el MAE respecto del baseline de Random Forest.
V2	Random Forest + Bayes TPE	Optimización bayesiana del mismo espacio de hiperparámetros.	Identificar configuraciones de menor error mediante búsqueda adaptativa.
V3	XGBoost + Random Search	Optimización aleatoria de seis hiperparámetros.	Reducir el MAE respecto del baseline de XGBoost.
V4	XGBoost + Bayes TPE	Optimización bayesiana del mismo espacio de hiperparámetros.	Mejorar el desempeño de XGBoost mediante exploración adaptativa.

Nota. Las variantes V1–V4 fueron ejecutadas por separado, manteniendo las mismas particiones temporales, semilla aleatoria, atributos y métrica principal.

La comparación de los modelos permitió establecer que las configuraciones optimizadas presentaron distintos niveles de mejora respecto de sus referencias. En el conjunto independiente de validación, Random Forest obtuvo un MAE inicial de 324,387 kg, mientras que sus variantes mediante Random Search y TPE alcanzaron 317,336 kg y 324,222 kg, respectivamente. En el caso de XGBoost, el baseline registró 364,549 kg y las variantes optimizadas alcanzaron 316,207 kg con Random Search y 316,905 kg con TPE.

De acuerdo con el criterio de minimización del MAE en validación, la mejor configuración correspondió a XGBoost con Random Search, que redujo el error aproximadamente un 13,26% respecto de su baseline. Sin embargo, la configuración Random Forest con TPE presentó el menor MAE promedio durante la validación cruzada interna, con 298,251 kg. Esta diferencia evidenció que el mejor desempeño durante la búsqueda no necesariamente coincidió con el mejor resultado en la validación independiente, justificando la utilización de ambos procedimientos de evaluación.

Como limitación del diseño comparativo, se reconoció que el notebook no incorporó un baseline mínimo basado en la media histórica o una regresión lineal simple. La incorporación de estas referencias quedó considerada para una evaluación posterior, con la finalidad de comprobar si los modelos de mayor complejidad ofrecían ventajas efectivas respecto de procedimientos predictivos elementales.

7.5 Ingeniería de atributos o componentes

La ingeniería de atributos se desarrolló con el propósito de transformar la información temporal y operativa disponible en variables capaces de representar características relevantes de los recorridos de recolección. Este procedimiento se fundamentó en la necesidad de proporcionar a los algoritmos información útil para identificar relaciones con la cantidad de residuos recolectados, evitando incorporar atributos derivados de resultados posteriores al servicio.

Inicialmente, se seleccionaron tres variables categóricas: codigo_ruta, vehiculo y sector, utilizadas para representar la identificación de los recorridos, los vehículos asignados y las áreas de atención. Asimismo, se conservaron dos variables cuantitativas originales: capacidad_vehicular_kg y puntos_programados, relacionadas con la capacidad operativa y la programación del servicio.

A partir del campo fecha, se generaron las variables mes, dia_semana, dia_anio y fin_semana, que permitieron incorporar información sobre la ubicación temporal de cada recorrido. De manera complementaria, la hora de salida fue transformada en hora_salida_min, expresada como el número de minutos transcurridos desde el inicio del día. Posteriormente, se calcularon las variables hora_sin y hora_cos, mediante funciones trigonométricas que permitieron representar el comportamiento cíclico de los horarios.

También se construyó la variable puntos_por_ton_cap, calculada mediante la relación entre los puntos programados y la capacidad vehicular expresada en toneladas. Esta transformación permitió representar la intensidad de atención programada respecto de la capacidad del vehículo, proporcionando una característica operativa adicional para el entrenamiento predictivo.

Como resultado, se conformó un conjunto de 13 atributos, integrado por tres variables categóricas y diez numéricas. Las variables categóricas fueron transformadas mediante codificación One-Hot, mientras que los valores ausentes se trataron utilizando la categoría más frecuente o la mediana, según el tipo de dato. Estas operaciones se integraron en un pipeline de Scikit-learn para asegurar que los parámetros estadísticos fueran estimados exclusivamente con los datos correspondientes a cada entrenamiento.

Durante la selección de atributos se excluyeron variables como duración, distancia recorrida, combustible consumido, costo operativo, puntos atendidos y porcentaje de cumplimiento, debido a que sus valores se conocían después de ejecutar el recorrido. Asimismo, la variable objetivo no se incorporó como predictor, mientras que las coordenadas geográficas quedaron reservadas para su integración posterior con el componente de optimización de rutas.

La experimentación mantuvo constante este conjunto de 13 atributos durante las cuatro búsquedas de hiper parámetros. Por consiguiente, el notebook permitió comparar algoritmos y estrategias de optimización sobre la misma representación de datos, pero no desarrolló una ablación independiente que evaluara el aporte específico de cada atributo. La aplicación posterior de análisis de importancia, selección de variables y pruebas de eliminación progresiva permitirá determinar si determinadas características mejoran consistentemente el desempeño predictivo o introducen redundancias.

7.6 Optimización y presupuesto de búsqueda

La optimización de hiper parámetros se desarrolló utilizando Optuna, mediante dos estrategias independientes: búsqueda aleatoria con RandomSampler y optimización bayesiana con TPESampler. Ambas estrategias se aplicaron por separado a Random Forest y XGBoost, utilizando espacios de búsqueda previamente definidos, la misma semilla aleatoria y tres pliegues de validación temporal.

El espacio de búsqueda de Random Forest comprendió cinco hiper parámetros relacionados con el número de árboles, la profundidad máxima, la cantidad mínima de observaciones necesarias para dividir un nodo, el número mínimo de observaciones por hoja y la proporción

de atributos considerados en cada división. Por su parte, XGBoost contempló seis hiper parámetros asociados con el número de estimadores, la profundidad, la tasa de aprendizaje, el muestreo de registros y atributos, y el peso mínimo requerido en los nodos.

Tabla 13

Espacio de hiper parámetros y presupuesto de búsqueda

Parámetro	Rango / opciones	Estrategia	Presupuesto
RF: n_estimators	80–250, incrementos de 10	Random / TPE	15 trials por método
RF: max_depth	3–16	Random / TPE	Presupuesto conjunto RF
RF: min_samples_split	2–12	Random / TPE	Presupuesto conjunto RF
RF: min_samples_leaf	1–8	Random / TPE	Presupuesto conjunto RF
RF: max_features	sqrt, 0,7 y 1,0	Random / TPE	Presupuesto conjunto RF
XGB: n_estimators	80–280, incrementos de 20	Random / TPE	15 trials por método
XGB: max_depth	2–9	Random / TPE	Presupuesto conjunto XGB
XGB: learning_rate	0,01–0,20, escala logarítmica	Random / TPE	Presupuesto conjunto XGB
XGB: subsample	0,60–1,00	Random / TPE	Presupuesto conjunto XGB
XGB: colsample_bytree	0,60–1,00	Random / TPE	Presupuesto conjunto XGB
XGB: min_child_weight	1–10	Random / TPE	Presupuesto conjunto XGB

Nota. RF = Random Forest; XGB = XGBoost. Los presupuestos indicados correspondieron a 15 pruebas por combinación de algoritmo y estrategia, no a 15 pruebas por cada hiper parámetro.

Se estableció un presupuesto de 15 pruebas de hiper parámetros por combinación, equivalente a 30 pruebas para Random Forest y 30 para XGBoost. En total, se programaron 60 evaluaciones mediante Optuna, utilizando tres pliegues temporales para calcular el MAE promedio de cada configuración. El número efectivo de ajustes dependió de la aplicación del mecanismo de poda, encargado de interrumpir anticipadamente las pruebas que presentaban resultados poco prometedores.

La búsqueda aleatoria seleccionó combinaciones de hiper parámetros mediante un procedimiento de muestreo independiente, mientras que la optimización bayesiana TPE utilizó los resultados de evaluaciones anteriores para orientar la exploración hacia regiones potencialmente favorables del espacio de búsqueda. En esta última estrategia se configuraron cinco pruebas iniciales de exploración antes de aplicar el procedimiento adaptativo.

Asimismo, se empleó MedianPruner, configurado con cinco pruebas iniciales y un paso de calentamiento, para interrumpir configuraciones cuyo desempeño parcial resultara desfavorable. Este mecanismo se aplicó a partir de los valores de MAE reportados durante los pliegues temporales y constituyó una estrategia de ahorro computacional. No correspondió a un procedimiento de parada temprana nativo de XGBoost, sino a una poda de pruebas gestionada por Optuna.

La ejecución de las cuatro combinaciones produjo 60 pruebas, de las cuales 37 finalizaron completamente y 23 fueron interrumpidas mediante poda. Los tiempos registrados para las búsquedas fueron aproximadamente 18,95 segundos para Random Forest con Random Search, 18,04 segundos para Random Forest con TPE, 3,62 segundos para XGBoost con Random Search y 4,13 segundos para XGBoost con TPE. Estos valores correspondieron al entorno específico de ejecución y no constituyeron estimaciones generales de rendimiento computacional.

La selección de hiper parámetros dentro de cada búsqueda se realizó mediante la minimización del MAE promedio de los tres pliegues temporales. Posteriormente, cada configuración seleccionada se entrenó nuevamente con el conjunto inicial de entrenamiento y se evaluó sobre los 110 registros independientes de validación. Finalmente, se eligió la combinación que presentó el menor MAE en dicho conjunto, reservándose los registros de prueba para una evaluación única posterior.

Este procedimiento permitió establecer un presupuesto computacional definido, mantener comparaciones bajo condiciones equivalentes y evitar que la información del conjunto de prueba influyera en la selección del modelo. No obstante, la cantidad de pruebas utilizada representó una exploración limitada de los espacios establecidos, por lo que no permitió asegurar que se hubiera identificado una solución globalmente óptima.

7.7 Reproducibilidad y registro de experimentos

La reproducibilidad del procedimiento experimental se sustentó en la utilización de un notebook estructurado, configuraciones explícitas y mecanismos de almacenamiento de resultados. El desarrollo se realizó en Python, mediante las bibliotecas Pandas, NumPy, Scikit-learn, XGBoost, Optuna, Joblib y PyYAML, empleadas para el procesamiento de datos, entrenamiento de modelos, optimización de hiperparámetros, serialización de artefactos y registro de configuraciones.

La ejecución documentada utilizó Python 3.13.18, Scikit-learn 1.6.1, XGBoost 3.4.1 y Optuna 5.0.0. Estas versiones fueron registradas durante la inicialización del notebook, permitiendo identificar parte del entorno de software utilizado. Sin embargo, no se documentaron de manera completa las versiones de todas las dependencias, las características del procesador, la memoria disponible ni el sistema operativo específico de ejecución, elementos que deberán incorporarse para facilitar la reproducción en entornos distintos.

El experimento se desarrolló mediante el archivo Sprint_IA07_Individualizado_Ejecutado(2).ipynb, cuya versión se identificó utilizando una huella digital SHA-256. La configuración estableció una semilla aleatoria de 42, tres pliegues de validación temporal, 15 pruebas por combinación, MAE como función objetivo y una partición cronológica de los datos en entrenamiento, validación y prueba. Asimismo, se definieron los espacios de búsqueda correspondientes a Random Forest y XGBoost y se conservaron los mismos atributos predictivos durante las comparaciones.

La reproducción del procedimiento contempló la apertura del notebook en un entorno compatible con Jupyter o Google Colab, la instalación de las dependencias y la incorporación del archivo CSV utilizado en el experimento. Posteriormente, las celdas debían ejecutarse de forma secuencial, comenzando con la configuración del entorno y la auditoría de datos, continuando con la generación de atributos y las particiones temporales, y finalizando con la evaluación de los modelos, la optimización de hiper parámetros y la exportación de resultados.

El registro de experimentos se implementó mediante archivos estructurados almacenados en el directorio artifacts/. La configuración general se guardó en search_config.yaml, mientras que los resultados individuales de las pruebas se registraron en archivos CSV asociados con cada combinación de algoritmo y estrategia. Asimismo, se generó hpo_runs.csv para consolidar los resultados de las búsquedas, incluyendo el identificador de prueba, modelo, método, hiper parámetros, semilla, métrica promedio, desviación estándar, pliegues completados, estado de ejecución y tiempo computacional.

La comparación independiente de modelos se conservó en comparacion_validacion.csv, mientras que la configuración seleccionada quedó registrada en config_ganadora.json. Posteriormente, la evaluación sobre el conjunto reservado se almacenó en metricas_test.csv y el modelo final se exportó mediante Joblib como modelo_predictivo.joblib, incluyendo el pipeline de preprocesamiento, los atributos utilizados, la variable objetivo y la semilla aleatoria.

Adicionalmente, se generaron archivos gráficos que permitieron examinar la evolución del MAE durante las búsquedas, comparar las configuraciones en validación y representar las predicciones sobre el conjunto de prueba. Estas salidas complementaron los registros numéricos y facilitaron la revisión del procedimiento experimental desarrollado.

La documentación del experimento contempló su incorporación a un repositorio GitHub, junto con el notebook, las configuraciones, los resultados y las instrucciones de ejecución. No

obstante, en los materiales disponibles para esta revisión no se acreditó una dirección específica del repositorio ni la existencia de un archivo README.md completamente actualizado. Asimismo, la identificación de la versión del CSV mediante su huella digital quedó pendiente de verificación, por no disponer de una copia independiente del archivo original.

En consecuencia, el protocolo permitió documentar las principales decisiones experimentales y conservar evidencia de las configuraciones y resultados obtenidos. Para alcanzar una reproducibilidad completa, será necesario incorporar la versión verificable del conjunto de datos, el registro integral de dependencias, las características del hardware, las instrucciones consolidadas de ejecución y la publicación controlada de los artefactos correspondientes, respetando las condiciones de uso de la información.

8. Resultados parciales y evidencia

Los resultados parciales correspondieron a la etapa experimental de desarrollo y evaluación de modelos de aprendizaje automático destinados a predecir la cantidad de residuos sólidos urbanos recolectados por recorrido en el distrito de Yarinacocha, provincia de Coronel Portillo, departamento de Ucayali. Se estableció como fecha de corte documental el 11 de noviembre de 2026, considerando los procedimientos ejecutados y las evidencias conservadas en el notebook del Sprint IA07. La base analizada comprendió fechas nominales del 1 de enero al 31 de diciembre de 2026, por lo que los registros posteriores al corte no se interpretaron como operaciones históricas municipales comprobadas.

Durante esta etapa se implementaron procedimientos de carga, auditoría, depuración, transformación de datos, ingeniería de atributos, partición temporal, entrenamiento y optimización de hiper parámetros. Se evaluaron los algoritmos Random Forest y XGBoost mediante búsqueda aleatoria y optimización bayesiana TPE, manteniendo condiciones comparables de entrenamiento y validación. La experimentación comprendió 730 registros válidos, distribuidos cronológicamente en entrenamiento, validación y prueba, y permitió ejecutar 60 pruebas de hiper parámetros, de las cuales 37 finalizaron completamente y 23 fueron interrumpidas mediante mecanismos de poda.

Los resultados obtenidos permitieron identificar diferencias en el desempeño predictivo de los algoritmos y las estrategias de búsqueda. La mejor configuración en el conjunto independiente de validación correspondió a XGBoost con Random Search, que alcanzó un error absoluto medio (MAE) de 316,207 kg. Posteriormente, su evaluación sobre el conjunto temporal reservado registró un MAE de 361,647 kg, una raíz del error cuadrático medio (RMSE) de 451,920 kg y un coeficiente de determinación (R^2) de 0,022. Estos resultados constituyeron evidencia del funcionamiento del procedimiento experimental, aunque también mostraron limitaciones en la capacidad explicativa y generalización del modelo.

El avance se concentró exclusivamente en el componente predictivo del sistema híbrido. Por consiguiente, no se presentaron resultados relacionados con reducción de distancias, tiempos de recorrido, consumo de combustible, costos operativos o mejoras de cobertura, debido a que el componente de optimización combinatoria y su evaluación comparativa todavía no habían sido ejecutados.

8.1 Estado de implementación del pipeline

La implementación del pipeline comprendió las principales etapas necesarias para desarrollar un modelo predictivo reproducible. Inicialmente, se efectuó la carga del conjunto de datos mediante Pandas, verificándose su estructura de 733 registros y 18 variables. Durante la auditoría se identificaron tres observaciones duplicadas, cuya eliminación permitió conservar 730 registros válidos. Asimismo, se examinaron los valores faltantes y se verificó la disponibilidad de la variable objetivo, correspondiente a la cantidad de residuos recolectados en kilogramos.

Posteriormente, se desarrolló la ingeniería de atributos mediante la extracción de componentes temporales y la construcción de variables relacionadas con la programación del recorrido. Se seleccionaron 13 atributos predictivos, integrados por tres variables categóricas y diez numéricas. El tratamiento de valores ausentes y la codificación de categorías se implementaron mediante herramientas de Scikit-learn, utilizando un pipeline que permitió ajustar las transformaciones exclusivamente con los datos correspondientes a cada entrenamiento.

La partición temporal se ejecutó sobre fechas únicas, destinando 510 registros al entrenamiento, 110 a la validación y 110 a la prueba. Asimismo, se configuraron tres pliegues temporales mediante TimeSeriesSplit, utilizados exclusivamente dentro del conjunto inicial de entrenamiento. Esta organización permitió mantener la secuencia cronológica de las observaciones y reducir el riesgo de contaminación entre las etapas del experimento.

En la fase de modelado se implementaron dos configuraciones de referencia, correspondientes a Random Forest Regressor y XGBoost Regressor. Posteriormente, se desarrollaron cuatro experimentos independientes mediante las combinaciones Random Forest con Random Search, Random Forest con TPE, XGBoost con Random Search y XGBoost con TPE. Cada combinación contempló 15 pruebas de hiperparámetros, empleando el MAE promedio de los tres pliegues temporales como función objetivo.

La ejecución permitió registrar 60 pruebas, de las cuales 37 finalizaron completamente y 23 fueron podadas por Optuna. Se generaron archivos de seguimiento de hiperparámetros, métricas, configuraciones y tiempos computacionales. Asimismo, se registraron representaciones de la evolución del error durante las búsquedas y una comparación de los resultados obtenidos sobre el conjunto independiente de validación.

Después de comparar las configuraciones, se seleccionó XGBoost con Random Search por presentar el menor MAE de validación. El modelo fue reentrenado con los registros conjuntos de entrenamiento y validación, y posteriormente evaluado sobre el conjunto de prueba, sin utilizar este último para modificar los hiperparámetros. La ejecución registró la generación del modelo serializado y de los archivos correspondientes a las métricas finales.

Entre las evidencias documentadas se encontraron search_config.yaml, hpo_runs.csv, comparacion_validacion.csv, config_ganadora.json, metricas_test.csv y modelo_predictivo.joblib. También se registró la generación de archivos gráficos correspondientes a la evolución de las búsquedas, comparación de modelos y predicciones finales. Estos elementos constituyeron evidencia de la ejecución del componente predictivo, aunque su disponibilidad independiente deberá comprobarse al consolidar el repositorio de entrega.

Las actividades pendientes comprendieron la evaluación individual de la importancia de los atributos, la elaboración de curvas de aprendizaje, el análisis de errores por sectores y períodos, y la validación externa con información operativa verificable. Asimismo, quedó pendiente la integración de las predicciones con la información georreferenciada, las restricciones vehiculares y el componente de optimización combinatoria mediante OR-Tools, necesario para generar y comparar rutas de recolección.

8.2 Comparación cuantitativa del baseline y variantes

La comparación cuantitativa se efectuó mediante el análisis de dos configuraciones iniciales y cuatro variantes optimizadas, utilizando los mismos registros, atributos, particiones temporales y métricas de evaluación. Los modelos de referencia permitieron establecer el desempeño inicial de Random Forest y XGBoost, mientras que las variantes buscaron identificar configuraciones de menor error mediante Random Search y optimización bayesiana TPE.

Durante la optimización se calculó el MAE de cada pliegue temporal y se utilizó su promedio como criterio de búsqueda. Asimismo, se registró la desviación estándar del error entre pliegues, lo que permitió examinar la variabilidad temporal de las configuraciones. Los resultados individuales de cada pliegue no quedaron exportados en las tablas finales del notebook; por ello, se presentan los promedios y desviaciones efectivamente registrados, sin reconstruir valores que no se encuentran documentados.

Tabla 14

Comparación experimental y estabilidad de los modelos

Experimento	Métrica por fold / réplica	Media ± DE del MAE en CV (kg)	Tiempo / coste	Decisión
RF Baseline	Validación independiente; sin CV registrada	No disponible	Ajuste: 0,561 s	Referencia inicial
XGB Baseline	Validación independiente; sin CV registrada	No disponible	Ajuste: 0,193 s	Referencia inicial
RF + Random	Tres pliegues temporales; valores individuales no exportados	300,754 ± 15,868	Búsqueda: 18,95 s	Conservar como variante
RF + TPE	Tres pliegues temporales; valores individuales no exportados	298,251 ± 15,033	Búsqueda: 18,04 s	Mejor MAE de CV
XGB + Random	Tres pliegues temporales; valores individuales no exportados	301,387 ± 14,563	Búsqueda: 3,62 s	Seleccionar por validación
XGB + TPE	Tres pliegues temporales; valores individuales no exportados	300,844 ± 12,250	Búsqueda: 4,13 s	Conservar como alternativa

Nota. RF = Random Forest; XGB = XGBoost; CV = validación cruzada temporal; DE = desviación estándar. Las medias y desviaciones correspondieron a la mejor prueba completa de cada búsqueda. Los tiempos de búsqueda comprendieron las pruebas completas y podadas. El costo monetario de cómputo no fue registrado.

La Tabla anterior evidenció que Random Forest con TPE alcanzó el menor MAE promedio durante la validación cruzada temporal, con 298,251 ± 15,033 kg. Sin embargo, este resultado no determinó automáticamente su selección como modelo definitivo, debido a que el protocolo estableció una evaluación adicional sobre un conjunto independiente de validación. En cuanto al costo computacional, las búsquedas de Random Forest requirieron tiempos superiores a los registrados por XGBoost. El tiempo conjunto de las cuatro búsquedas fue aproximadamente de 44,74 segundos, bajo las condiciones específicas del entorno utilizado. No obstante, estos valores no incluyeron toda la preparación de datos ni reflejaron la latencia de inferencia en producción.

Tabla 15

Resultados comparativos en el conjunto independiente de validación

Modelo	Método	MAE (kg)	RMSE (kg)	R^2
Random Forest	Baseline	324,387	410,076	0,191
Random Forest	Random Search	317,336	399,301	0,233
Random Forest	TPE	324,222	410,488	0,190
XGBoost	Baseline	364,549	444,666	0,049
XGBoost	Random Search	316,207	405,249	0,210
XGBoost	TPE	316,905	399,963	0,231

Nota. Las métricas fueron obtenidas sobre los mismos 110 registros de validación. El criterio principal de selección correspondió al menor MAE.

Los resultados mostraron que Random Forest con Random Search redujo el MAE de 324,387 kg a 317,336 kg, equivalente a una mejora relativa del 2,17 %. En cambio, Random Forest con TPE alcanzó 324,222 kg, representando una reducción de apenas 0,05 % respecto de su baseline. Aunque esta última configuración obtuvo el menor MAE durante la validación cruzada interna, su desempeño independiente resultó inferior al de Random Forest con Random Search.

En XGBoost, la configuración inicial registró un MAE de 364,549 kg, mientras que Random Search redujo el error a 316,207 kg, equivalente a una mejora relativa del 13,26 %. La optimización TPE alcanzó un MAE de 316,905 kg, que representó una reducción del 13,07 % frente al baseline. Ambos métodos mejoraron el error absoluto medio inicial, aunque Random Search presentó una ligera ventaja en la métrica principal.

Debe señalarse que la configuración XGBoost con TPE obtuvo un RMSE de 399,963 kg y un R^2 de 0,231, resultados superiores a los de XGBoost con Random Search en esas métricas secundarias. Asimismo, Random Forest con Random Search alcanzó el menor RMSE de todas las variantes, con 399,301 kg, y el mayor R^2, con 0,233. Estas diferencias evidenciaron que la selección del modelo dependió del indicador priorizado y que ninguna configuración presentó superioridad simultánea en todas las métricas.

Finalmente, la selección correspondió a XGBoost con Random Search por presentar el menor MAE de validación, conforme al criterio establecido en el protocolo experimental. El modelo fue reentrenado con 620 registros de entrenamiento y validación, y posteriormente evaluado sobre 110 registros reservados, obteniéndose un MAE de 361,647 kg, un RMSE de 451,920 kg y un R^2 de 0,022. Estos resultados mostraron un deterioro respecto del desempeño observado durante la validación, por lo que la configuración seleccionada no pudo considerarse suficientemente validada para su utilización operativa.

8.3 Ablaciones y análisis de sensibilidad

El análisis de componentes se realizó mediante comparaciones controladas entre configuraciones iniciales y variantes optimizadas, manteniendo constantes los atributos predictivos, las particiones temporales y la métrica principal. Estas comparaciones permitieron examinar los cambios asociados con la aplicación de procedimientos de búsqueda de hiperparámetros y con la utilización de diferentes estrategias de optimización.

No obstante, el experimento no incorporó ablaciones estrictas de atributos, debido a que las cuatro búsquedas emplearon el mismo conjunto de 13 variables predictivas. Tampoco se modificó un único hiperparámetro por experimento, pues cada búsqueda evaluó combinaciones de varios parámetros. Por consiguiente, las diferencias registradas permitieron evaluar el efecto conjunto de las configuraciones, pero no atribuir causalmente las mejoras a un atributo o hiperparámetro específico.

Tabla 16

Comparaciones controladas y cambios de desempeño

Componente cambiado	Control	Resultado	Interpretación
Optimización aleatoria de Random Forest	RF Baseline: MAE 324,387 kg	RF Random: 317,336 kg; mejora del 2,17 %	La configuración optimizada redujo moderadamente el error.
Optimización TPE de Random Forest	RF Baseline: MAE 324,387 kg	RF TPE: 324,222 kg; mejora del 0,05 %	La mejora fue mínima y no justificó su selección.
Optimización aleatoria de XGBoost	XGB Baseline: MAE 364,549 kg	XGB Random: 316,207 kg; mejora del 13,26 %	Presentó la mayor reducción relativa del MAE.
Optimización TPE de XGBoost	XGB Baseline: MAE 364,549 kg	XGB TPE: 316,905 kg; mejora del 13,07 %	Mejoró considerablemente el baseline, pero no superó a Random Search en MAE.
Estrategia TPE frente a Random en RF	RF Random: MAE 317,336 kg	RF TPE: 324,222 kg; aumento de 6,886 kg	TPE no produjo la mejor generalización en validación.
Estrategia TPE frente a Random en XGB	XGB Random: MAE 316,207 kg	XGB TPE: 316,905 kg; aumento de 0,698 kg	La diferencia entre estrategias fue reducida.

Nota. Las comparaciones se efectuaron sobre el conjunto independiente de validación. Los porcentajes representan cambios relativos respecto de cada baseline. No constituyen pruebas de ablación individual de atributos o hiper parámetros.

Los resultados evidenciaron que la optimización de hiperparámetros produjo mejoras diferentes según el algoritmo utilizado. Random Forest presentó una reducción moderada del MAE mediante búsqueda aleatoria y una mejora prácticamente nula mediante TPE. Por su parte, XGBoost mostró reducciones superiores al 13% con ambas estrategias, lo que indicó una mayor sensibilidad de su desempeño frente a las configuraciones de hiperparámetros evaluadas.

Asimismo, la comparación entre los métodos de búsqueda mostró que TPE no garantizó mejores resultados en validación independiente, pese a obtener errores promedio favorables durante la validación cruzada interna. Esta diferencia se observó principalmente en Random Forest, donde TPE alcanzó el menor MAE de los pliegues temporales, pero presentó un error de validación superior al obtenido mediante búsqueda aleatoria.

En cuanto a la sensibilidad individual de los hiper parámetros, el experimento no permitió determinar qué cambios específicos en profundidad, número de estimadores, tasa de aprendizaje o condiciones de muestreo fueron responsables de las variaciones observadas. Tampoco se evaluó la contribución independiente de los atributos temporales y operativos mediante eliminación progresiva de variables.

En consecuencia, los resultados permitieron identificar configuraciones predictivas favorables, pero no establecer todavía relaciones causales entre cada componente del modelo y su desempeño. Para la siguiente etapa se consideró necesario incorporar pruebas de ablación con conjuntos de atributos diferenciados, análisis de importancia mediante permutación o SHAP y evaluaciones de sensibilidad con modificaciones individuales de hiper parámetros, conservando las mismas particiones y condiciones experimentales.

8.4 Sobreajuste, errores y robustez

La evaluación del sobreajuste se abordó mediante la comparación de los resultados de validación cruzada temporal, validación independiente y prueba final. Este procedimiento permitió examinar cambios en el desempeño predictivo cuando los modelos fueron evaluados sobre períodos posteriores a los utilizados durante su entrenamiento. Sin embargo, el notebook no registró métricas equivalentes de entrenamiento para todas las configuraciones, por lo que no fue posible calcular directamente la brecha entre los errores de entrenamiento y validación ni determinar mediante ella la magnitud del sobreajuste.

La variabilidad del desempeño se examinó mediante la desviación estándar del MAE correspondiente a los tres pliegues temporales de cada configuración seleccionada. Los valores oscilaron entre 12,250 kg para XGBoost con TPE y 15,868 kg para Random Forest con Random Search. Estas diferencias permitieron describir la dispersión de los errores entre períodos, aunque el reducido número de pliegues no permitió establecer conclusiones definitivas sobre la estabilidad del modelo frente a distintos conjuntos de datos.

En el conjunto independiente de validación, XGBoost con Random Search obtuvo un MAE de 316,207 kg, un RMSE de 405,249 kg y un R^2 de 0,210. Posteriormente, la evaluación única sobre el conjunto reservado de prueba registró un MAE de 361,647 kg, un RMSE de 451,920 kg y un R^2 de 0,022. La diferencia absoluta del MAE fue de 45,440 kg, equivalente a un incremento relativo del 14,37 % respecto del error registrado durante la validación.

Este deterioro evidenció una reducción de la capacidad predictiva del modelo frente al conjunto temporal reservado. Asimismo, el R^2 de 0,022 indicó que el modelo explicó aproximadamente el 2,2% de la variabilidad observada en la variable objetivo del conjunto de prueba. Por consiguiente, aunque la configuración seleccionada produjo mejoras respecto de su baseline, su capacidad explicativa final fue limitada y no permitió afirmar que el modelo hubiera alcanzado un desempeño suficiente para la predicción operativa de la demanda de residuos.

El incremento del error entre validación y prueba pudo relacionarse con diferencias en la distribución temporal de los registros, limitaciones en la representación de los atributos o una adaptación insuficiente del modelo a nuevas observaciones. Sin embargo, estas posibles explicaciones no fueron comprobadas individualmente. Además, la brecha observada entre validación y prueba no constituyó por sí sola evidencia concluyente de sobreajuste, debido a que este diagnóstico también requería examinar los errores de entrenamiento y las curvas de aprendizaje.

Respecto de los casos de fallo, el notebook registró una representación de las cantidades observadas frente a las predichas en el conjunto de prueba, pero no conservó un análisis tabular individual de los residuos de predicción ni una clasificación de los recorridos con mayores errores. Tampoco se desarrolló una evaluación segmentada por sector, ruta, vehículo, mes o capacidad vehicular. En consecuencia, no fue posible determinar si los errores se concentraron en determinados tipos de recorrido o condiciones operativas.

En cuanto a la robustez computacional, la experimentación mantuvo una semilla fija y las mismas particiones temporales, permitiendo reproducir las comparaciones bajo condiciones equivalentes. La utilización de Optuna permitió completar 37 pruebas e interrumpir 23 mediante mecanismos de poda, lo que evidenció el funcionamiento del control de presupuesto de búsqueda. No obstante, las pruebas podadas no representaron fallas de ejecución, sino interrupciones anticipadas de configuraciones que no cumplieron los criterios internos del optimizador.

Finalmente, no se elaboraron curvas de aprendizaje que relacionaran el desempeño con diferentes tamaños de entrenamiento ni se desarrollaron pruebas de perturbación de datos, variaciones de semilla o validación externa. Por consiguiente, el avance proporcionó evidencia inicial del comportamiento predictivo, pero la evaluación integral del sobreajuste y la robustez quedó pendiente para una etapa experimental posterior.

8.5 Interpretación y amenazas a la validez

Los resultados parciales evidenciaron que el procedimiento implementado permitió entrenar, optimizar y comparar modelos de aprendizaje automático destinados a estimar la cantidad de residuos sólidos urbanos recolectados por recorrido. La experimentación mostró mejoras en el MAE de determinadas configuraciones respecto de sus modelos iniciales, especialmente en XGBoost mediante Random Search. Sin embargo, la evaluación final registró un deterioro del desempeño y una capacidad explicativa limitada, lo que hizo necesario interpretar los resultados como una validación inicial del procedimiento computacional y no como una solución predictiva suficientemente comprobada para su aplicación municipal.

Una primera amenaza a la validez interna estuvo relacionada con la selección de atributos y la posible dependencia entre observaciones. Aunque se utilizaron particiones cronológicas y se excluyeron variables conocidas después del recorrido, los registros podían compartir características de rutas, vehículos y sectores que generaran relaciones repetitivas. Asimismo, el protocolo no incluyó pruebas específicas para determinar si los identificadores utilizados incorporaban información redundante o relaciones que limitaran la generalización hacia nuevas condiciones operativas.

Otra limitación correspondió al proceso de selección de modelos. Aunque se utilizó un conjunto independiente de validación y se reservó la prueba final, la elección del mejor algoritmo se realizó mediante una única partición temporal. Por consiguiente, el modelo seleccionado pudo favorecer las condiciones particulares de dicho período. La ausencia de repeticiones con diferentes semillas y de evaluaciones temporales adicionales también limitó la estimación de incertidumbre y la posibilidad de comprobar la estabilidad de las diferencias observadas.

En relación con la validez estadística, el conjunto comprendió 730 registros, de los cuales 110 fueron destinados a la prueba final. Este tamaño permitió desarrollar una evaluación inicial, pero no aseguró una representación suficiente de todas las condiciones operativas del servicio, especialmente cuando se consideraron variaciones entre rutas, sectores, vehículos y períodos. Asimismo, la utilización de tres pliegues temporales permitió calcular promedios y desviaciones estándar, pero no proporcionó evidencia suficiente para formular afirmaciones concluyentes sobre superioridad estadística entre algoritmos.

Respecto de la validez externa, una limitación importante estuvo relacionada con la procedencia y representatividad de los registros. La documentación del notebook no acreditó una extracción verificable de los sistemas municipales y consignó un origen de datos que

requiere conciliación con la procedencia institucional declarada en el informe. Adicionalmente, el período representado incluyó fechas posteriores al corte documental, por lo que la información no pudo considerarse íntegramente como un registro histórico municipal observado. Estas condiciones limitaron la posibilidad de extrapolar los resultados al funcionamiento real del servicio de recolección de Yarinacocha.

También se identificó una limitación relacionada con la variable objetivo. El modelo fue entrenado para predecir la cantidad efectivamente recolectada por recorrido, la cual podía estar influida por la capacidad de los vehículos y las condiciones de ejecución del servicio. Por consiguiente, esta cantidad no necesariamente representaba la totalidad de residuos generados o pendientes de atención en cada punto de recolección. Esta diferencia conceptual deberá resolverse antes de integrar las predicciones con un algoritmo de optimización de rutas, cuya formulación requiere estimaciones de demanda por punto o sector.

En cuanto a la interpretabilidad, el procedimiento permitió comparar el desempeño global de Random Forest y XGBoost, pero no incorporó análisis de importancia de variables, valores SHAP ni pruebas de ablación que permitieran explicar individualmente la contribución de los atributos. Por ello, no fue posible establecer qué características temporales u operativas determinaron las predicciones ni identificar con suficiente precisión las causas de los errores registrados.

La reproducibilidad constituyó una fortaleza del avance, debido a que se documentaron las configuraciones de búsqueda, la semilla aleatoria, las particiones temporales, las métricas y los archivos generados. Sin embargo, permanecieron pendientes la verificación de la huella digital del conjunto de datos, la documentación completa del entorno computacional, el acceso comprobable al repositorio y la conservación independiente de todas las salidas experimentales. Estos elementos deberán completarse para garantizar que terceros puedan repetir el procedimiento y obtener resultados comparables.

Finalmente, los resultados obtenidos no permitieron evaluar todavía el efecto del sistema híbrido sobre la planificación de rutas de recolección, debido a que el componente de optimización combinatoria no había sido implementado ni validado. En consecuencia, no se formularon conclusiones sobre reducción de distancias, tiempos, combustible o costos operativos.

9. Conclusiones del avance y próximos pasos

Los avances obtenidos permitieron establecer el estado de desarrollo del componente predictivo del sistema híbrido de aprendizaje automático y optimización combinatoria para la planificación de rutas de recolección de residuos sólidos urbanos. La experimentación proporcionó evidencias sobre la implementación del procesamiento de datos, el entrenamiento de modelos, la optimización de hiper parámetros y la evaluación temporal de las predicciones. Sin embargo, también se identificaron limitaciones relacionadas con la capacidad de generalización, la procedencia verificable de los datos y la integración pendiente del componente de optimización de rutas. En consecuencia, se formularon conclusiones sustentadas en los resultados disponibles y se establecieron acciones de mejora para continuar el desarrollo experimental.

9.1 Conclusiones sustentadas por evidencia

En relación con el objetivo general, orientado a determinar en qué medida el desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará la planificación de las rutas de recolección de residuos sólidos urbanos, se concluyó que el avance experimental permitió implementar y evaluar el componente predictivo mediante procedimientos de preparación de datos, entrenamiento, validación temporal y optimización de hiperparámetros. Sin embargo, todavía no fue posible determinar el efecto del sistema híbrido sobre la planificación de rutas, debido a que el componente de optimización combinatoria y su evaluación operativa permanecieron pendientes.

Respecto al primer objetivo específico, relacionado con la identificación de patrones de generación de residuos sólidos urbanos mediante datos históricos, operativos y geográficos, se concluyó que el análisis exploratorio de 730 registros permitió reconocer características de la distribución de residuos recolectados, con una media de 3 833,59 kg y una desviación estándar de 476,91 kg, así como variaciones descriptivas entre los períodos analizados. No obstante, estos resultados se limitaron a las características temporales y operativas del conjunto disponible, sin establecer todavía patrones geográficos verificables ni relaciones concluyentes sobre la generación real de residuos en los puntos o sectores de recolección.

En cuanto al segundo objetivo específico, dirigido a evaluar la capacidad predictiva de un modelo de aprendizaje automático para estimar la cantidad de residuos sólidos urbanos, se concluyó que XGBoost optimizado mediante Random Search presentó el menor error absoluto medio en validación independiente, con 316,207 kg, equivalente a una reducción

del 13,26% respecto de su configuración inicial. Sin embargo, la evaluación final registró un MAE de 361,647 kg, un RMSE de 451,920 kg y un R^2 de 0,022, evidenciando una capacidad explicativa limitada y la necesidad de fortalecer el modelo antes de considerar su aplicación operativa.

Respecto al tercer objetivo específico, orientado al diseño de un modelo de optimización combinatoria para generar rutas factibles considerando la demanda estimada, capacidad vehicular, restricciones horarias, cobertura y condiciones operativas, se concluyó que el avance permitió desarrollar una base computacional inicial para estimar la cantidad de residuos recolectados por recorrido. No obstante, todavía no se implementó el algoritmo de optimización combinatoria ni se comprobaron las restricciones necesarias para generar rutas factibles, por lo que el cumplimiento de este objetivo permaneció pendiente para las siguientes etapas experimentales.

Finalmente, en relación con el cuarto objetivo específico, destinado a comparar las rutas generadas por el sistema híbrido con las rutas convencionales, se concluyó que aún no existieron resultados experimentales suficientes para establecer diferencias respecto de la distancia y el tiempo de recorrido, el consumo de combustible, el costo operativo, la cobertura del servicio, el cumplimiento de las rutas y el aprovechamiento de la capacidad vehicular. Por consiguiente, la evaluación de estos indicadores quedó condicionada a la implementación del componente combinatorio y a la disponibilidad de información operativa verificable que permita desarrollar comparaciones bajo condiciones equivalentes.

9.2 Riesgos y plan de mitigación

El avance experimental permitió identificar riesgos técnicos, científicos, relacionados con los datos, éticos y operativos que podrían afectar la confiabilidad de los resultados y el desarrollo del sistema híbrido de aprendizaje automático y optimización combinatoria. La evaluación se fundamentó en las limitaciones observadas durante el procesamiento de los registros, la validación temporal de los modelos y la comparación de las estrategias de optimización de hiper parámetros. Se priorizaron aquellos riesgos que comprometían la validez de las predicciones, la reproducibilidad de los experimentos y la posterior generación de rutas factibles para el servicio de recolección de residuos sólidos urbanos.

Entre los principales riesgos se identificaron la procedencia y representatividad de los datos, el deterioro del desempeño predictivo en el conjunto de prueba, la posible dependencia entre observaciones y la falta de información geográfica suficiente para implementar el

componente combinatorio. Asimismo, se reconocieron limitaciones relacionadas con la interpretación de los modelos, la documentación del entorno computacional y la protección de información institucional. En consecuencia, se establecieron medidas de mitigación orientadas a fortalecer la calidad de los datos, mejorar la evaluación de los algoritmos y preparar las condiciones necesarias para continuar el desarrollo del sistema propuesto.

Tabla 17

Riesgos identificados y plan de mitigación del proyecto

Riesgo	Impacto	Mitigación	Evidencia / responsable
Procedencia y representatividad insuficientemente documentadas de los datos.	**Alto.** Limita la validez externa y confiabilidad de los resultados.	Verificar la procedencia institucional, documentar autorizaciones y fechas, y registrar la versión y huella digital de la base.	Constancia de procedencia, inventario de datos y SHA-256. Ambos investigadores.
Capacidad predictiva limitada y deterioro del desempeño en prueba.	**Alto.** Afecta la precisión de las estimaciones de residuos.	Incorporar modelos de referencia, revisar atributos, analizar errores y aplicar validaciones temporales adicionales.	Tabla comparativa de MAE, RMSE y R^2, curvas de aprendizaje e informe de errores. Equipo de modelado.
Diferencia entre residuos recolectados y demanda real por punto o sector.	**Alto.** Puede afectar la asignación de carga y la planificación de rutas.	Precisar la variable objetivo e incorporar información de demanda por punto o sector, verificando su relación con la capacidad vehicular.	Diccionario de datos actualizado y reporte de consistencia. Ambos investigadores.
Fuga de información y dependencia temporal entre registros.	**Alto.** Puede generar resultados artificialmente favorables.	Mantener particiones cronológicas, ajustar transformaciones exclusivamente con entrenamiento y verificar los predictores disponibles antes del recorrido.	Pruebas del pipeline, configuraciones y reporte de validación temporal. Equipo de modelado.
Información geográfica y restricciones operativas incompletas.	**Alto.** Limita la generación de rutas factibles mediante optimización combinatoria.	Verificar coordenadas, red vial, capacidades vehiculares, horarios y matrices de distancia y tiempo.	Base georreferenciada y matriz de restricciones. Equipo de optimización.
Ausencia de ablaciones, interpretabilidad y pruebas adicionales de robustez.	**Medio.** Limita la explicación de los resultados y la selección de atributos.	Aplicar importancia por permutación o SHAP, eliminar atributos de forma controlada y evaluar errores por segmentos.	Matriz de ablaciones e informe de importancia de variables. Equipo de modelado.
Reproducibilidad incompleta de los experimentos.	**Medio.** Dificulta verificar las métricas en diferentes entornos.	Documentar versiones, dependencias, hardware, semillas, configuraciones, instrucciones y registros de ejecución.	Repositorio, README, archivos de configuración y registros automáticos. Ambos investigadores.
Uso o divulgación no autorizada de información institucional.	**Alto.** Puede comprometer la confidencialidad y el cumplimiento ético.	Gestionar autorizaciones, restringir accesos y aplicar seudonimización cuando corresponda.	Autorizaciones institucionales y registro de controles de acceso. Ambos investigadores.

Nota. Los riesgos fueron priorizados según su efecto potencial sobre la validez científica, el desempeño predictivo y la implementación operativa. Las medidas de mitigación corresponden a acciones propuestas cuyo cumplimiento deberá sustentarse mediante evidencias verificables.

El plan de mitigación priorizó la verificación de los datos y el fortalecimiento del componente predictivo, debido a que ambas condiciones resultaron fundamentales para continuar el desarrollo experimental. Posteriormente, se consideró necesario incorporar información geográfica y restricciones operativas que permitieran implementar el modelo de optimización combinatoria. Estas acciones buscarán reducir las limitaciones identificadas, mejorar la confiabilidad de los resultados y establecer condiciones adecuadas para evaluar el sistema híbrido frente a las rutas convencionales.

9.3 Trabajo futuro para el siguiente sprint

El siguiente sprint estará orientado al fortalecimiento del componente predictivo y al desarrollo inicial del modelo de optimización combinatoria, considerando los resultados obtenidos y las limitaciones identificadas durante el avance experimental. Las actividades previstas se organizarán en función de los objetivos específicos de la investigación, priorizando la verificación de la información, el análisis de patrones, la mejora de la evaluación predictiva y la preparación de los datos necesarios para generar rutas de recolección factibles.

Inicialmente, se revisará la procedencia y consistencia de los registros, incluyendo sus características temporales, operativas y geográficas. Posteriormente, se incorporarán modelos predictivos de referencia y se desarrollarán pruebas de importancia de atributos, curvas de aprendizaje y análisis de errores por segmentos. De manera complementaria, se preparará la información georreferenciada y se formularán las restricciones de capacidad, horarios y cobertura necesarias para implementar un prototipo de optimización combinatoria mediante OR-Tools.

El trabajo se organizará mediante entregables verificables, criterios de aceptación previamente definidos y fechas de cumplimiento. La distribución de responsabilidades entre Grimaldo René Abarca Urbano y Jorge Raúl Valega Marquina se presenta como una propuesta de coordinación, sujeta a la conformidad de ambos investigadores.

Tabla 18

Plan de trabajo propuesto para el siguiente sprint

Actividad	Entregable	Criterio de aceptación	Fecha
Verificar procedencia y trazabilidad de los datos. **Responsables: ambos investigadores.**	Informe de procedencia y registro de versiones.	Fuente y condiciones de uso documentadas; identificación de registros verificables y cálculo SHA-256.	13/11/2026
Actualizar el análisis exploratorio e identificar patrones. **Responsable propuesto: Jorge Raúl Valega Marquina.**	Notebook EDA y reporte de calidad de datos.	Auditoría de valores faltantes, duplicados, distribuciones, anomalías y diferencias temporales y operativas.	16/11/2026
Incorporar modelos predictivos de referencia. **Responsable propuesto: Jorge Raúl Valega Marquina.**	Notebook comparativo de modelos.	Evaluación de media histórica y regresión lineal mediante MAE, RMSE y R^2, con particiones equivalentes.	18/11/2026
Evaluar importancia de atributos, sobreajuste y robustez. **Responsables: ambos investigadores.**	Matriz de ablaciones, curvas de aprendizaje e informe de errores.	Comparación controlada de conjuntos de atributos, métricas de entrenamiento y validación, y análisis segmentado.	20/11/2026
Preparar información geográfica y restricciones operativas. **Responsable propuesto: Grimaldo René Abarca Urbano.**	Base georreferenciada y matrices de distancias y tiempos.	Coordenadas verificadas, unidades consistentes y restricciones de capacidad, horarios y cobertura documentadas.	24/11/2026
Implementar prototipo de optimización combinatoria. **Responsable propuesto: Grimaldo René Abarca Urbano.**	Notebook OR-Tools y reporte de factibilidad.	Generación de rutas sobre un escenario documentado, con verificación de restricciones y registro de resultados.	26/11/2026
Consolidar experimentos y documentación reproducible. **Responsables: ambos investigadores.**	Repositorio, archivos de configuración, registros e informe de sprint.	Ejecución verificable, dependencias documentadas, conservación de artefactos y registro de actividades pendientes.	27/11/2026

Nota. Las fechas corresponden a una programación propuesta para noviembre de 2026 y deberán ajustarse al calendario oficial del curso. La implementación del componente combinatorio dependerá de la disponibilidad de información operativa y geográfica suficiente.

Los criterios de aceptación se formularon considerando la obtención de productos verificables y no únicamente la mejora de las métricas predictivas. Por ello, los nuevos experimentos deberán registrar resultados favorables y desfavorables, manteniendo la trazabilidad de las configuraciones y la independencia de los conjuntos utilizados para su evaluación. En caso de modificar los modelos después de haber examinado el conjunto de prueba del Sprint IA07, será necesario disponer de nuevas observaciones independientes para realizar una evaluación final sin contaminación.

Al culminar el siguiente sprint, se espera contar con una evaluación predictiva más completa, información geográfica organizada y un prototipo inicial de optimización combinatoria, siempre que se disponga de datos suficientes para formular las restricciones operativas. Estos productos permitirán avanzar en el cumplimiento de los objetivos específicos relacionados con la predicción de residuos y el diseño de rutas factibles, preparando las condiciones necesarias para comparar posteriormente el desempeño del sistema híbrido frente a las rutas convencionales de la Municipalidad Distrital de Yarinacocha.

REFERENCIAS

Ali, B., Javed, M. A., Alharbi, A. A. K., Alotaibi, S., & Alkhathami, M. (2024). Internet of Things-assisted vehicle route optimization for municipal solid waste collection. *Applied Sciences, 14*(1), 287. https://doi.org/10.3390/app14010287

Alsabt, R., Alkhaldi, W., Adenle, Y. A., & Alshuwaikhat, H. M. (2024). Optimizing waste management strategies through artificial intelligence and machine learning—An economic and environmental impact study. *Cleaner Waste Systems, 8*, 100158. https://doi.org/10.1016/j.clwas.2024.100158

Alzate Montoya, P. M., Bustamante Gutiérrez, L. C., & Alzate Álvarez, A. M. (2024). Un modelo de rutas para la recolección de residuos sólidos domiciliarios: un caso de estudio. *Revista de Métodos Cuantitativos para la Economía y la Empresa, 37*, 1–14. https://doi.org/10.46661/rev.metodoscuant.econ.empresa.7820

Anton Bernal, J. M., Bravo Ruíz, J. A., Arcila Díaz, J. C., & Tuesta Monteza, V. A. (2021). Planificador de rutas para recojo de desechos sólidos utilizando el algoritmo de Dijkstra. *Ingeniería: Ciencia, Tecnología e Innovación, 8*(2), 92–99. https://doi.org/10.26495/icti.v8i2.1918

Arista-López, D. R. (2025). Application of artificial intelligence for optimizing solid waste management in rural municipalities: A systematic review. *Revista Científica de Sistemas e Informática, 5*(2), e960. https://doi.org/10.51252/rcsi.v5i2.960

Bai, R., Chen, X., Chen, Z.-L., Cui, T., Gong, S., He, W., Jiang, X., Jin, H., Jin, J., Kendall, G., Li, J., Lu, Z., Ren, J., Weng, P., Xue, N., & Zhang, H. (2023). Analytics and machine learning in vehicle routing research. *International Journal of Production Research, 61*(1), 4–30. https://doi.org/10.1080/00207543.2021.2013566

Benitez-Bravo, R., Gomez-González, R., Rivas-García, P., Botello-Álvarez, J. E., Huerta-Guevara, O. F., García-León, A. M., & Rueda-Avellaneda, J. F. (2021). Optimization of municipal solid waste collection routes in a Latin-American context. *Journal of the Air & Waste Management Association, 71*(11), 1415–1427. https://doi.org/10.1080/10962247.2021.1957040

Castro Fuentes, E. M. (2024). Gestión de residuos sólidos: estudio de casos y lecciones aprendidas en ciudades intermedias aplicables en el contexto latinoamericano y Perú. *Ciencia Latina Revista Científica Multidisciplinar, 8*(4), 7066–7084. https://doi.org/10.37811/cl_rcm.v8i4.12883

Centro Nacional de Planeamiento Estratégico. (2024). *Informe sobre la gestión estratégica del Estado 2024*. https://www.gob.pe/institucion/ceplan/informes-publicaciones/6339665-informe-sobre-la-gestion-estrategica-del-estado-2024

Cerna Cueva, A. F., Rosas Echevarría, C. W., Perales Flores, R. S., & Ataucusi Flores, P. L. (2022). Predicción de la generación de residuos sólidos domiciliarios con machine learning en una zona rural de Puno. *Tecnia, 32*(1), 44–52. https://doi.org/10.21754/tecnia.v32i1.1378

Chacaltana Lara, N. S., Flores Ledesma, K. N., Choque Mandamiento, Á. S., Villegas Gómez, S., Guardamino Quiroz, M. E., & Canez Palomino, R. W. (2024). Gestión integrada de residuos sólidos urbanos a través de la economía circular. *Revista de Climatología, 24*, 273–278. https://doi.org/10.59427/rcli/2024/v24cs.273-278

Fang, B., Yu, J., Chen, Z., Osman, A. I., Farghali, M., Ihara, I., Hamza, E. H., Rooney, D. W., & Yap, P.-S. (2023). Artificial intelligence for waste management in smart cities: A review. *Environmental Chemistry Letters, 21*(4), 1959–1989. https://doi.org/10.1007/s10311-023-01604-3

Goswami, A., Poornima, N. V., Prabu, P., & Saudagar, A. K. J. (2026). Route optimization in urban waste management using locally adjusted discrete cuckoo search: A hybrid metaheuristic approach. *Scientific Reports, 16*, 10097. https://doi.org/10.1038/s41598-026-40208-z

Granda Cruz, L. E., & Agurto Marchena, F. J. (2024). Artificial intelligence-powered solid waste detection system. En *Proceedings of the 4th LACCEI International Multiconference on Entrepreneurship, Innovation and Regional Development (LEIRD 2024)*. Latin American and Caribbean Consortium of Engineering Institutions. https://doi.org/10.18687/LEIRD2024.1.1.669

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). *Metodología de la investigación* (6.ª ed.). McGraw-Hill Education.

Hu, Y., Ju, Q., Peng, T., Zhang, S., & Wang, X. (2024). Municipal solid waste collection and transportation routing optimization based on IAC-SFLA. *Journal of Environmental Engineering and Landscape Management, 32*(1), 31–44. https://doi.org/10.3846/jeelm.2024.20774

Jaime Piñas, J. A., & Cotrina Cabello, G. G. (2021). Gestión integral de residuos sólidos como herramienta para la optimización del servicio de limpieza pública. *Ciencia Latina Revista Científica Multidisciplinar, 5*(3), 3275–3295. https://doi.org/10.37811/cl_rcm.v5i3.531

Jerbi, H., Gnana Vincy, V. G. A., Ben Aoun, S., Abbassi, R., & Kchaou, M. (2026). Optimizing waste management in smart cities: An IoT-based approach using dynamic bald eagle search optimization algorithm (DBESO) and machine learning. *Journal of Urban Management, 15*(1), 114–130. https://doi.org/10.1016/j.jum.2025.05.015

Julca Flores, J. D. (2025). Análisis comparativo de algoritmos de machine learning para la predicción de la generación de residuos sólidos en la playa Venecia de la ciudad de Lima. *Biotech & Engineering, 5*(2), 107–128. https://doi.org/10.52248/eb.Vol5Iss02.216

Kaza, S., Yao, L. C., Bhada-Tata, P., & Van Woerden, F. (2018). *What a waste 2.0: A global snapshot of solid waste management to 2050*. World Bank. https://doi.org/10.1596/978-1-4648-1329-0

Liang, Y.-C., Minanda, V., & Gunawan, A. (2022). Waste collection routing problem: A mini-review of recent heuristic approaches and applications. *Waste Management & Research, 40*(5), 519–537. https://doi.org/10.1177/0734242X211003975

Lopez, M., Villagra, A., & Pandolfi, D. (2023). Optimización de rutas en la recolección de residuos tecnológicos. *Informes Científicos Técnicos - UNPA, 14*(3). https://doi.org/10.22305/ict-unpa.v14.n3.897

Municipalidad Distrital de Yarinacocha. (2024). *Resolución de Gerencia Municipal N.° 191-2024-MDY-GM*. Plataforma Digital Única del Estado Peruano. https://www.gob.pe/institucion/muniyarinacocha/normas-legales/5462751-191-2024-mdy-gm

Municipalidad Distrital de Yarinacocha. (2025). *Resolución de Gerencia Municipal N.° 148-2025-MDY-GM*. Plataforma Digital Única del Estado Peruano. https://www.gob.pe/institucion/muniyarinacocha/normas-legales/6604160-148-2025-mdy-gm

Najar Marín, E. (2024). Manejo de residuos sólidos en zonas urbanas en América Latina. *Revista Científica Visión de Futuro, 28*(2), 78–97. https://doi.org/10.36995/j.visiondefuturo.2024.28.02.003.es

Niu, Y., Xu, C., Liao, S., Zhang, S., & Xiao, J. (2024). Multi-objective location-routing optimization based on machine learning for green municipal waste management. *Waste Management, 181*, 157–167. https://doi.org/10.1016/j.wasman.2024.04.001

Ochoa-Barragán, R., Munguía-López, A. D. C., & Ponce-Ortega, J. M. (2023). A hybrid machine learning-mathematical programming optimization approach for municipal solid waste

management during the pandemic. *Environment, Development and Sustainability, 26*(7), 17653–17672. https://doi.org/10.1007/s10668-023-03354-2

Ogbolumani, O. A., & Adekoya, M. (2025). Intelligent waste management optimization through machine learning analytics. *Journal of Science Research and Reviews, 2*(1), 7–26. https://doi.org/10.70882/josrar.2025.v2i1.25

Priyanka, E. B., Vijayashanthy, S., Thangavel, S., Anand, R., Bhavana, G. B., Khan, B., Jeyanthi, K., & Ambikapathy, A. (2025). Prediction of waste generation forecast and emission potential on the Erode City solid waste dump yards based on machine learning approach. *Scientific Reports, 15*, 37021. https://doi.org/10.1038/s41598-025-19288-w

Programa de las Naciones Unidas para el Medio Ambiente. (2024). *Perspectiva mundial de la gestión de residuos 2024*. https://www.unep.org/es/publications/report/perspectiva-mundial-de-la-gestion-de-residuos-2024

Quispe Huayta, E. C. N., Sarmiento Quispe, E. E., & Calli Vilca, L. W. (2024). Eficiencia en la gestión de residuos sólidos urbanos en los municipios distritales de la macrorregión sur del Perú. *Semestre Económico, 13*(1), 116–132. https://doi.org/10.26867/se.2024.v13i1.165

Ramos, J., Luque, A., Larios, D., & Barbancho, J. (2019). *Machine learning para la optimización inteligente de la recogida de residuos*. https://hdl.handle.net/11441/88837

Rihm, A., Piamonte, C., Restrepo Lagos, E. A., Correal, M., Guerra Morán, P. G., & Basani, M. (2024). *Transformación digital de la gestión de residuos sólidos* (C. M. Pasquetti, Ed.). Banco Interamericano de Desarrollo. https://doi.org/10.18235/0013169

Ruiz Huaraz, C. B., & Valenzuela Ramos, M. R. (2022). *Metodología de la investigación* (1.ª ed.). Fondo Editorial de la Universidad Nacional Autónoma de Tayacaja Daniel Hernández Morillo. https://doi.org/10.56224/EdiUnat.4

Sánchez Yáñez, J. M., & Márquez Benavides, L. (2024). Gestión de residuos sólidos y la inteligencia artificial en el contexto mexicano. *Ciencia Nicolaita*, (90). https://doi.org/10.35830/cn.vi90.722

Silva, A., Ribeiro, T., Lima, J., Fernandes, F. P., Silva, A. M. T., Gomes, H. T., & Pereira, A. I. (2025). Hybrid fleet optimization for waste collection: Addressing urban constraints using OR-Tools. *SN Computer Science, 6*, 482. https://doi.org/10.1007/s42979-025-04018-w

Sopla Mas, J. (2023). Aplicación Web SIG para gestionar el sistema de recolección de residuos sólidos urbanos en la ciudad de Chachapoyas, Amazonas, Perú 2022. *Revista Científica Pakamuros, 10*(4). https://doi.org/10.37787/m4f63d45

Xia, W., Jiang, Y., Chen, X., & Zhao, R. (2022). Application of machine learning algorithms in municipal solid waste management: A mini review. *Waste Management & Research, 40*(6), 609–624. https://doi.org/10.1177/0734242X211033716

Zhao, Y., Tao, Z., Li, Y., Sun, H., Tang, J., Wang, Q., Guo, L., Song, W., & Li, B. L. (2024). Prediction of municipal solid waste generation and analysis of dominant variables in rapidly developing cities based on machine learning—A case study of China. *Waste Management & Research, 42*(6), 476–484. https://doi.org/10.1177/0734242X231192766

ANEXOS

Anexo A. Matriz de consistencia

TÍTULO: SISTEMA HÍBRIDO DE APRENDIZAJE AUTOMÁTICO Y OPTIMIZACIÓN COMBINATORIA PARA LA PLANIFICACIÓN DE RUTAS DE RECOLECCIÓN DE RESIDUOS SÓLIDOS URBANOS.							
Problema del Estudio	**Problemas**	**Objetivos**	**Hipótesis**	**Variables y dimensiones**	**Dimensiones**	**Indicadores**	**Diseño Metodológico**
La planificación de las rutas de recolección de residuos sólidos urbanos presenta limitaciones para aprovechar adecuadamente la información histórica, operativa y geográfica disponible. Esto puede generar recorridos extensos, mayores tiempos de operación, elevado consumo de combustible, costos innecesarios y dificultades en la cobertura del servicio. Ante esta situación, se requiere desarrollar un sistema híbrido de aprendizaje automático y optimización combinatoria que permita predecir la generación de residuos y diseñar rutas más eficientes, considerando las restricciones operativas del servicio.	**Problema general** ▪ ¿En qué medida el desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará la planificación de las rutas de recolección de residuos sólidos urbanos?	**Objetivo general** ▪ Determinar en qué medida el desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará la planificación de las rutas de recolección de residuos sólidos urbanos.	**Hipótesis general** ▪ El desarrollo de un sistema híbrido de aprendizaje automático y optimización combinatoria mejorará significativamente la planificación de las rutas de recolección de residuos sólidos urbanos.	VI: Sistema híbrido de aprendizaje automático y optimización combinatoria	D1: Preparación e integración de datos	Porcentaje de registros válidos. Porcentaje de completitud de los datos. Porcentaje de puntos correctamente georreferenciados. Disponibilidad de la matriz de distancias y tiempos.	**Tipo:** Aplicada. **Nivel:** Explicativo. **Métodos:** Experimental. **Diseño:** Preexperimental. **Población:** Conformada por los registros operativos de recolección de residuos sólidos urbanos, considerando cada recorrido o jornada como unidad de análisis. **Muestra:** será censal e incluirá todos los registros operativos válidos, cuyo tamaño final (n) se determinará después de la depuración de datos. **Técnicas e instrumentos de recolección de datos:** Se emplearán la observación y el análisis documental, utilizando fichas y una matriz de registro para recopilar información de las rutas antes y después de implementar el sistema híbrido. **Técnicas e instrumentos de análisis y procesamiento de datos:** Se aplicarán técnicas de procesamiento y análisis de datos, aprendizaje automático, análisis geoespacial y optimización combinatoria, utilizando matrices digitales, bases geoespaciales y scripts desarrollados en Python.
	Problemas específicos ▪ ¿Qué patrones de generación de residuos sólidos urbanos se identifican mediante el análisis de los datos históricos, operativos y geográficos de los puntos o sectores de recolección? ▪ ¿En qué medida un modelo de aprendizaje automático permite predecir la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección? ▪ ¿Cómo diseñar un modelo de optimización combinatoria que permita generar rutas de recolección factibles, considerando la demanda estimada, la capacidad vehicular, las restricciones horarias, la cobertura y las condiciones operativas del servicio? ▪ ¿Qué diferencias existen entre las rutas generadas por el sistema híbrido y las rutas convencionales respecto a la distancia y el tiempo de recorrido, el consumo de combustible, el costo operativo, la cobertura del servicio, el cumplimiento de las rutas y el aprovechamiento de la capacidad vehicular?	**Objetivos específicos** ▪ Identificar los patrones de generación de residuos sólidos urbanos mediante el análisis de los datos históricos, operativos y geográficos de los puntos o sectores de recolección. ▪ Evaluar la capacidad predictiva de un modelo de aprendizaje automático para estimar la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección. ▪ Diseñar un modelo de optimización combinatoria para generar rutas de recolección factibles, considerando la demanda estimada, la capacidad vehicular, las restricciones horarias, la cobertura y las condiciones operativas del servicio. ▪ Comparar las rutas generadas por el sistema híbrido con las rutas convencionales, considerando la distancia y el tiempo de recorrido, el consumo de combustible, el costo operativo, la cobertura del servicio, el cumplimiento de las rutas y el aprovechamiento de la capacidad vehicular.	**Hipótesis específicas** ▪ Los patrones de generación de residuos sólidos urbanos presentan variaciones identificables mediante el análisis de los datos históricos, operativos y geográficos de los puntos o sectores de recolección. ▪ El modelo de aprendizaje automático presenta una capacidad predictiva adecuada para estimar con precisión la cantidad de residuos sólidos urbanos en los puntos o sectores de recolección. ▪ El modelo de optimización combinatoria permitirá generar rutas de recolección factibles, cumpliendo las restricciones de demanda estimada, capacidad vehicular, horarios, cobertura y condiciones operativas del servicio. ▪ Las rutas generadas por el sistema híbrido serán significativamente más eficientes que las rutas convencionales, al reducir la distancia y el tiempo de recorrido, el consumo de combustible y el costo operativo, y mejorar la cobertura, el cumplimiento del servicio y el aprovechamiento de la capacidad vehicular.		D2: Desempeño predictivo del aprendizaje automático.	Error absoluto medio — MAE. Error cuadrático medio — MSE. Raíz del error cuadrático medio — RMSE. Coeficiente de determinación — R^2. Tiempo de entrenamiento del modelo. Tiempo de generación de las predicciones.	
					D3: Optimización combinatoria de rutas.	Porcentaje de rutas factibles generadas. Cumplimiento de la capacidad vehicular. Cumplimiento de las ventanas de tiempo. Cobertura de puntos incorporados en las rutas. Número de restricciones operativas incumplidas. Tiempo computacional de optimización.	
				VD: Planificación de rutas de recolección de residuos sólidos urbanos	D1: Eficiencia del recorrido.	Distancia total recorrida. Tiempo total de recorrido. Velocidad promedio. Porcentaje de reducción de la distancia. Porcentaje de reducción del tiempo.	
					D2: Eficiencia económica y energética.	Consumo total de combustible. Consumo de combustible por kilómetro. Costo operativo total. Costo operativo por kilómetro. Porcentaje de reducción del consumo de combustible. Porcentaje de reducción del costo operativo.	
					D3: Cobertura y cumplimiento del servicio.	Número de puntos programados. Número de puntos atendidos. Porcentaje de puntos atendidos. Porcentaje de cumplimiento de la ruta. Número de puntos o sectores no atendidos.	
					D4: Productividad y aprovechamiento vehicular.	Cantidad total de residuos recolectados. Cantidad de residuos recolectados por punto. Cantidad de residuos recolectados por kilómetro. Porcentaje de utilización de la capacidad vehicular. Número de puntos atendidos por vehículo.	

Autores: Jorge Valega y René Abarca.

Anexo B. Cronograma detallado

El cronograma comprende el período de julio de 2026 a marzo de 2027, conforme a la duración prevista en el plan de tesis. Las fechas y asignaciones son propuestas de gestión y no deben confundirse con evidencia de actividades efectivamente ejecutadas. El notebook IA07 documenta un avance predictivo; la integración combinatoria continúa pendiente.

Período	Actividad	Entregable / criterio verificable	Responsable propuesto	Estado
Jul. 2026	Formulación del problema, variables y objetivos	Plan de tesis y matriz de consistencia	Ambos investigadores	Planificado; verificar evidencia
Ago. 2026	Revisión de fuentes y definición de datos	Marco teórico; solicitud formal de registros	Ambos investigadores	Planificado; verificar evidencia
Sep. 2026	Ingesta, calidad y exploración de datos	Diccionario; auditoría; documentación de origen	Equipo de datos	Documentación retrospectiva pendiente
Oct. 2026	Ingeniería de atributos y modelos de referencia	Notebook EDA; partición y baseline	Equipo de modelado	Documentación retrospectiva pendiente
06–11 nov. 2026	Consolidación Sprint IA07	Notebook con 4 búsquedas, 60 trials y test temporal	Ambos investigadores	Evidenciado por salidas guardadas
12–13 nov. 2026	Verificación de procedencia y licencias	Constancia de origen, fecha, versión y SHA-256 del CSV	Ambos investigadores	Programado
14–16 nov. 2026	Auditoría temporal y representatividad	Base corregida; informe de calidad y sesgos	Jorge Raúl Valega Marquina (propuesto)	Programado
17–18 nov. 2026	Baselines simples de referencia	Comparativa media histórica / regresión lineal	Jorge Raúl Valega Marquina (propuesto)	Programado
19–23 nov. 2026	Ablaciones, errores y robustez	MAE/RMSE/R^2 por segmento y curva de aprendizaje	Ambos investigadores	Programado
24–25 nov. 2026	Modelo territorial y restricciones	Puntos, rutas, capacidades, ventanas y matrices	Grimaldo René Abarca Urbano (propuesto)	Programado
26–27 nov. 2026	Prototipo combinatorio y registro	OR-Tools, factibilidad y artefactos reproducibles	Ambos investigadores	Programado; condicionado a datos
Dic. 2026	Integración y pruebas por escenarios	Predicción→demanda por punto→optimizador	Ambos investigadores	Programado
Ene. 2027	Comparación de rutas	Distancia, tiempo, cobertura y restricciones	Ambos investigadores	Programado; sin resultados actuales
Feb. 2027	Validación externa y análisis estadístico	Evaluación en períodos/datos independientes	Ambos investigadores	Programado
Mar. 2027	Redacción, anexos y sustentación	Tesis y repositorio reproducible final	Ambos investigadores	Programado

Nota. Los productos se aceptarán cuando el archivo y su evidencia de ejecución puedan localizarse; el cumplimiento futuro no se presume. Las fechas de noviembre están sujetas al cronograma oficial de la UNI.

Anexo C. Diccionario de datos

La unidad original es el recorrido de recolección. La tabla describe los 18 campos importados del CSV y las ocho variables derivadas por el notebook. La predicción se realizó sobre residuos_recolectados_kg (kg/recorrido), no sobre la demanda individual por punto. El dataset original no se adjuntó a esta revisión.

Campo original	Tipo	Unidad / formato	Uso en IA07	Faltantes
fecha	Fecha	AAAA-MM-DD	Orden y separación temporal	0
codigo_ruta	Texto/categoría	Identificador	Predictor (codificado)	0
vehiculo	Texto/categoría	Identificador	Predictor (codificado)	0
sector	Texto/categoría	Categoría territorial	Predictor (codificado)	0
hora_salida	Hora	HH:MM	Fuente de atributos horarios	0
hora_llegada	Hora	HH:MM	Excluido: posterior al servicio	0
duracion_min	Número	min	Excluido: resultado operativo	0
distancia_km	Número	km	Excluido: resultado operativo	0
combustible_l	Número	litros	Excluido: resultado operativo	6
costo_operativo_soles	Número	S/	Excluido: resultado operativo	4
capacidad_vehicular_kg	Número	kg	Predictor	0
residuos_recolectados_kg	Número	kg	Variable objetivo (y)	0
puntos_programados	Entero	puntos	Predictor	0
puntos_atendidos	Entero	puntos	Excluido: posterior al servicio	0
cumplimiento_pct	Número	%	Excluido: posterior al servicio	0
latitud	Número	grados decimales	Reservado: componente geográfico	3
longitud	Número	grados decimales	Reservado: componente geográfico	3
incidencia	Categoría	Descripción	Excluido: posterior al servicio	0

Nota. La auditoría conservó 730 observaciones después de retirar tres duplicados de un total de 733. No se registraron faltantes en fecha ni en la variable objetivo.

C.1 Variables derivadas

Atributo derivado	Rango / unidad	Regla de construcción	Uso
mes	1–12	Mes de fecha	Predictor
dia_semana	0–6	Día semanal de fecha	Predictor
dia_anio	1–366	Día del año desde fecha	Predictor
fin_semana	0/1	1 cuando dia_semana >= 5	Predictor
hora_salida_min	0–1439 min	60×hora + minuto	Predictor
hora_sin	–1 a 1	sen(2π×hora_salida_min/1440)	Predictor
hora_cos	–1 a 1	cos(2π×hora_salida_min/1440)	Predictor
puntos_por_ton_cap	puntos/tonelada	puntos_programados / (capacidad_vehicular_kg / 1000)	Predictor

El conjunto final incluyó 13 predictores: tres categóricos y diez numéricos (dos numéricos originales y ocho derivados). El pipeline aplicó imputación de moda y One-Hot a las categorías, e imputación de mediana a las variables numéricas. Las estimaciones se ajustaron únicamente con los registros de entrenamiento de cada pliegue.

Anexo D. Configuraciones y tabla completa de corridas

Se documentaron cuatro experimentos independientes: Random Forest y XGBoost, cada uno con RandomSampler y TPESampler. Se utilizaron 15 trials por experimento, tres folds temporales, semilla 42, MAE como objetivo de minimización y poda mediante MedianPruner (cinco trials iniciales; un paso de calentamiento). Los resultados mostrados son los guardados en el notebook, no una ejecución nueva.

Modelo	Buscador	Trials	Completados	Podados	Tiempo total (s)
RF	Aleatorio	15	7	8	18.95
RF	TPE	15	11	4	18.04
XGB	Aleatorio	15	8	7	3.62
XGB	TPE	15	11	4	4.13
TOTAL	—	60	37	23	44.74

D.1 Espacio de búsqueda y parámetros fijos

Algoritmo	Hiperparámetro	Rango / opciones
RF	n_estimators	80–250, paso 10
RF	max_depth	3–16
RF	min_samples_split	2–12
RF	min_samples_leaf	1–8
RF	max_features	sqrt; 0.7; 1.0
XGB	n_estimators	80–280, paso 20
XGB	max_depth	2–9
XGB	learning_rate	0.01–0.20, logarítmico
XGB	subsample	0.60–1.00
XGB	colsample_bytree	0.60–1.00
XGB	min_child_weight	1–10

Valores de referencia: RF = n_estimators 150, max_depth 12, min_samples_leaf 3; XGB = n_estimators 150, max_depth 5, learning_rate 0.07, subsample 0.9 y colsample_bytree 0.9. XGBoost se ejecutó con objective=reg:squarederror y tree_method=hist.

D.2 Mejores hiperparámetros completos verificables

RF + Random: n_estimators=230, max_depth=11, min_samples_split=9, min_samples_leaf=1, max_features=sqrt

RF + Bayes_TPE: n_estimators=190, max_depth=12, min_samples_split=3, min_samples_leaf=1, max_features=sqrt

XGB + Random: n_estimators=200, max_depth=9, learning_rate=0.01303561122512888, subsample=0.6783931449676581, colsample_bytree=0.6180909155642152, min_child_weight=3.927972976869379

XGB + Bayes_TPE: n_estimators=280, max_depth=5, learning_rate=0.011964481144256049, subsample=0.7186031951965186, colsample_bytree=0.6295498706678058, min_child_weight=7.7732193266486025

La configuración seleccionada mediante MAE de validación independiente fue XGB + Random; CV 301.387 ± 14.563 kg, validación 316.207 kg; prueba final 361.647 kg (RMSE 451.920, R^2 0.022).

D.3 Tabla de 60 trials — estado de disponibilidad

El notebook contiene los cinco mejores registros de cada método, con MAE, desviación y duración (20 de 60). Los 40 restantes no están expuestos individualmente en las salidas guardadas. La siguiente tabla presenta todos los IDs 0–14 de cada experimento, completa los valores verificables y marca explícitamente los faltantes. La tabla plenamente poblada requiere artifacts/hpo_runs.csv o los cuatro archivos trials_*.csv originales.

Modelo	Método	ID trial	Estado individual	MAE CV ± DE (kg)	Tiempo (s)
RF	Random	0	Completo	308.190 ± 15.639	1.644
RF	Random	1	Completo	300.754 ± 15.868	5.466
RF	Random	2	No desglosado	No documentado	—
RF	Random	3	Completo	307.938 ± 15.598	0.784
RF	Random	4	No desglosado	No documentado	—
RF	Random	5	No desglosado	No documentado	—
RF	Random	6	No desglosado	No documentado	—
RF	Random	7	No desglosado	No documentado	—
RF	Random	8	Completo	312.099 ± 13.135	0.745
RF	Random	9	Completo	309.414 ± 13.741	1.129
RF	Random	10	No desglosado	No documentado	—
RF	Random	11	No desglosado	No documentado	—
RF	Random	12	No desglosado	No documentado	—
RF	Random	13	No desglosado	No documentado	—
RF	Random	14	No desglosado	No documentado	—
RF	TPE	0	No desglosado	No documentado	—
RF	TPE	1	Completo	300.754 ± 15.868	1.673
RF	TPE	2	No desglosado	No documentado	—
RF	TPE	3	No desglosado	No documentado	—
RF	TPE	4	No desglosado	No documentado	—
RF	TPE	5	Completo	301.358 ± 15.795	1.628
RF	TPE	6	No desglosado	No documentado	—
RF	TPE	7	No desglosado	No documentado	—
RF	TPE	8	No desglosado	No documentado	—
RF	TPE	9	No desglosado	No documentado	—
RF	TPE	10	No desglosado	No documentado	—
RF	TPE	11	Completo	299.420 ± 18.068	1.603
RF	TPE	12	Completo	298.251 ± 15.033	1.392
RF	TPE	13	No desglosado	No documentado	—
RF	TPE	14	Completo	300.006 ± 14.925	1.492
XGB	Random	0	No desglosado	No documentado	—
XGB	Random	1	Completo	306.908 ± 14.799	0.174

XGB	Random	2	Completo	303.174 ± 17.112	0.216
XGB	Random	3	No desglosado	No documentado	—
XGB	Random	4	Completo	305.429 ± 15.518	0.517
XGB	Random	5	Completo	304.005 ± 16.570	0.214
XGB	Random	6	No desglosado	No documentado	—
XGB	Random	7	No desglosado	No documentado	—
XGB	Random	8	No desglosado	No documentado	—
XGB	Random	9	Completo	301.387 ± 14.563	0.396
XGB	Random	10	No desglosado	No documentado	—
XGB	Random	11	No desglosado	No documentado	—
XGB	Random	12	No desglosado	No documentado	—
XGB	Random	13	No desglosado	No documentado	—
XGB	Random	14	No desglosado	No documentado	—
XGB	TPE	0	No desglosado	No documentado	—
XGB	TPE	1	No desglosado	No documentado	—
XGB	TPE	2	No desglosado	No documentado	—
XGB	TPE	3	No desglosado	No documentado	—
XGB	TPE	4	No desglosado	No documentado	—
XGB	TPE	5	Completo	302.398 ± 14.950	0.360
XGB	TPE	6	No desglosado	No documentado	—
XGB	TPE	7	No desglosado	No documentado	—
XGB	TPE	8	No desglosado	No documentado	—
XGB	TPE	9	No desglosado	No documentado	—
XGB	TPE	10	No desglosado	No documentado	—
XGB	TPE	11	Completo	302.054 ± 14.109	0.271
XGB	TPE	12	Completo	300.844 ± 12.250	0.316
XGB	TPE	13	Completo	301.328 ± 12.462	0.284
XGB	TPE	14	Completo	302.683 ± 13.179	0.302

Importante. Los estados completos/podados de las 40 corridas no desglosadas no se atribuyeron individualmente. Sí se verificó el total por grupo: RF–Random 7/8; RF–TPE 11/4; XGB–Random 8/7; XGB–TPE 11/4 (completos/podados).

D.4 Comparación en validación independiente

Modelo	Método	MAE (kg)	RMSE (kg)	R^2
XGB	Random	316.207	405.249	0.210
XGB	Bayes_TPE	316.905	399.963	0.231
RF	Random	317.336	399.301	0.233
RF	Bayes_TPE	324.222	410.488	0.190
RF	Baseline	324.387	410.076	0.191
XGB	Baseline	364.549	444.666	0.049

Anexo E. Evidencia de ejecución, repositorio, logs, pruebas y figuras

La evidencia disponible corresponde a las salidas guardadas en el notebook .ipynb. Los archivos citados como generados en artifacts/ figuran en la salida de la celda final, pero no se proporcionó el directorio original exportado: por ello no se presentan como archivos independientes revisados. Tampoco se facilitó una URL verificable del repositorio.

Origen / elemento	Prueba / evidencia	Estado
Celdas 4 y 6	Versiones: Python 3.13.18; sklearn 1.6.1; XGB 3.4.1; Optuna 5.0.0; auditoría 733→730	Verificada en stdout
Celda 10	Particiones 510 / 110 / 110 y 3 folds 132/126, 258/126, 384/126	Verificada en stdout
Celdas 18, 20, 22, 24	Cuatro búsquedas individuales, mejor MAE CV y configuración ganadora	Verificada en stdout; top-5 visible
Celda 26	60 pruebas; 37 completas y 23 podadas	Verificada en stdout
Celda 27	Tabla comparativa de validación y elección XGB Random	Verificada en salida
Celda 31	Test: MAE 361.646676, RMSE 451.920434, R^2 0.021971; ajuste 0.25 s	Verificada en stdout
Celda 33	Lista de 17 artefactos y ZIP del entorno de ejecución	Reportada por notebook; archivos originales no adjuntos
Repositorio GitHub	URL, commit y README de ejecución	No verificable con lo adjuntado
CSV original	SHA-256, licencia, autorización y fecha de obtención	No disponible
Pruebas automáticas	Test unitarios/funcionales, integridad, ausencia de leakage	Parciales: asserts documentados; suite independiente no disponible
Modelos y optimizador	modelo_predictivo.joblib; instancia OR-Tools	Modelo reportado pero binario no adjunto; OR-Tools pendiente

E.1 Registros y artefactos reportados en la ejecución

Los nombres de los archivos fueron listados en la salida de la celda 33: search_config.yaml, hpo_runs.csv, comparacion_validacion.csv, config_ganadora.json, metricas_test.csv, modelo_predictivo.joblib, trials_RF_Random.csv, trials_RF_Bayes_TPE.csv, trials_XGB_Random.csv, trials_XGB_Bayes_TPE.csv, comparacion_mae.png, evolucion_RF_Random.png, evolucion_RF_Bayes_TPE.png, evolucion_XGB_Random.png, evolucion_XGB_Bayes_TPE.png, evolucion_trials.png y predicciones_test.png.

Para completar la entrega, se debe adjuntar la exportación real de artifacts/, junto con README, requirements.txt, versión y hash del CSV, URL/commit de GitHub y comprobación

de ejecución limpia. El presente paquete incluye extracciones fieles de figuras y salidas visibles, rotuladas como tales.

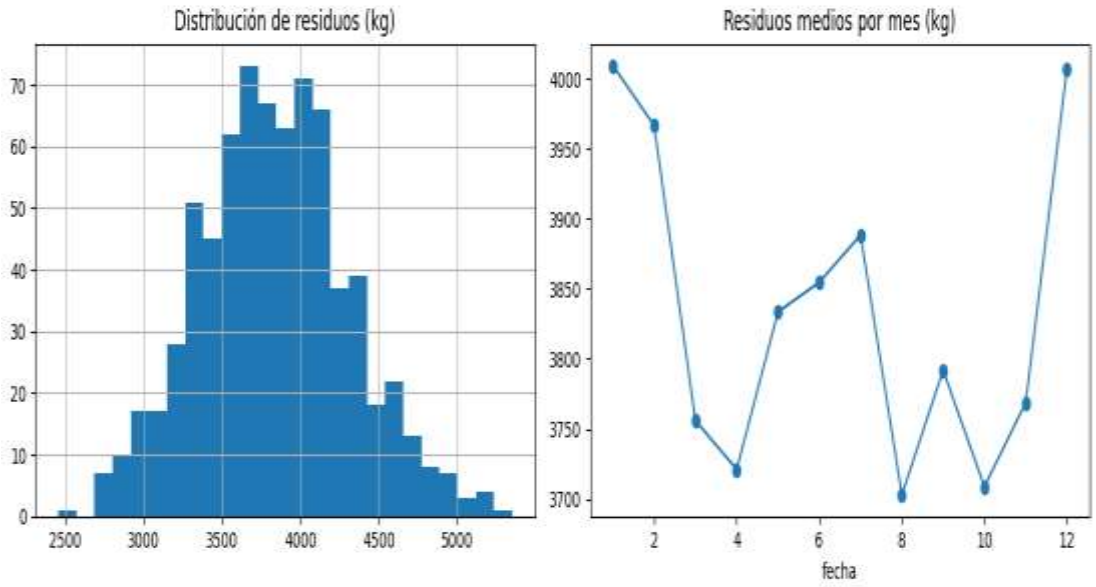
E.2 Pruebas verificables y pendientes

Prueba	Resultado respaldado	Estado
Consistencia temporal	train.fecha.max() < val.fecha.min() < test.fecha.min()	Validado por assert del notebook
Existencia de columnas predictoras	Los 13 atributos aparecen en el conjunto procesado	Validado por assert
Presupuesto mínimo	N_TRIALS >= 1	Validado por assert
Cuatro búsquedas antes de comparar	len(estudios)==4	Validado por condición en notebook
Pruebas unitarias, CI/CD y ejecución desde cero	No se proporcionó salida independiente de esas pruebas	Pendiente
Comparación de rutas y factibilidad	No existe salida de optimizador combinatorio	Pendiente

E.3 Figuras verificadas en las salidas del notebook

Figura E1.

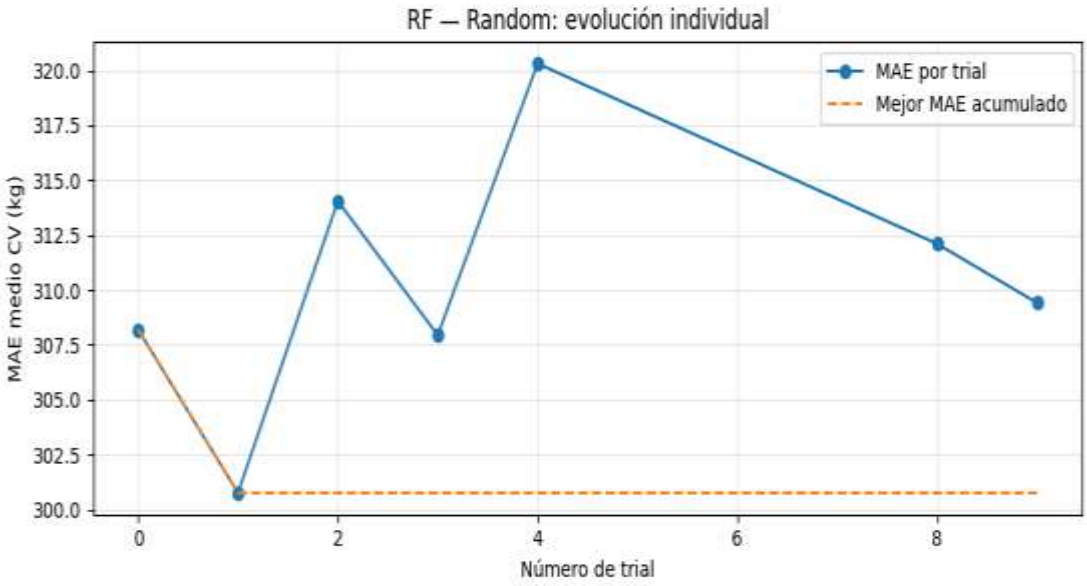
Distribución de residuos y promedio mensual. Salida guardada, celda 8



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos.

Figura E2.

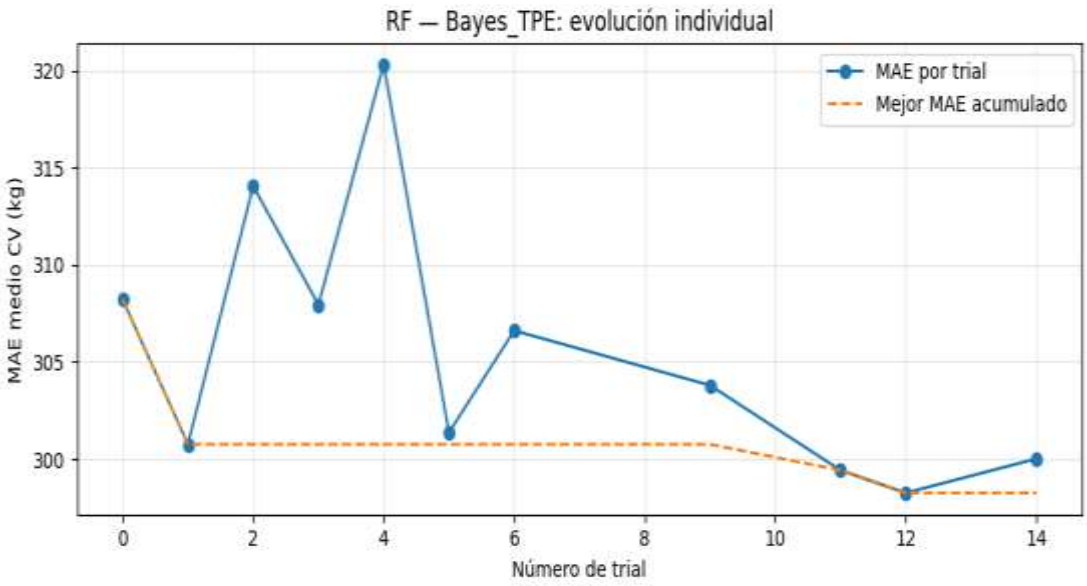
Evolución de Random Forest con búsqueda aleatoria. Salida guardada, celda 18



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos.

Figura E3.

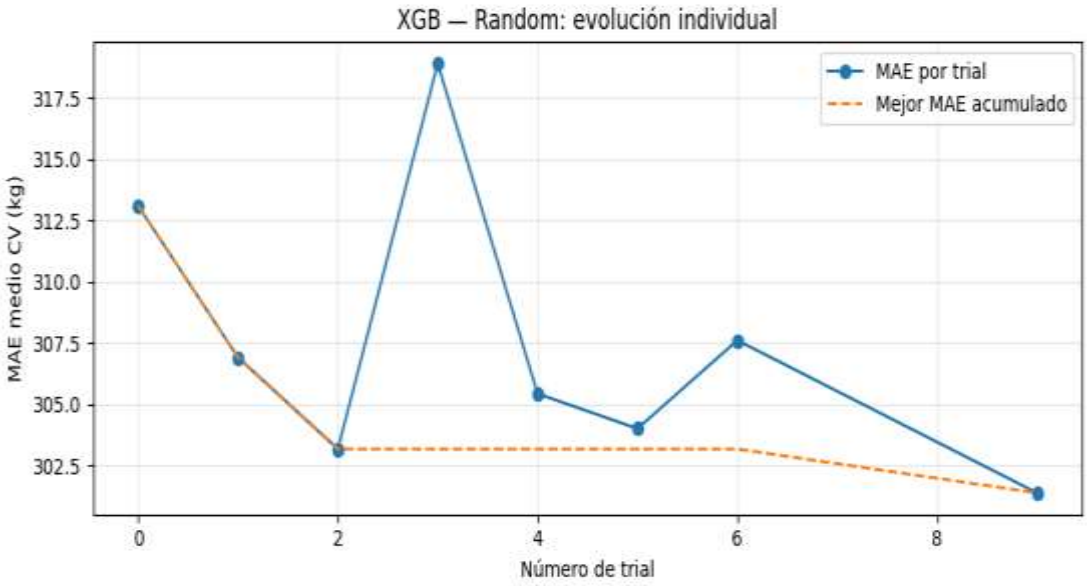
Evolución de Random Forest con TPE. Salida guardada, celda 20.



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos

Figura E4.

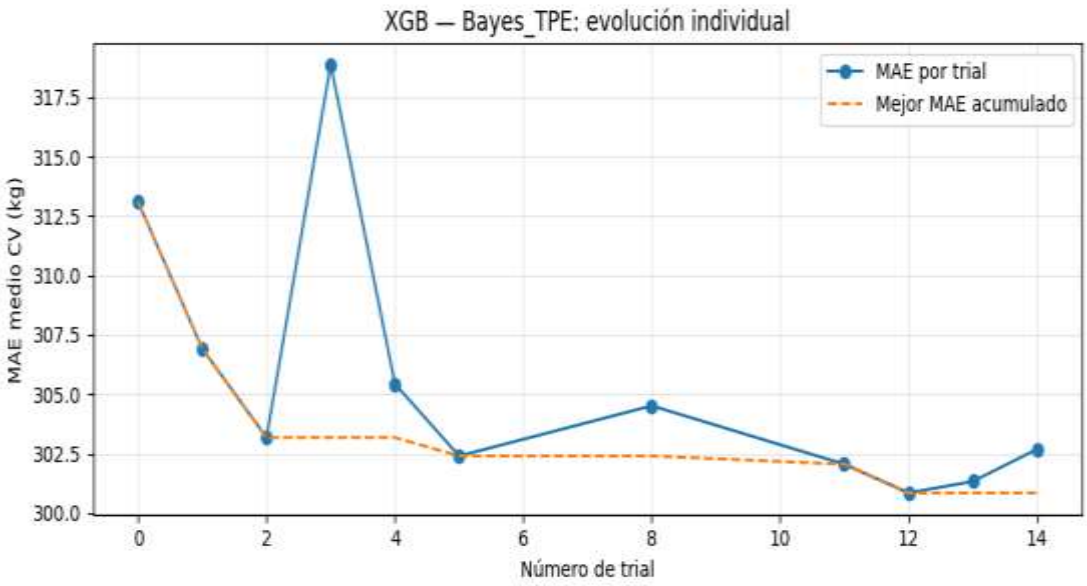
Evolución de XGBoost con búsqueda aleatoria. Salida guardada, celda 22.



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos

Figura E5.

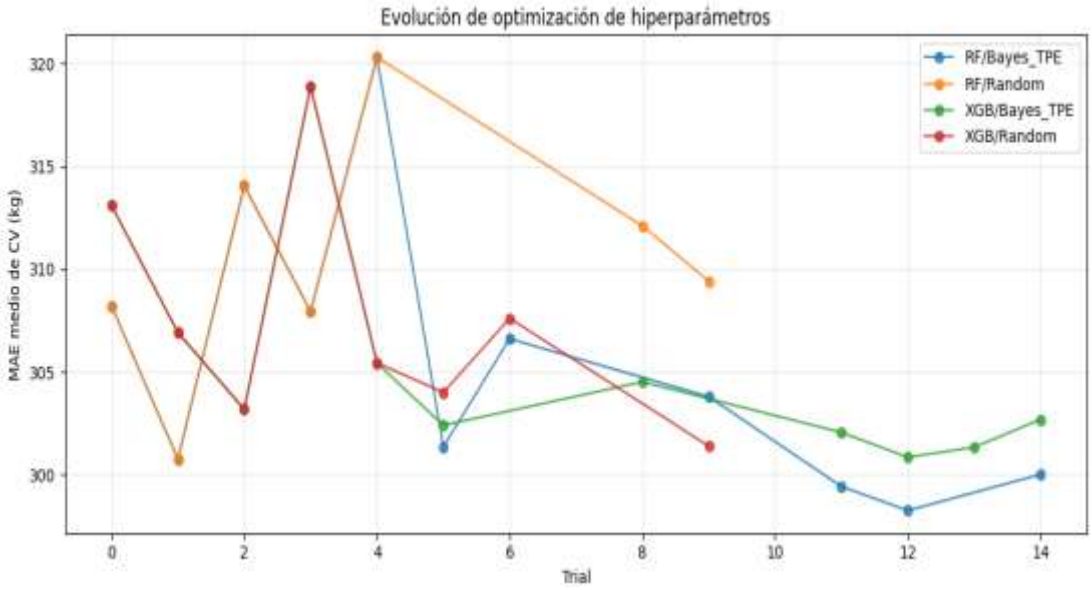
Evolución de XGBoost con TPE. Salida guardada, celda 24.



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos

Figura E6.

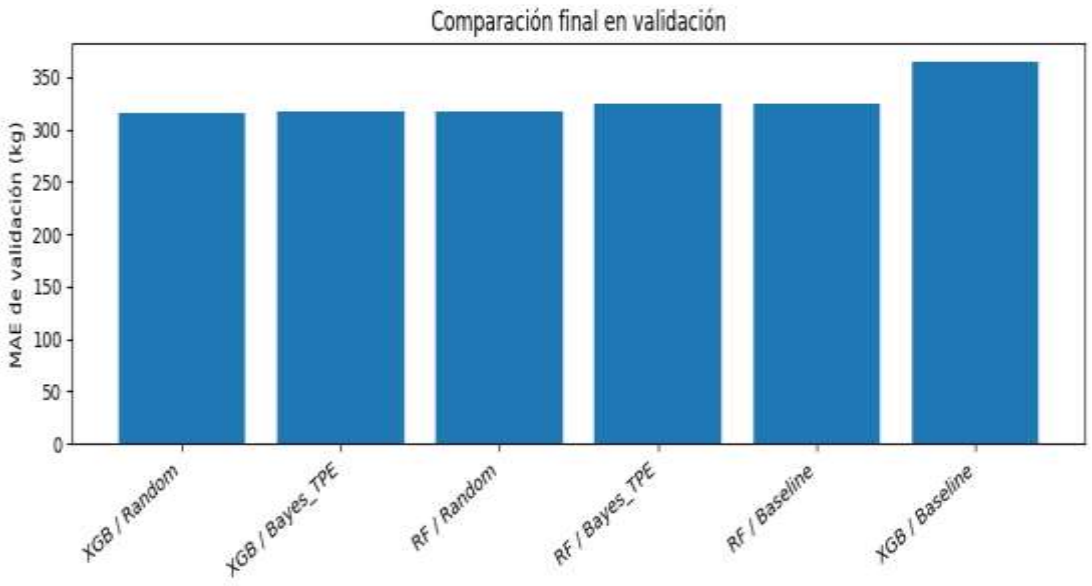
Evolución global de pruebas. Salida guardada, celda 29.



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos

Figura E7.

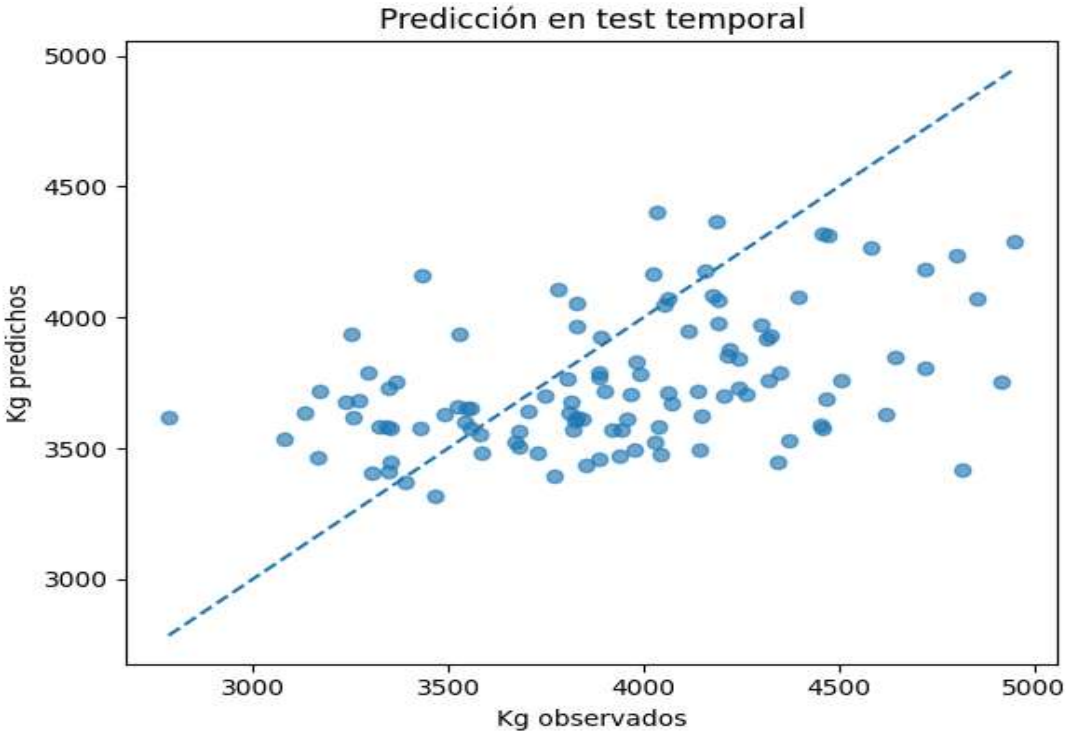
Comparación del error absoluto medio. Salida guardada, celda 29.



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos.

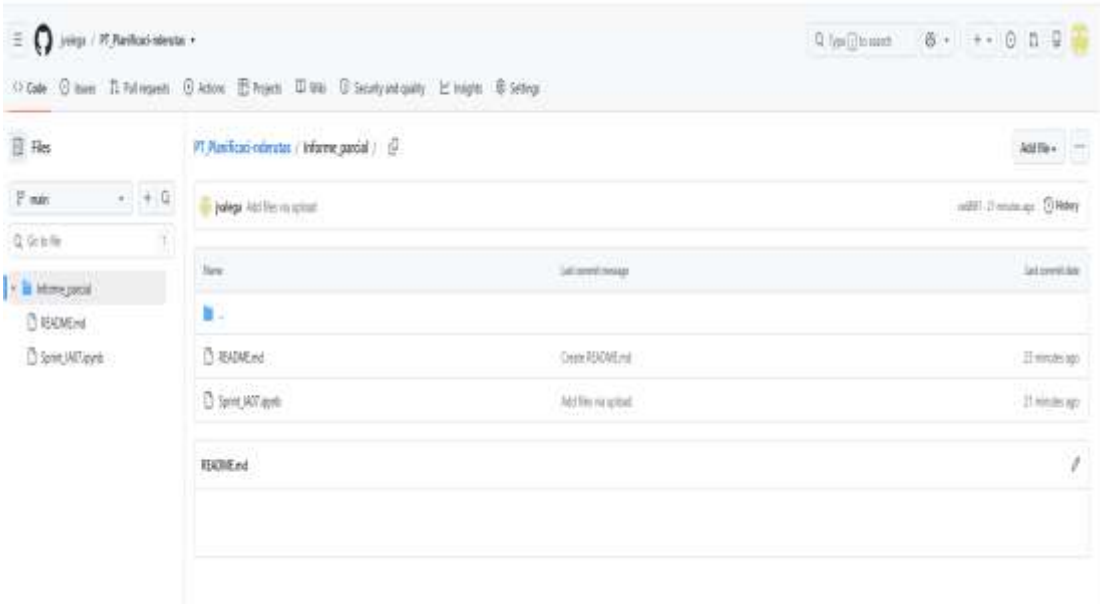
Figura E8.

Predicciones del conjunto de prueba. Salida guardada, celda 31.



Nota. Imagen recuperada de la salida image/png del notebook; no es una figura generada con nuevos datos.

Anexo F. Repositorio de GitHub del código fuente y cuaderno experimental del Sprint IA07



https://github.com/jvalega/PT_Planificaci-nderutas/tree/main/Informe_parcial